Segmentación de clientes Mercedes-Benz

Informe de resultados del proyecto — Malackathon, reto Mercedes-Benz

Segmentación no supervisada (K-Means) de 173.456 clientes de Suiza y Austria para habilitar campañas de ofertas de vehículo, mantenimiento, fidelización y comunicación dirigida.

Resumen ejecutivo

• **Datos:** 302.850 relaciones cliente–vehículo, 173.456 clientes. Tras el tratamiento no queda ningún nulo y las 15 comprobaciones de coherencia dan 0 errores.

• **Features:** 13 variables de modelo (perfil, relación con la marca, gama, energía, antigüedad y mantenimiento), log1p + StandardScaler en un Pipeline. Se eliminó *tiene_vehiculo_actual* por redundante con *n_vehiculos_actuales* (coinciden en el 99,998 % de los clientes).

• **Modelo:** K-Means con **k = 8** (silhouette 0,163; Davies-Bouldin 1,74). Se probó k = 7 y fue menos estable (ARI Jackknife 0,63 frente a 0,69).

• **Segmentos:** 8 segmentos K-Means + 1 segmento Flota/Profesional (833 cuentas excluidas del entrenamiento).

• **Robustez:** K-Means es el mejor de los algoritmos comparados; 5 de los 8 segmentos son estables o muy estables.

1. EDA y calidad de datos

Cada fila es una relación cliente–vehículo, así que para segmentar se agrega por cliente.

Características principales de los clientes

• Particulares: el 99,4 % son B2C y el 61 % tiene 45 años o más.

• Mayoría en Suiza (66 %); poder adquisitivo de su zona ≈ 1,7 veces el de Austria (51 k€ frente a 30 k€ por habitante).

• Un solo coche conectado en el 81 % de los casos; el 10 % no tiene ningún vehículo actual (ex-clientes).

• Relación de unos 3 años con la marca; el 71 % no ha usado nunca leasing (más habitual en Suiza y entre 35 y 44 años).

• El 81 % acepta teléfono, email y correo postal.

• SUV y compactos premium (GLC, C, A, B/GLA/GLB), 13 % AMG, 14 % furgonetas; antigüedad mediana del coche 4,7 años.

• Electrificación en subida: los eléctricos pasan del 2,5 % de las matriculaciones de 2019 al 37,5 % de las de 2026.

• Uso urbano: trayectos de unos 14 km a unos 49 km/h.

Problemas de calidad y solución

Problema	Solución
Columnas sin valor analítico (índice, IDs, model_class)	Eliminadas; los IDs solo como clave de agregación
Telemetría ausente en el 52 % de las filas	Sin telemetría → 0 + indicador has_telemetry; parcial → mediana/moda de su serie
Motorización nula (44 %) y combustible nulo (59 %)	Reglas por nombre comercial, serie y año (99–100 % de acierto); el resto con la moda
Código postal nulo (5 %) y datos de zona nulos (6 %)	Código postal real del país por cliente; datos de zona del código postal o de la región
Valores imposibles (velocidad < 1 km/h, horas a 0…)	Tratados como nulos; extremos recortados a P1–P99
Género desconocido (17 %)	Categoría unknown
Pico artificial en 36 meses como cliente (12 %)	Se conserva y se marca con un indicador

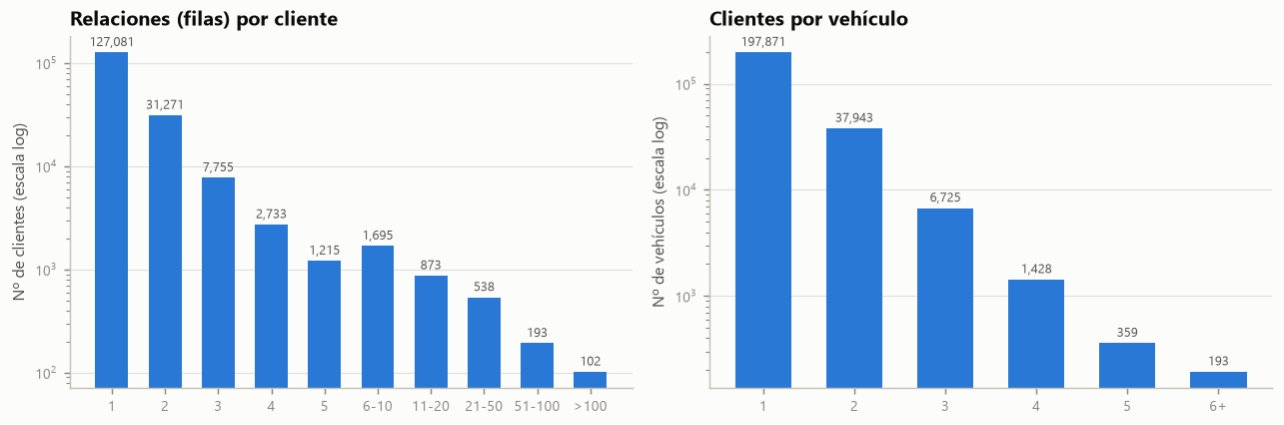


Figura 1.1. Granularidad: relaciones por cliente

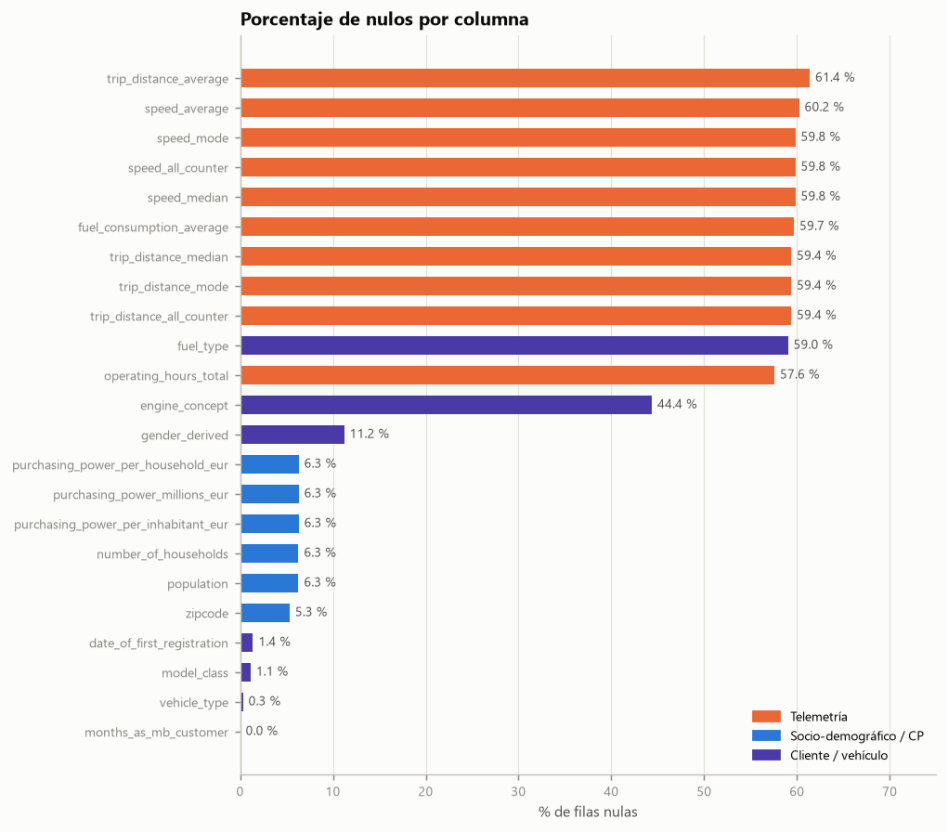


Figura 1.2. Nulos por columna

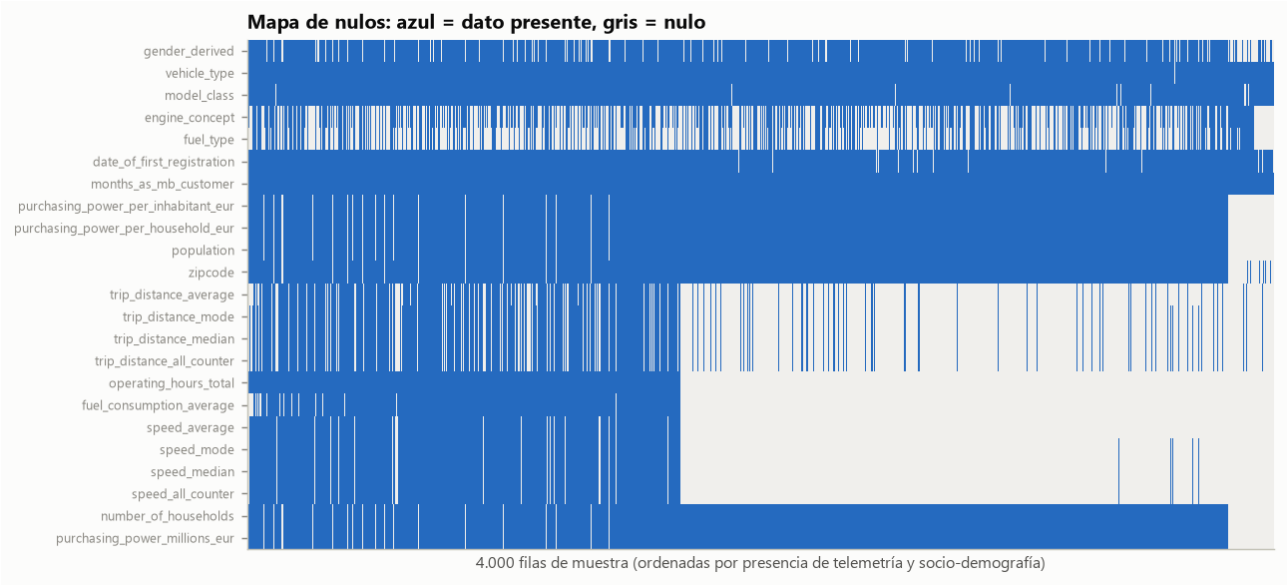


Figura 1.3. Mapa de nulos

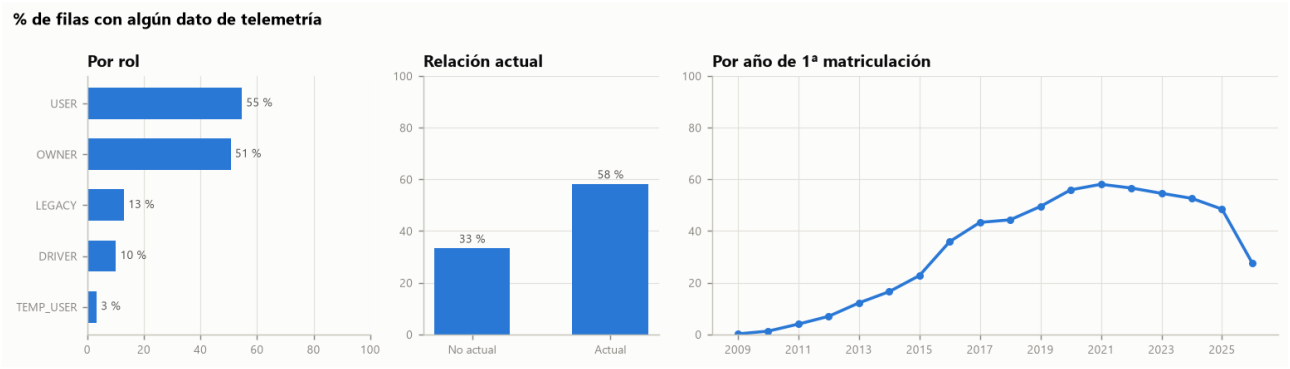


Figura 1.4. Disponibilidad de telemetría

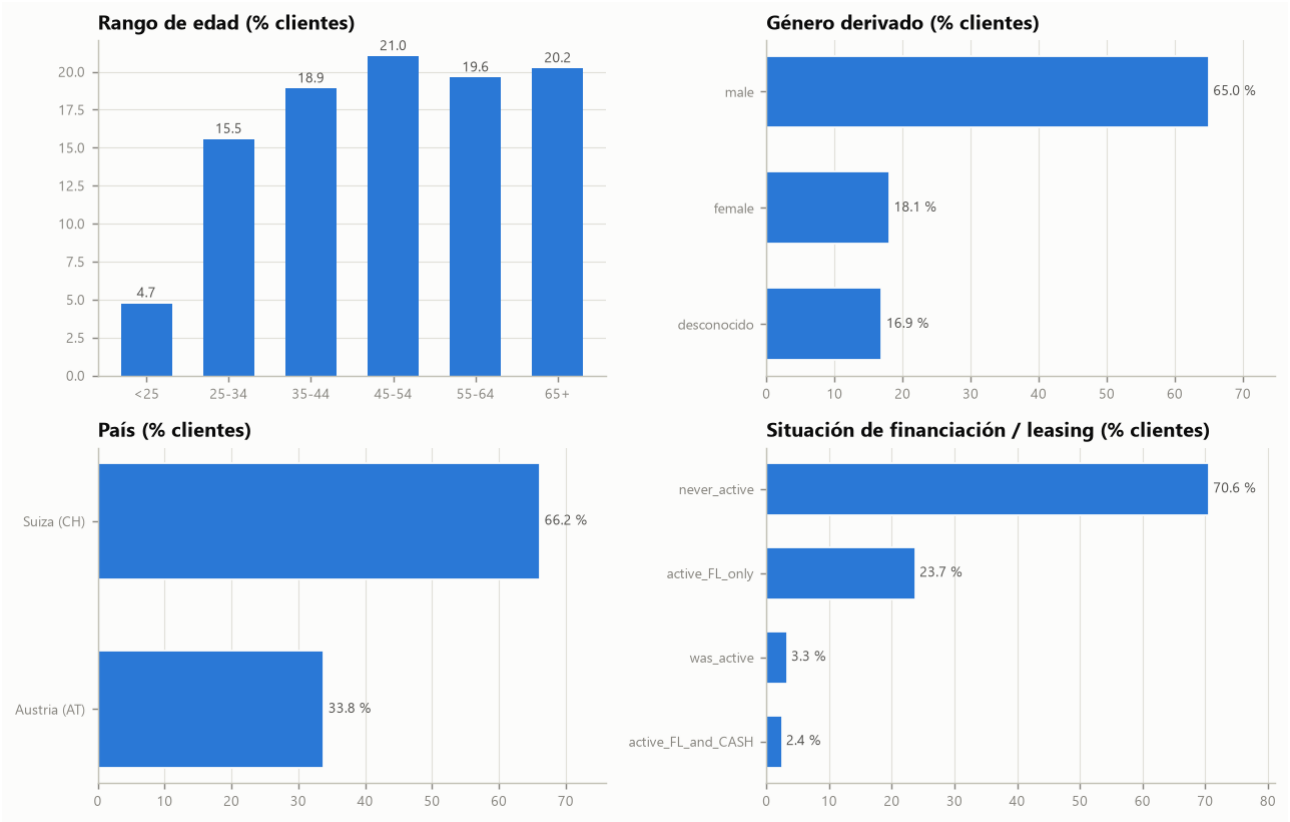


Figura 1.5. Perfil del cliente

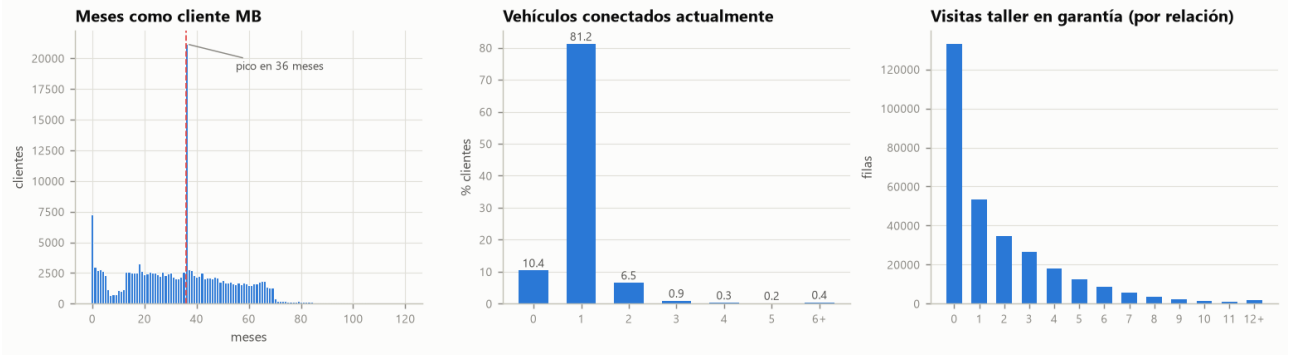


Figura 1.6. Relación con la marca

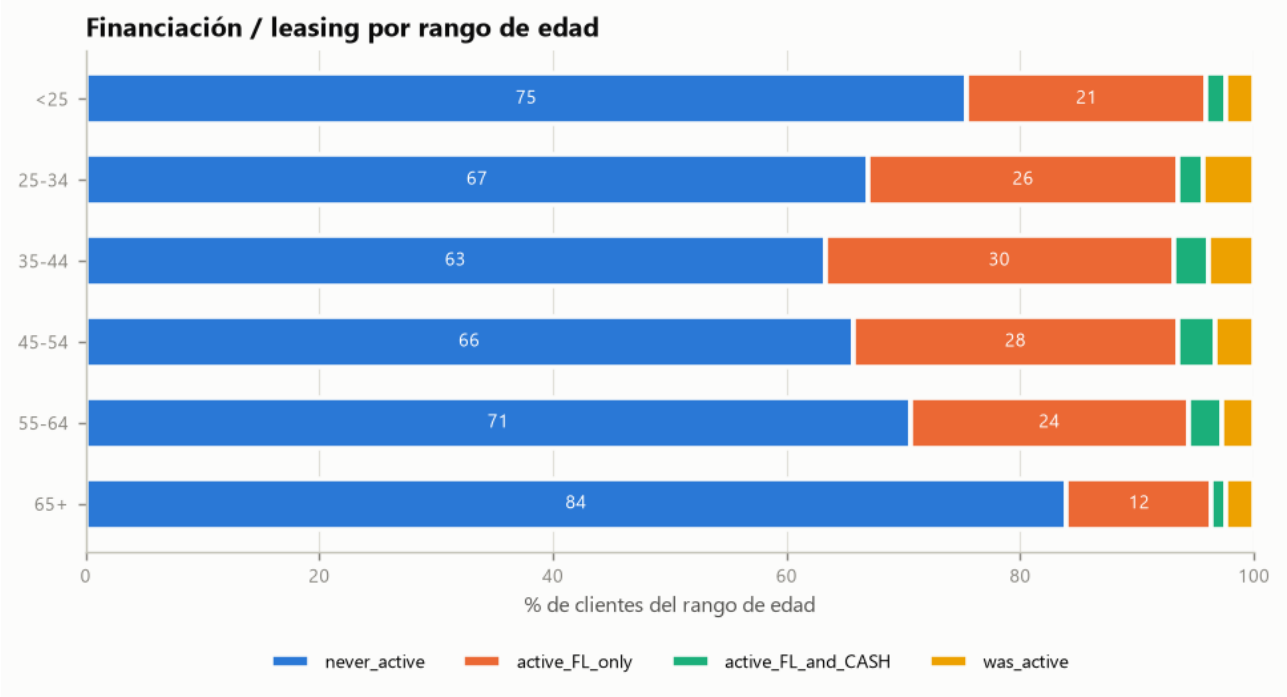


Figura 1.7. Financiación por edad

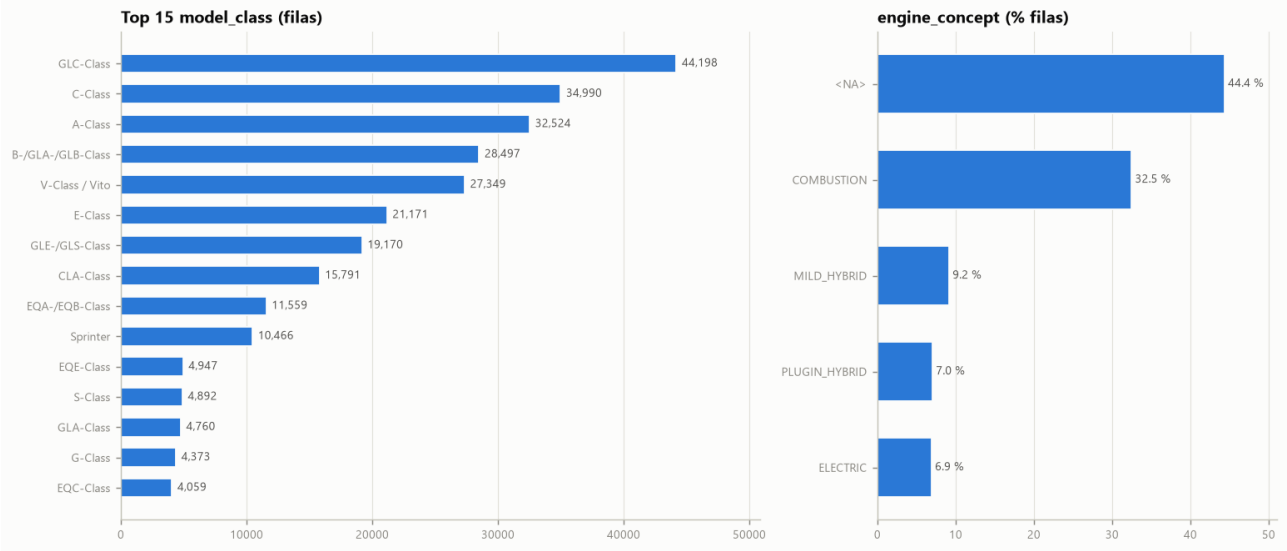


Figura 1.8. Clase de vehículo y motor

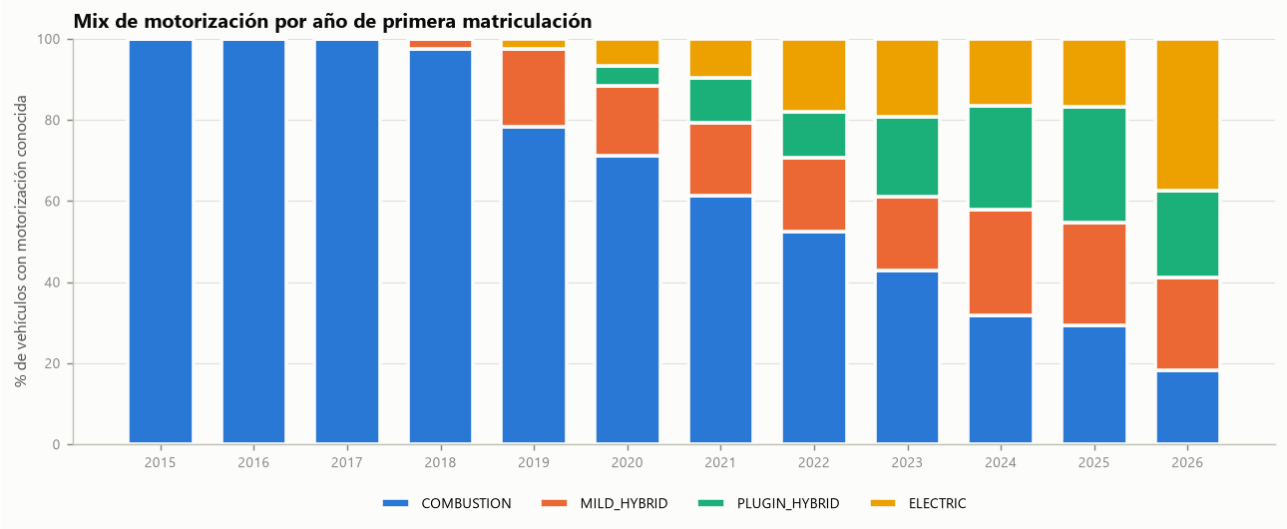


Figura 1.9. Electrificación por año de matriculación

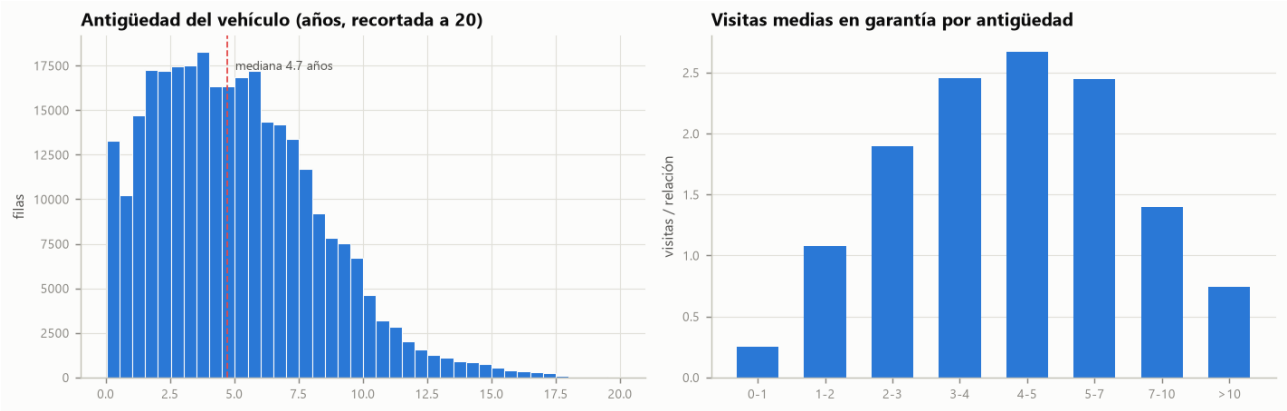


Figura 1.10. Antigüedad y visitas al taller

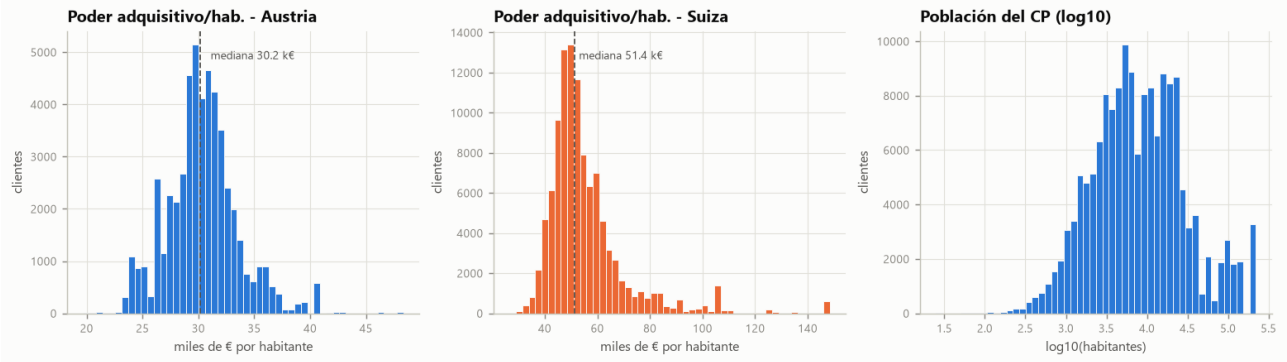


Figura 1.11. Socio-demografía de la zona

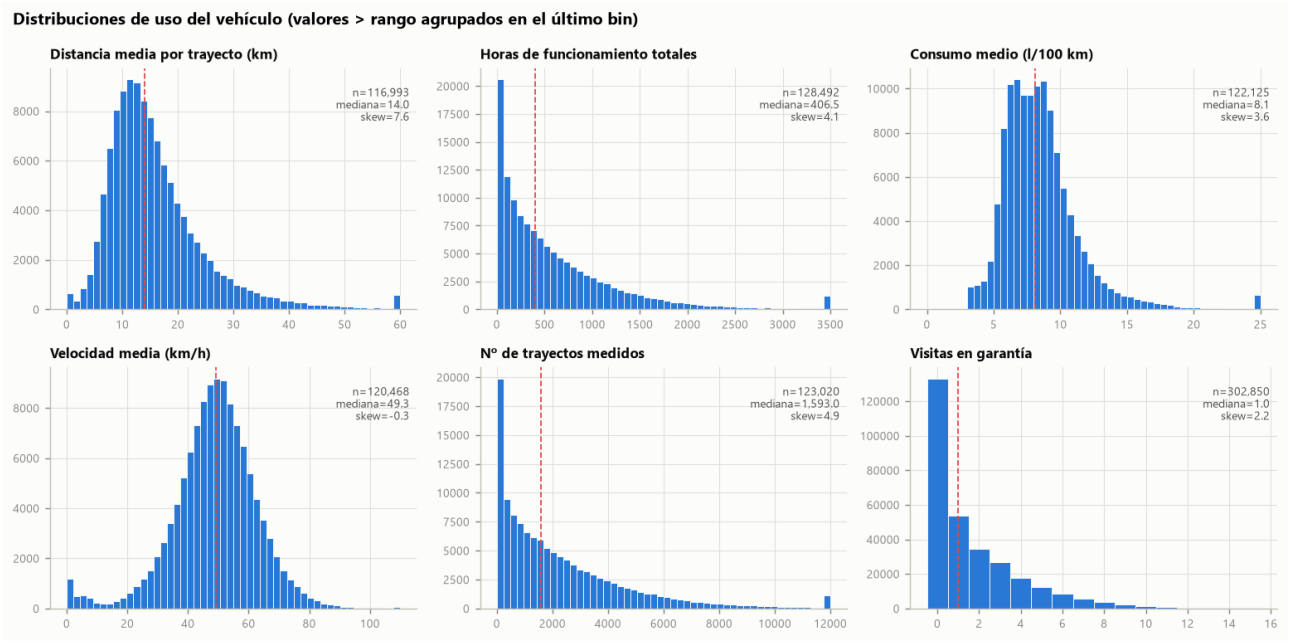


Figura 1.12. Distribuciones de telemetría

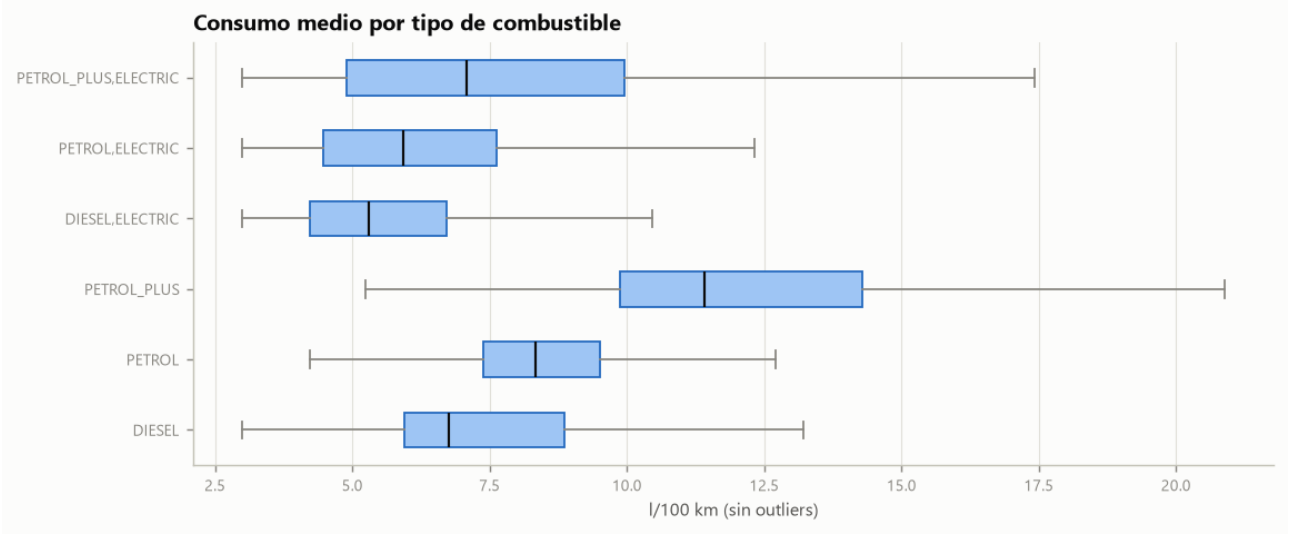


Figura 1.13. Consumo por combustible

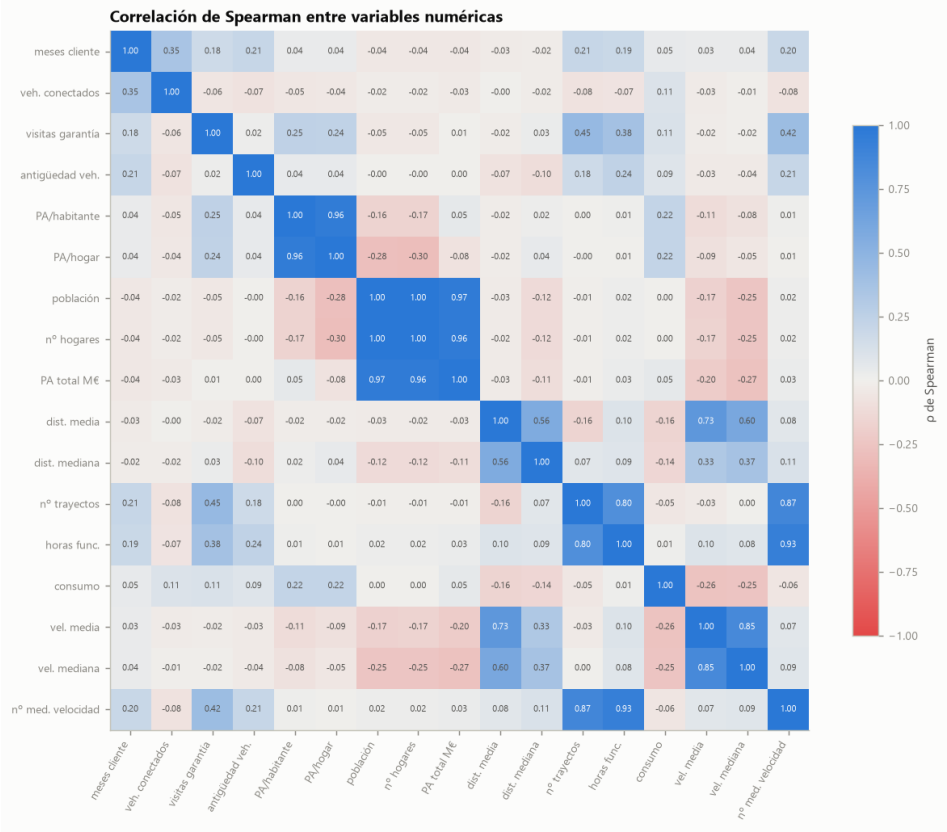


Figura 1.14. Correlación de Spearman

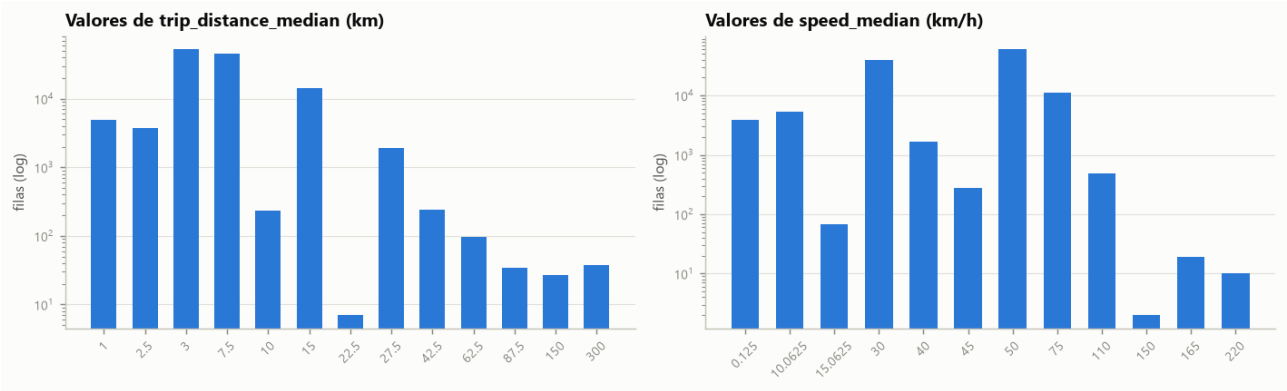


Figura 1.15. Medianas discretizadas

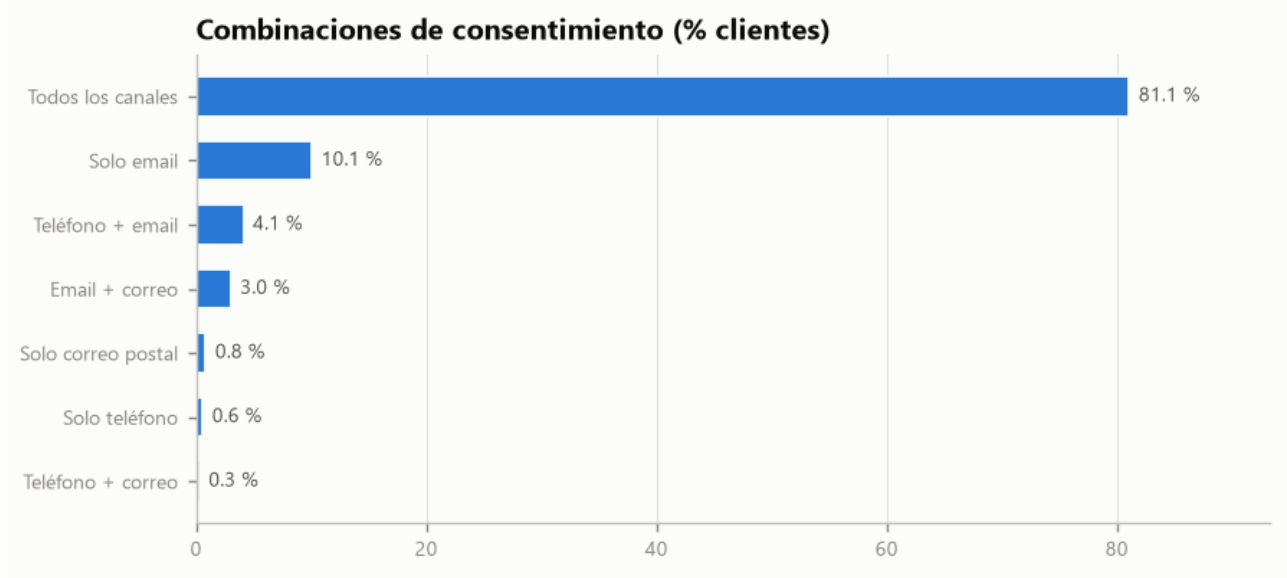


Figura 1.16. Consentimientos de comunicación

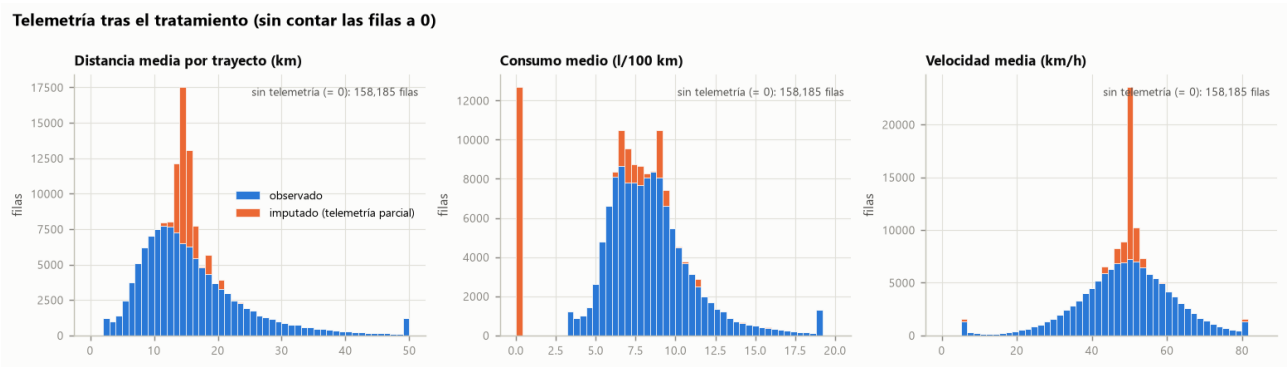


Figura 1.17. Impacto del relleno de telemetría

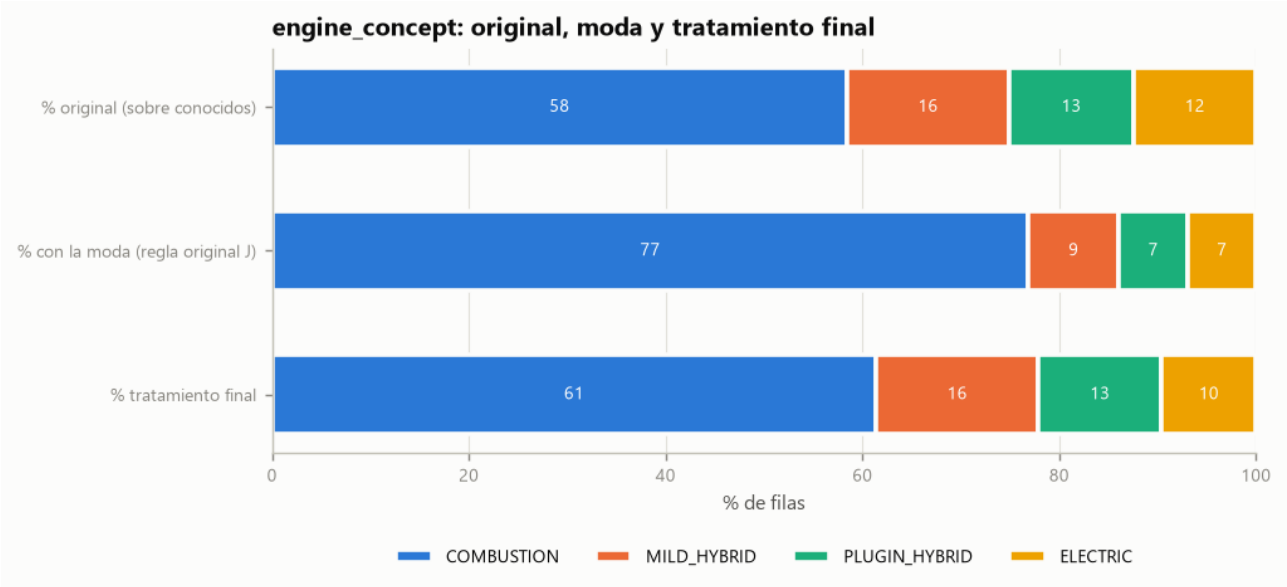


Figura 1.18. Motorización: moda frente a reglas

2. Feature engineering

Las 833 cuentas con más de 20 relaciones (concesionarios, rent-a-car o flotas) se apartan como segmento propio. El resto se segmenta con 13 features; telemetría, país y leasing pasado se usan solo para describir.

#	Feature	Por qué se incluye
1	edad_ord	Etapa vital
2	meses_cliente	Antigüedad y fidelidad
3	n_vehiculos_actuales	Valor del cliente; con 0 identifica a los ex-clientes
4	leasing_activo	Contrato vivo: renovación
5	pa_relativo_pais	Poder adquisitivo relativo a su país
6–9	share_compacto / suv / lujo_deportivo / furgoneta	Gama de la flota
10	share_amg	Altas prestaciones
11	share_electrificado	Transición energética
12	edad_vehiculo	Ciclo de renovación y garantía
13	visitas_por_vehiculo	Necesidad de mantenimiento

Cambio respecto a la versión anterior: se eliminó *tiene_vehiculo_actual*. Era redundante con *n_vehiculos_actuales* y duplicaba el peso de esa dimensión, sesgando el modelo hacia separar activos de ex-clientes.

Sensibilidad: con 18 features el mejor silhouette es 0,144 (k = 5); con las 13 del modelo el silhouette es mayor para todos los k = 4–8.

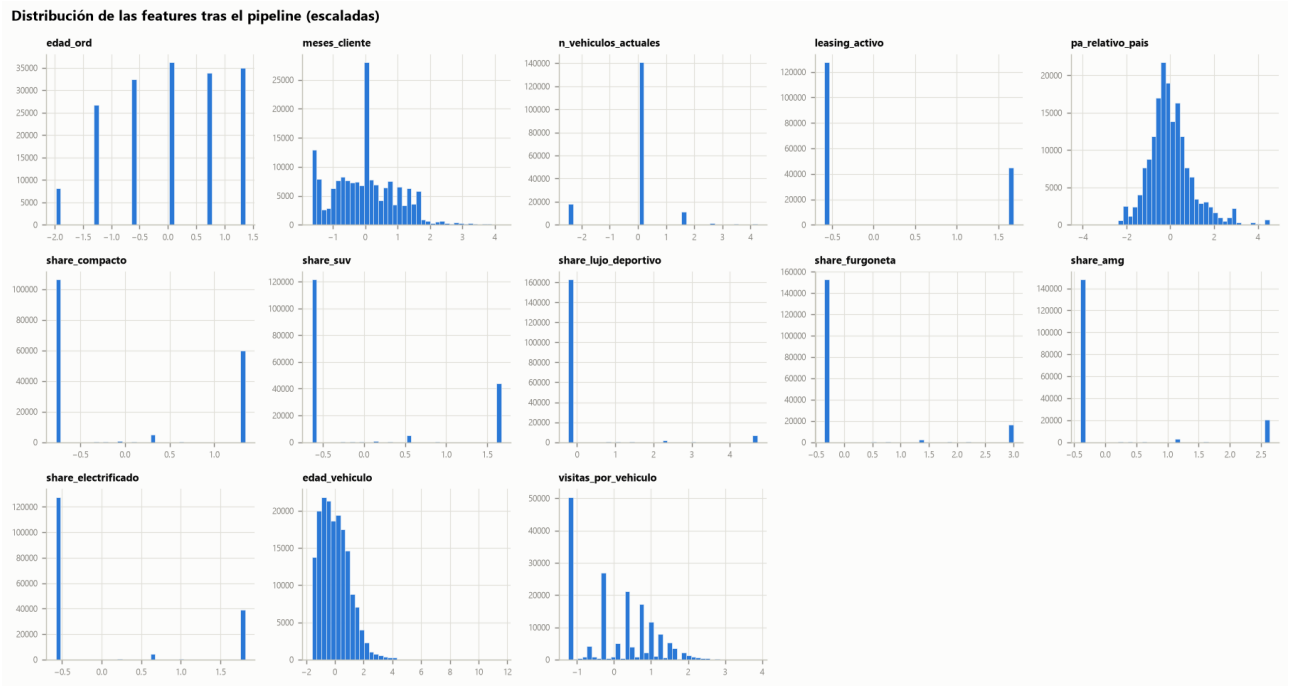


Figura 2.1. Distribución de las features

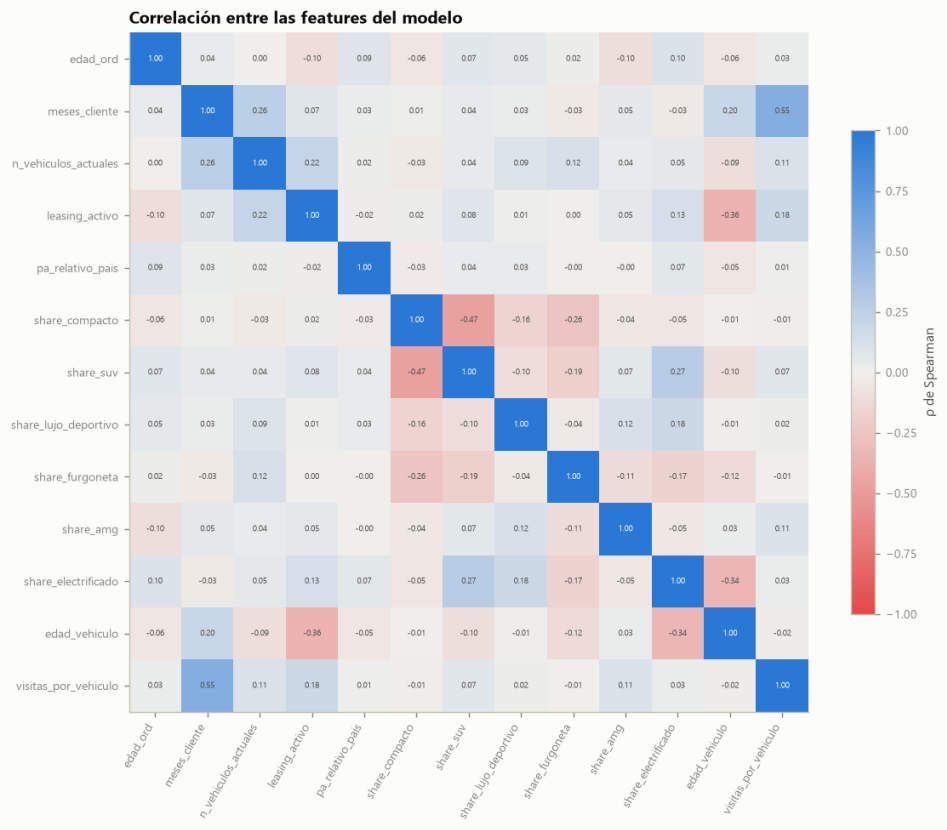


Figura 2.2. Correlación entre features (sin pares |ρ| > 0,8)

3. Modelo K-Means

K-Means para k = 2…10. Criterio: mejor silhouette dentro del rango de negocio (4–8 segmentos, todos ≥ 3 % de los clientes); a menos de 0,01 de silhouette se prefiere el mejor Davies-Bouldin. **k elegido = 8** (silhouette 0,163, Davies-Bouldin 1,74, clúster más pequeño 4,2 %).

k	silhouette	Davies-Bouldin	Calinski-Harabasz	clúster mín. %
2	0.135	2.682	2,386	34.0
3	0.165	2.227	2,380	10.9
4	0.141	2.313	2,225	10.3
5	0.149	1.974	2,371	5.1
6	0.145	1.909	2,265	4.6
7	0.158	1.824	2,260	4.5
8	0.163	1.739	2,201	4.2
9	0.170	1.697	2,122	4.2
10	0.151	1.723	2,003	4.2

Prueba con k = 7: estabilidad Jackknife peor (ARI medio 0,633 frente a 0,691; Jaccard del segmento más débil 0,33 frente a 0,53). Se mantiene k = 8.

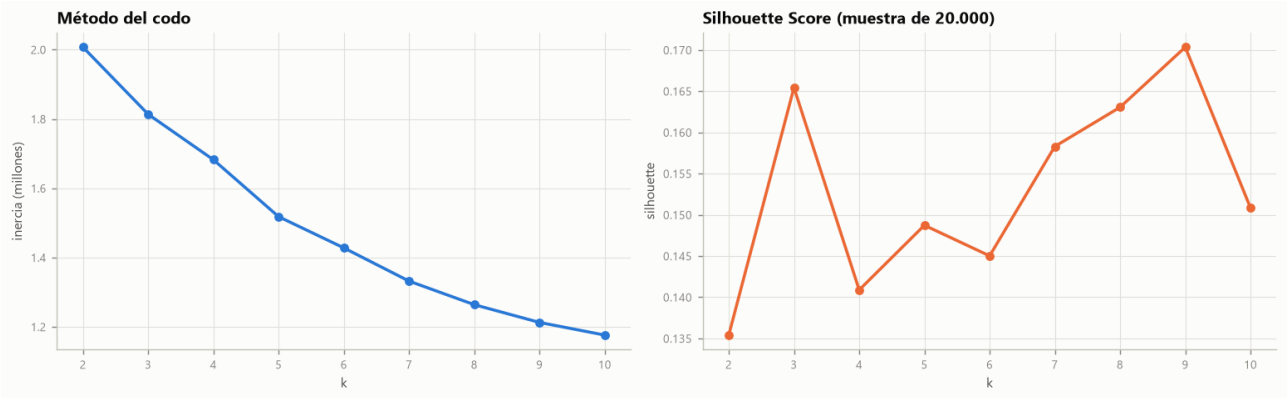


Figura 3.1. Método del codo y silhouette

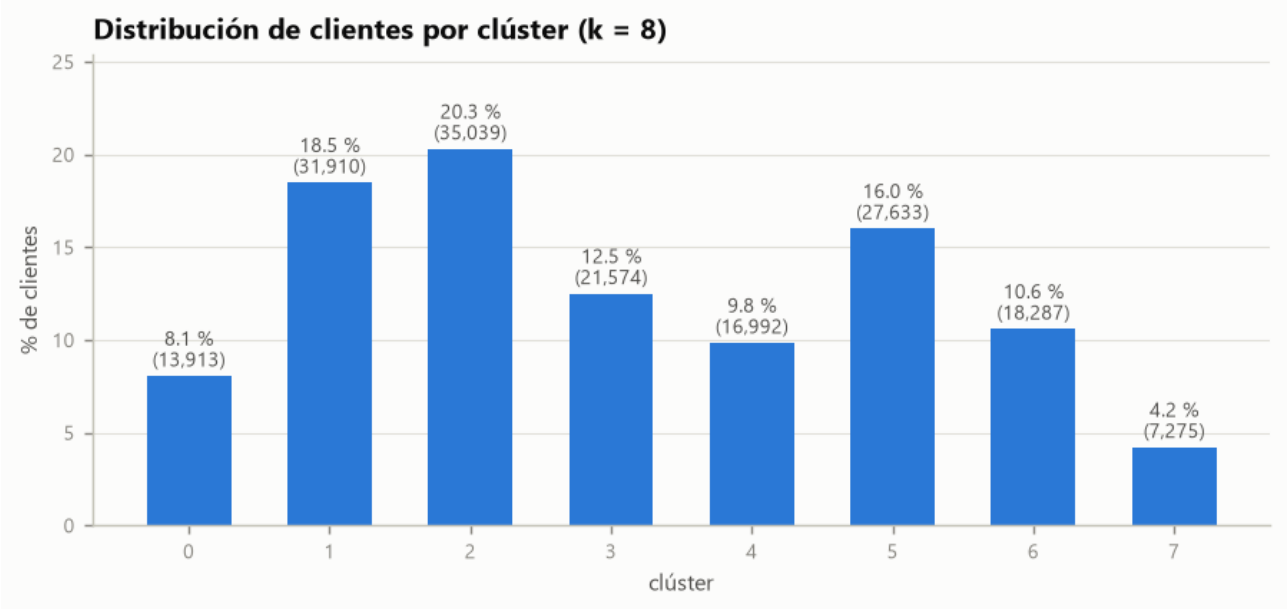


Figura 3.2. Distribución de clientes por clúster

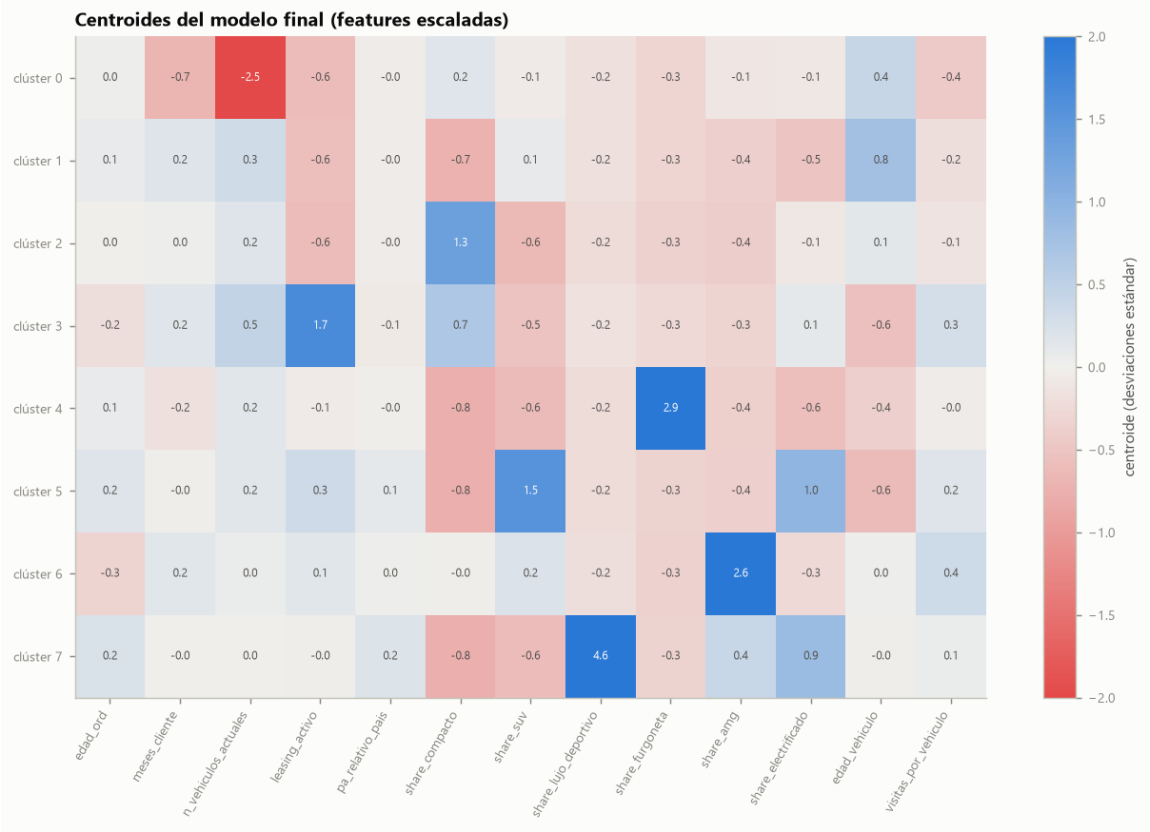


Figura 3.3. Centroides del modelo final (features escaladas)

4. Perfilado de los segmentos

Segmento	%	Quién es	Acción
Compacto al contado	20,2	A, B/GLA/GLB o CLA de ~5 años, sin financiación; 20 % electrificado	Renovación a compacto nuevo o EQA/EQB con financiación; mantenimiento al salir de garantía
Berlina clásica al contado	18,4	C/E y algo de GLC, ~7 años (los más antiguos), sin financiación, 3 % electrificado	Mantenimiento y extensión de garantía; renovación financiada con paso a híbrido
Familia SUV híbrida	15,9	GLC/GLE, 64 % electrificado (sobre todo PHEV), 45+ años, 41 % con leasing	Paso a SUV eléctrico, accesorios, mantenimiento de híbridos
Urbano financiado	12,4	100 % leasing, compactos de ~3 años, 19 % BEV, más joven, 77 % Suiza	Renovación anticipada al vencer el contrato, upgrade a EQ, canal digital
Entusiasta AMG	10,5	Flota casi solo AMG; el más joven y el más suizo (92 %); más visitas al taller	Eventos AMG, mantenimiento premium, personalización
Trabajador profesional que utiliza furgoneta	9,8	V-Class, Vito o Sprinter de ~4 años; 35–64 años	Taller prioritario, mantenimiento por km, eVito/eSprinter
Ex-cliente por recuperar	8,0	Sin vehículo actual; menos meses como cliente; 12 % salió de un leasing	Win-back: ocasión certificada o nuevo leasing, por email
Élite eléctrica y lujo	4,2	EQE/EQS, Clase S/Maybach, AMG GT; 50 % BEV; zona más rica; más edad	Gestor dedicado, acceso preferente, recogida y entrega
Flota / Profesional	0,5	833 cuentas con más de 20 relaciones (fuera del K-Means)	Gestión B2B; revisar el rol en el CRM

Nota: sin la binaria *tiene_vehiculo_actual*, los ex-clientes con una flota muy marcada se quedan en el segmento de su gama (el 9 % de Furgoneta, el 6 % de AMG y el 11 % de Élite no tienen vehículo actual). Para una campaña de recuperación completa conviene filtrar *n_vehiculos_actuales = 0* en toda la base.

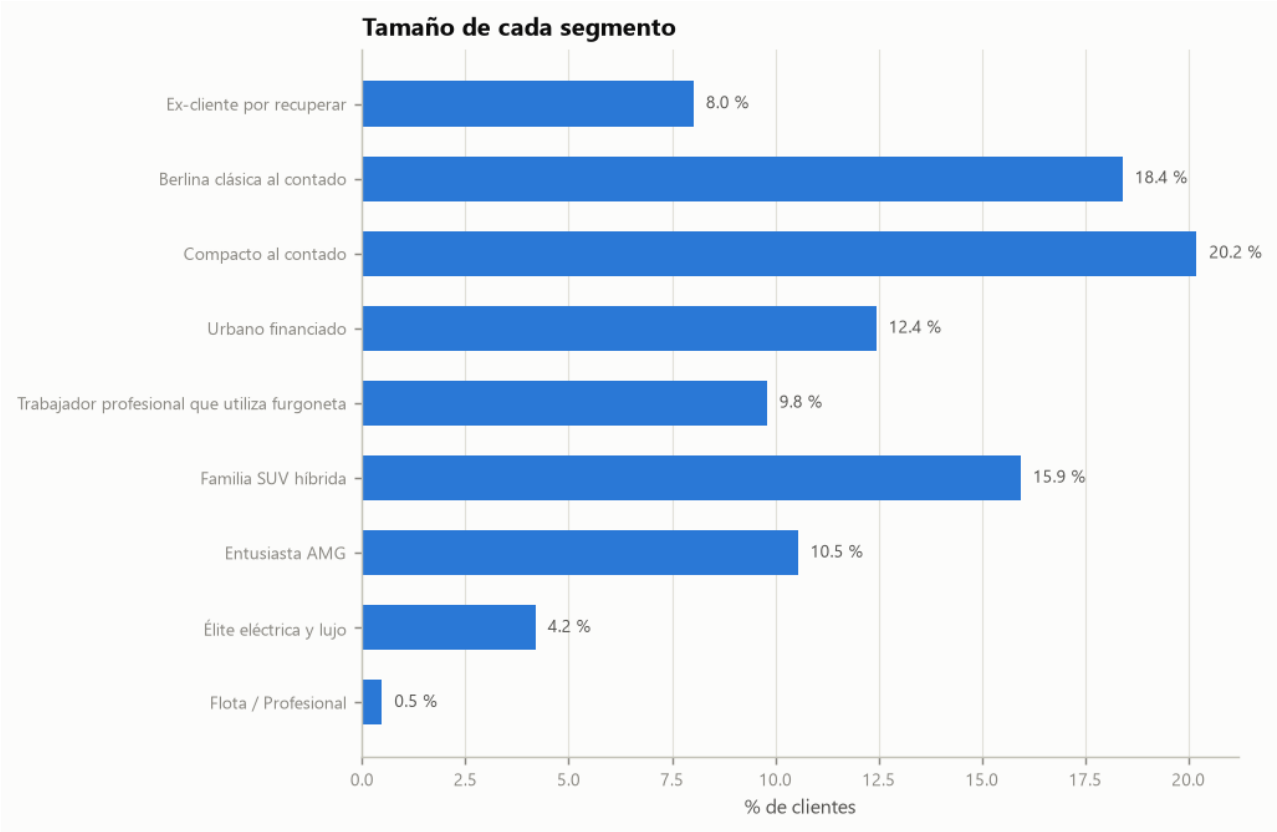


Figura 4.1. Tamaño de cada segmento

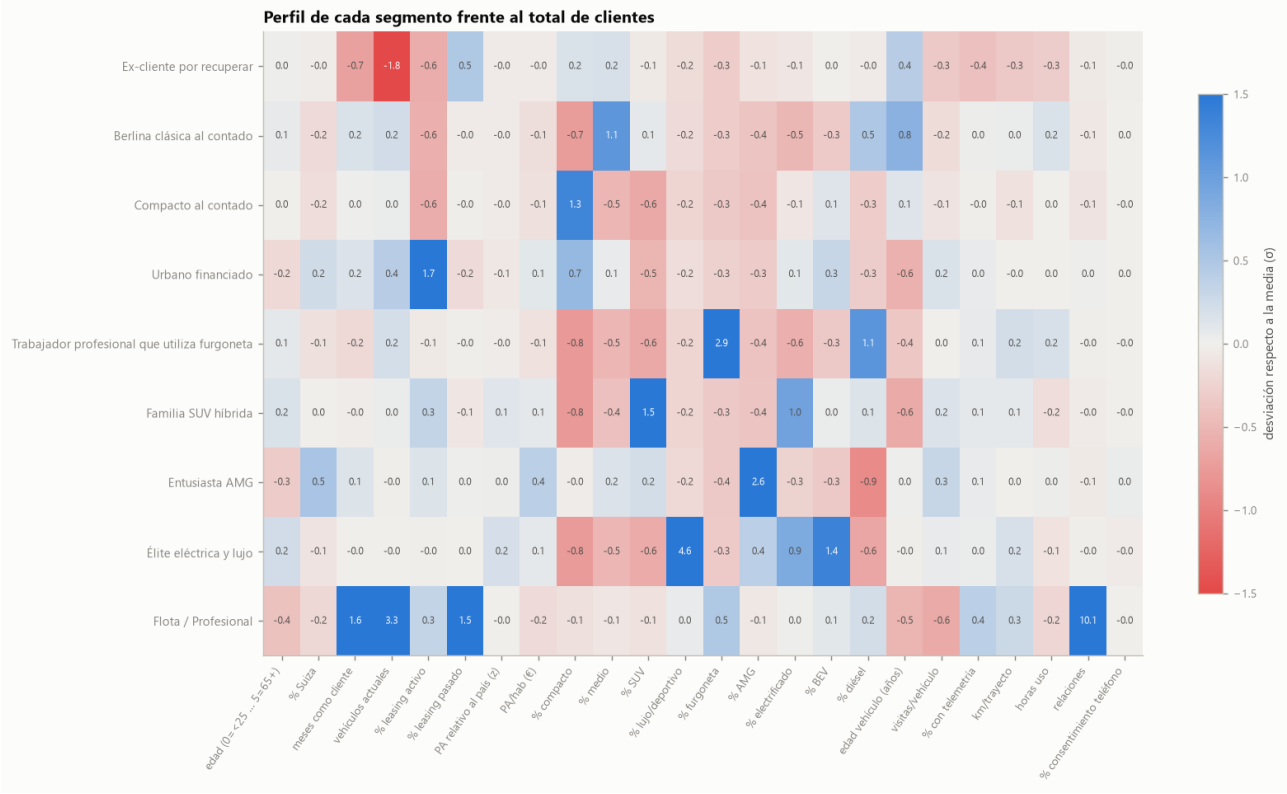


Figura 4.2. Perfil de cada segmento frente al total (σ)



Figura 4.3. Composición de cada segmento (%)

5. Avanzado 1: comparativa de algoritmos

Mismo k = 8 y mismos datos; métricas sobre una muestra común de 15.000 clientes.

Algoritmo	silhouette	Davies-Bouldin	ARI vs K-Means	NMI vs K-Means
K-Means	0.163	1.740	1.00	1.00
Aglomerativo (Ward)	0.155	1.764	0.53	0.70
Gaussian Mixture	0.151	2.449	0.47	0.61
MiniBatch K-Means	0.145	2.109	0.49	0.61
Birch	0.122	2.207	0.38	0.60

Furgonetas, élite eléctrica/lujo y Familia SUV se reproducen en GMM y Ward con un 88–97 % de coincidencia; Ward también reproduce ex-clientes y AMG. GMM y Ward fusionan Berlina clásica y Compacto al contado. DBSCAN no encaja (mucho ruido o un único clúster). **Recomendación: mantener K-Means.**

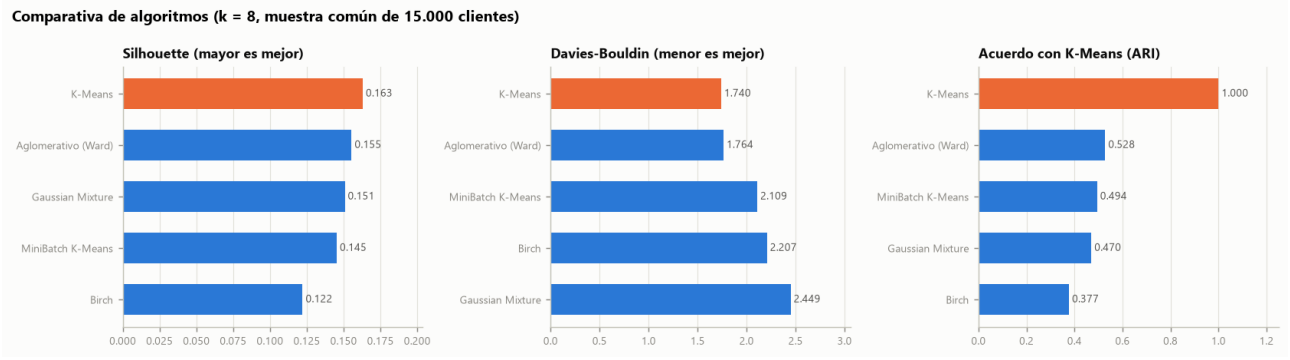


Figura 5.1. Comparativa de métricas

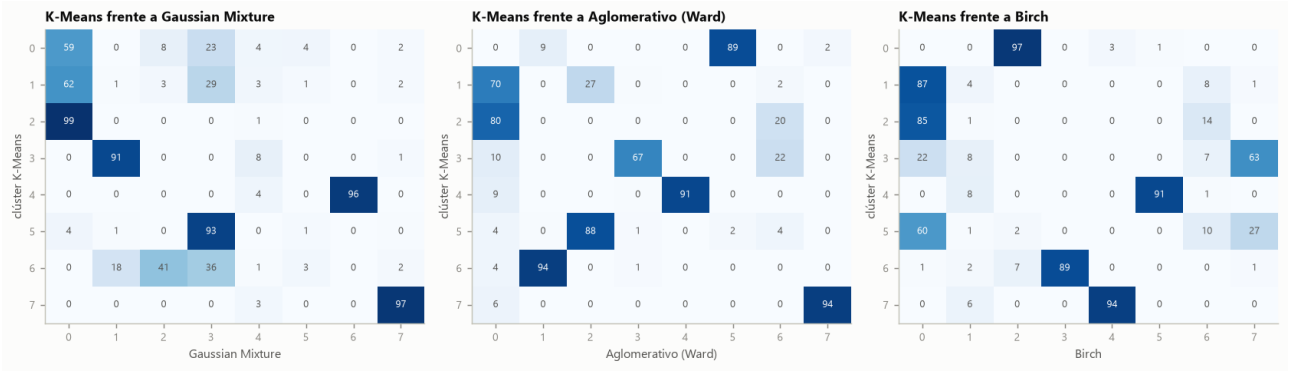


Figura 5.2. Contingencias frente a K-Means

6. Avanzado 2: PCA

Hacen falta 8 componentes para explicar el 80 % de la varianza (PC1 + PC2 = 27 %). En 2D solo los ex-clientes forman un grupo aislado; el silhouette cae de 0,162 (13 dimensiones) a −0,041 (2D). La segmentación es válida en el espacio completo, pero un gráfico 2D no la resume bien.

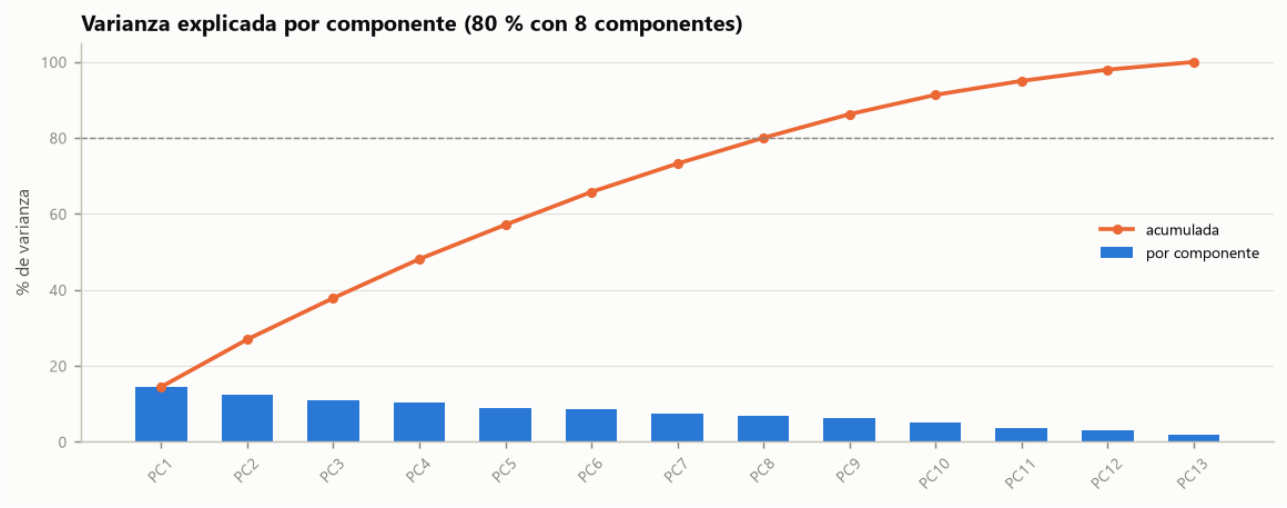


Figura 6.1. Varianza explicada

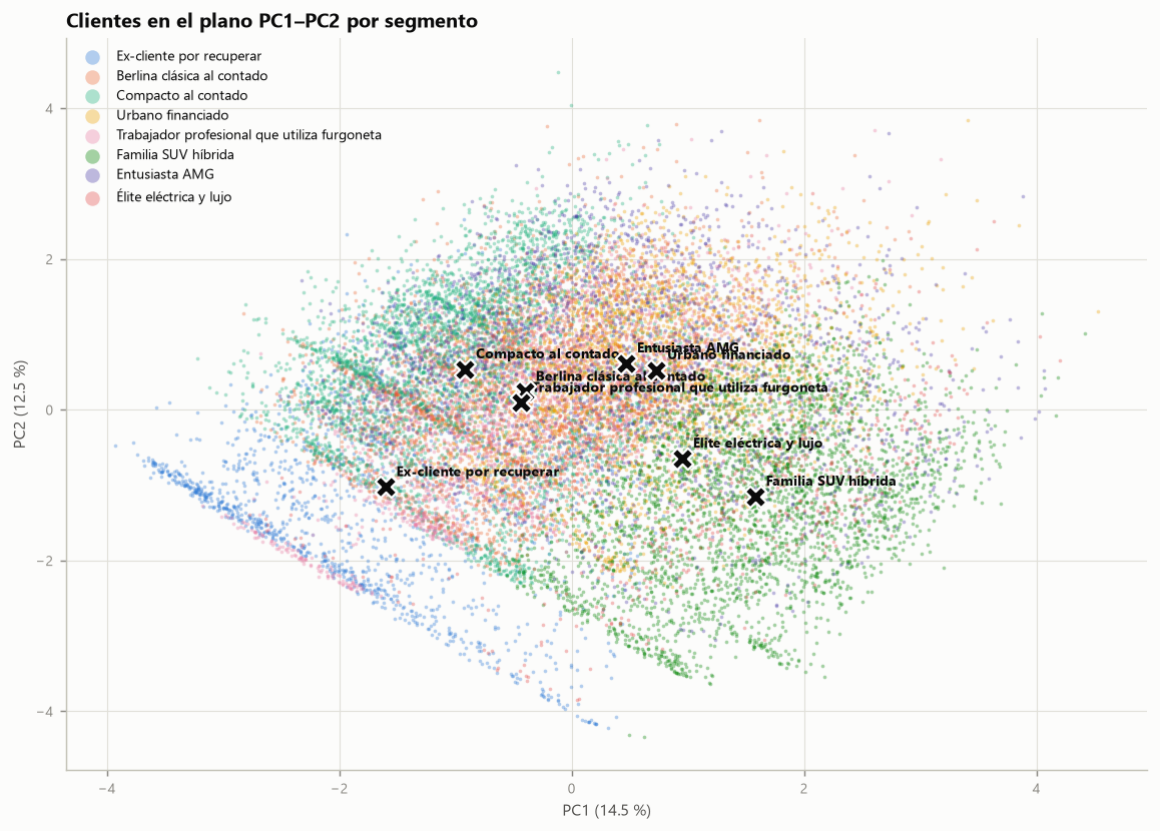


Figura 6.2. Clientes en el plano PC1–PC2

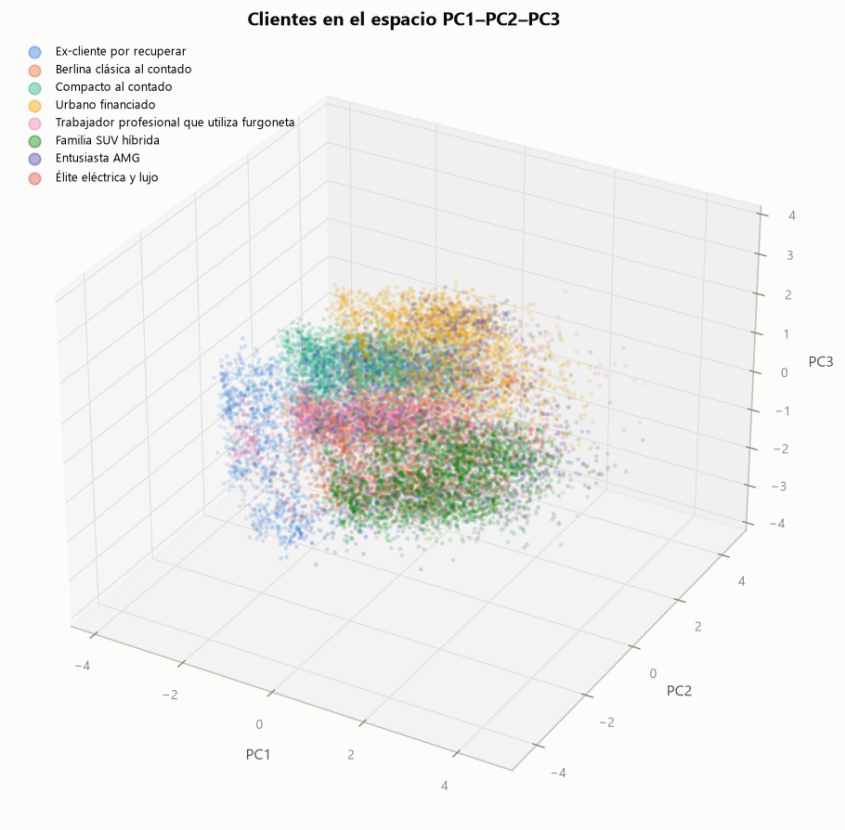


Figura 6.3. Proyección 3D

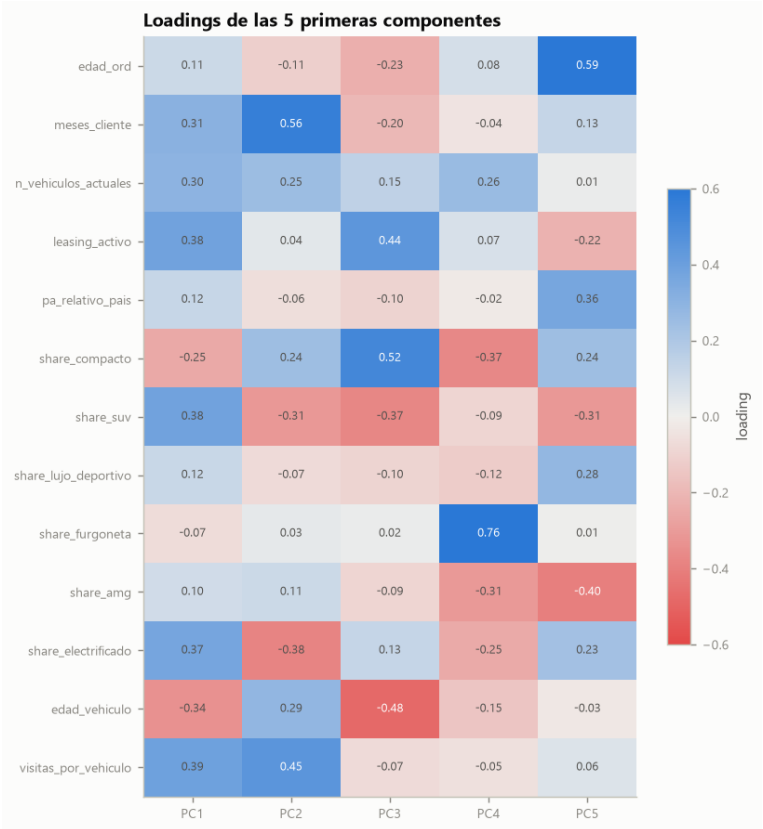


Figura 6.4. Loadings de las componentes

7. Avanzado 3: estabilidad (Jackknife)

20 submuestras excluyendo el 15 % de los clientes. ARI medio 0,691 (mín. 0,452); coincidencia media por cliente 79,4 %.

Segmento	Jaccard medio	Jaccard mín.	% coincidencia	Estabilidad
Berlina clásica al contado	0.531	0.198	60.2	inestable
Compacto al contado	0.539	0.162	61.5	inestable
Ex-cliente por recuperar	0.547	0.108	72.1	inestable
Familia SUV híbrida	0.761	0.551	85.8	estable
Urbano financiado	0.914	0.330	95.2	muy estable
Entusiasta AMG	0.941	0.879	97.9	muy estable
Élite eléctrica y lujo	0.969	0.939	99.4	muy estable
Trabajador profesional que utiliza furgoneta	0.980	0.954	99.6	muy estable

Cinco segmentos (Furgoneta, Élite, AMG, Urbano financiado y Familia SUV) son estables o muy estables y pueden activarse ya. Berlina clásica, Compacto al contado y Ex-cliente son inestables: los clientes que saltan están cerca de la frontera entre centroides. **Recomendación:** usar el margen a la frontera como medida de confianza, fijar semilla y n_init, y repetir el test cada trimestre.

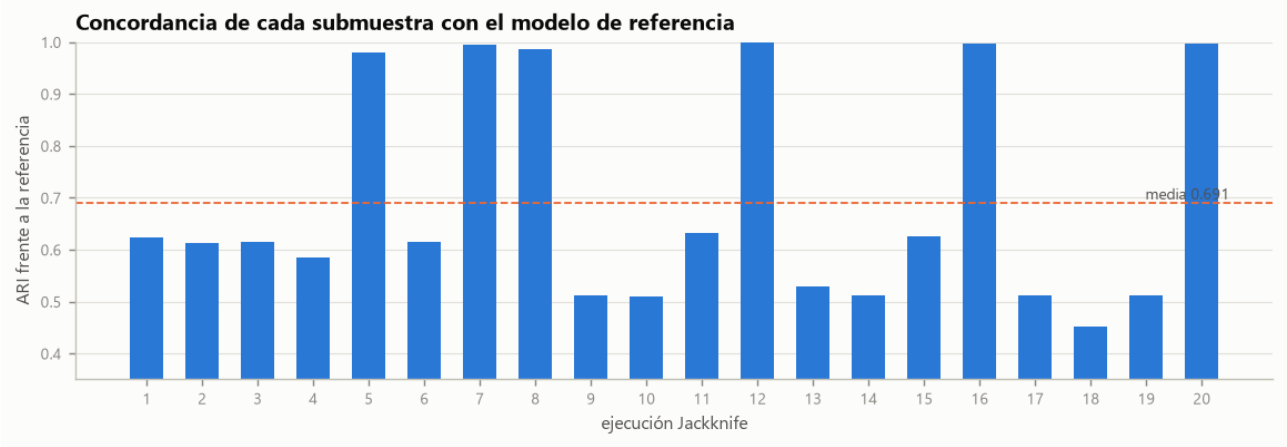


Figura 7.1. ARI de cada submuestra

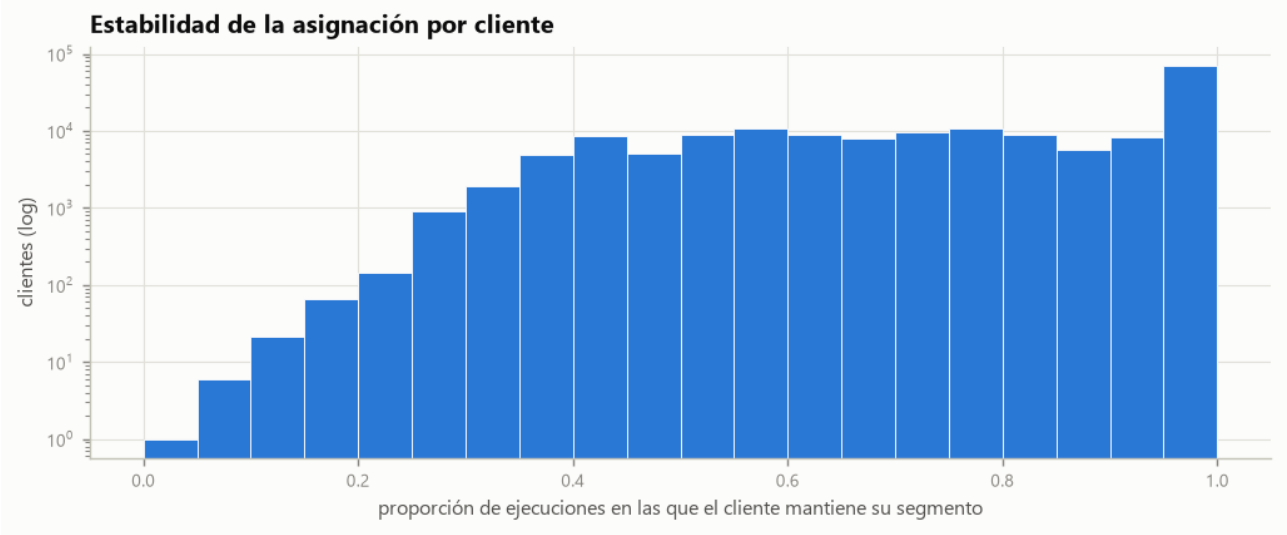


Figura 7.2. Estabilidad por cliente

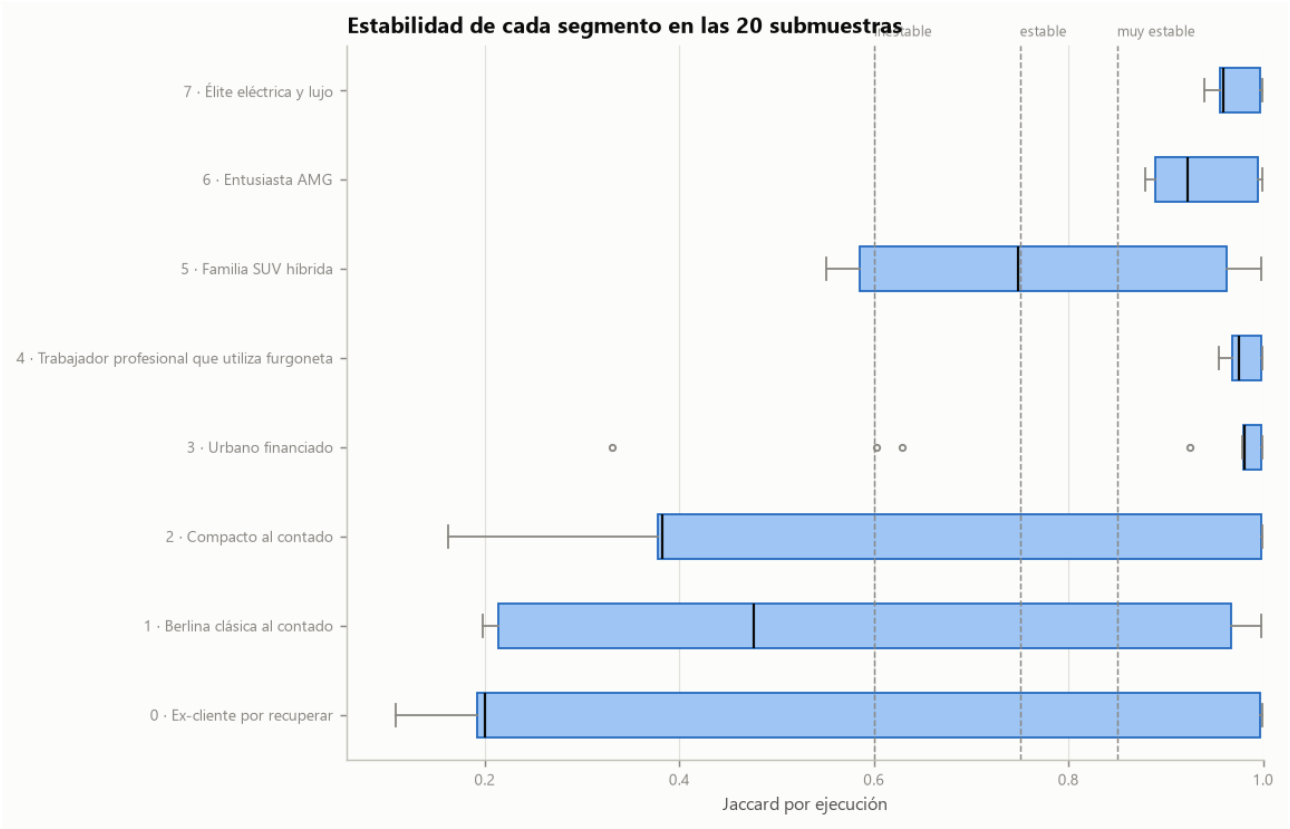


Figura 7.3. Jaccard por segmento

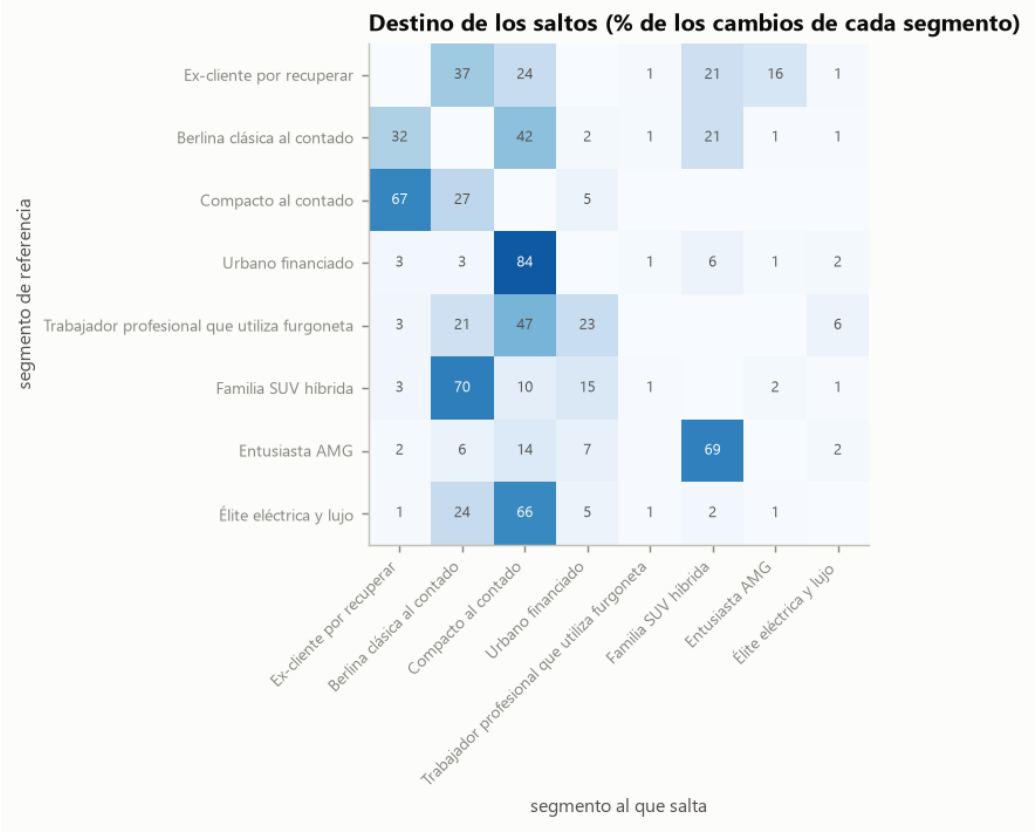


Figura 7.4. Destino de los saltos