Segmentación de clientes Mercedes-Benz

Informe de resultados del proyecto — Malackathon, reto Mercedes-Benz

Segmentación no supervisada (K-Means) de 173.456 clientes de Suiza y Austria para habilitar campañas de ofertas de vehículo, mantenimiento, fidelización y comunicación dirigida.

Resumen ejecutivo

• **Datos:** 302.850 relaciones cliente–vehículo, 173.456 clientes. Tras el tratamiento no queda ningún nulo y las 15 comprobaciones de coherencia dan 0 errores.

• **Features:** 10 variables de modelo (edad, vehículos actuales, leasing, gama de la flota, AMG, electrificación y antigüedad del vehículo), log1p + StandardScaler en un Pipeline. Se eliminó *tiene_vehiculo_actual* por redundante con *n_vehiculos_actuales*, y meses como cliente, PA relativo y visitas al taller pasan a ser solo descriptivas porque desestabilizaban el modelo.

• **Modelo:** K-Means con **k = 7** (silhouette 0,240; Davies-Bouldin 1,42).

• **Segmentos:** 7 segmentos K-Means + 1 segmento Flota/Profesional (833 cuentas excluidas del entrenamiento). Los ex-clientes (~10 %) se tratan con una campaña transversal.

• **Robustez:** K-Means es el mejor de los algoritmos comparados y la segmentación es muy estable: **ARI Jackknife 0,91** y los 7 segmentos con Jaccard ≥ 0,87.

1. EDA y calidad de datos

Cada fila es una relación cliente–vehículo, así que para segmentar se agrega por cliente.

Características principales de los clientes

• Particulares: el 99,4 % son B2C y el 61 % tiene 45 años o más.

• Mayoría en Suiza (66 %); poder adquisitivo de su zona ≈ 1,7 veces el de Austria (51 k€ frente a 30 k€ por habitante).

• Un solo coche conectado en el 81 % de los casos; el 10 % no tiene ningún vehículo actual (ex-clientes).

• Relación de unos 3 años con la marca; el 71 % no ha usado nunca leasing (más habitual en Suiza y entre 35 y 44 años).

• El 81 % acepta teléfono, email y correo postal.

• SUV y compactos premium (GLC, C, A, B/GLA/GLB), 13 % AMG, 14 % furgonetas; antigüedad mediana del coche 4,7 años.

• Electrificación en subida: los eléctricos pasan del 2,5 % de las matriculaciones de 2019 al 37,5 % de las de 2026.

• Uso urbano: trayectos de unos 14 km a unos 49 km/h.

Problemas de calidad y solución

Problema	Solución
Columnas sin valor analítico (índice, IDs, model_class)	Eliminadas; los IDs solo como clave de agregación
Telemetría ausente en el 52 % de las filas	Sin telemetría → 0 + indicador has_telemetry; parcial → mediana/moda de su serie
Motorización nula (44 %) y combustible nulo (59 %)	Reglas por nombre comercial, serie y año (99–100 % de acierto); el resto con la moda
Código postal nulo (5 %) y datos de zona nulos (6 %)	Código postal real del país por cliente; datos de zona del código postal o de la región
Valores imposibles (velocidad < 1 km/h, horas a 0…)	Tratados como nulos; extremos recortados a P1–P99
Género desconocido (17 %)	Categoría unknown
Pico artificial en 36 meses como cliente (12 %)	Se conserva y se marca con un indicador

1.b Tratamiento de nulos: decisiones

Los nulos aparecen **en bloques** (telemetría, motorización, socio-demografía), lo que indica que vienen de las fuentes de datos y no de errores de captura. Se partió de la decisión del equipo (*Descripcion_uso_de_datos*), pero aplicada al pie de la letra generaba incoherencias, así que se corrigió:

Variable	Regla original	Problema detectado	Decisión final
Motorización (engine_concept, 44 % nulo)	Moda (COMBUSTION)	7.114 eléctricos EQ… quedaban como combustión; la combustión subía del 58 % al 77 %	Cascada de reglas por nombre comercial, serie y año (99–100 % de acierto validado sobre datos conocidos). La moda (de su serie y luego global) solo para el resto
Combustible (fuel_type, 59 % nulo)	Derivado del motor por moda	71.283 turismos de gasolina quedaban como diésel	Por nombre comercial: d/CDI/BlueTEC → diésel; furgoneta → diésel; PHEV «de» → diésel-eléctrico; resto → gasolina
Código postal (5 % nulo o mal escrito)	CP aleatorio entre mín. y máx.	El 68 % de los CP generados no existía y un cliente podía recibir CP distintos	CP real del país, sorteado ponderado por nº de clientes y uno por cliente. Formatos «A-»/«CH-» normalizados
Socio-demografía (PA, población, hogares; 6 % nulo)	Media/moda del CP	Rellenos independientes rompían PA total = PA/hab × población	Valor del CP (real o sorteado); si no hay datos, mediana de la región y el resto se recalcula con las identidades
Telemetría (52 % de filas sin datos)	Métricas → 0 y velocidad → moda de la serie	Filas sin telemetría con distancia 0 pero velocidad 50 km/h	Ausencia estructural (MNAR): sin telemetría → todo 0 + flag has_telemetry. Parcial → mediana o moda de su serie; consumo de un eléctrico = 0
Contadores de telemetría	Nulo → 1	Contador 1 con velocidad 0	0 sin telemetría; mediana de la serie si es parcial
Población = 0	—	PA por habitante imputado con población 0	Se trata como CP sin datos (respaldo de región)
Género (17 % desconocido)	→ unknown	Nulo no aleatorio (usuarios secundarios, extremos de edad)	Categoría unknown; solo descriptiva, no entra en el modelo
Fecha de matriculación (1,4 %)	Pendiente	—	Mediana de su serie, con flag (decisión provisional)

Trazabilidad: cada relleno deja un indicador (*has_telemetry, tel_partial, zip_imputed, socio_imputed, engine_imputed, fuel_imputed, reg_date_imputed*) para poder aislar su efecto en el clustering.

Resultado: ningún nulo y 15 comprobaciones de coherencia (por cliente, por vehículo, zona, motor y combustible, telemetría) con 0 errores.

Valores imposibles, anomalías y outliers

Problema	Técnica aplicada
Velocidad media < 1 km/h, horas de uso ≤ 0, contadores a 0 con métricas informadas	Valores imposibles → se tratan como nulos y se rellenan con las reglas de telemetría
Colas extremas en las métricas continuas de telemetría	Winsorización a los percentiles 1 y 99 de los valores observados
Pico artificial en 36 meses como cliente (12 % de clientes, 8 veces más que los meses vecinos)	Se conserva el valor y se marca con months_is_36_spike
Taxonomía de model_class solapada entre épocas y series de 2026 sin clase	Se elimina model_class y la gama se reconstruye desde model_series (17 familias → 6 segmentos comerciales)
833 cuentas con más de 20 relaciones (hasta 561) y solo un 10 % de vehículos actuales	Outliers extremos (concesionarios, rent-a-car, flotas): se apartan del entrenamiento como segmento propio
Variables con colas largas (vehículos actuales, visitas; asimetría > 2)	Tope de 5 vehículos actuales y transformación log1p antes de escalar
Columnas redundantes: PA total y PA/hogar (identidades exactas), población ↔ hogares (ρ = 0,998)	Se usa solo el PA por habitante; el resto queda fuera del modelo
Grano cliente–vehículo (302.850 filas para 173.456 clientes)	Vista agregada por cliente: la cartera son sus vehículos actuales; si no tiene ninguno, todas sus relaciones

Figuras del EDA

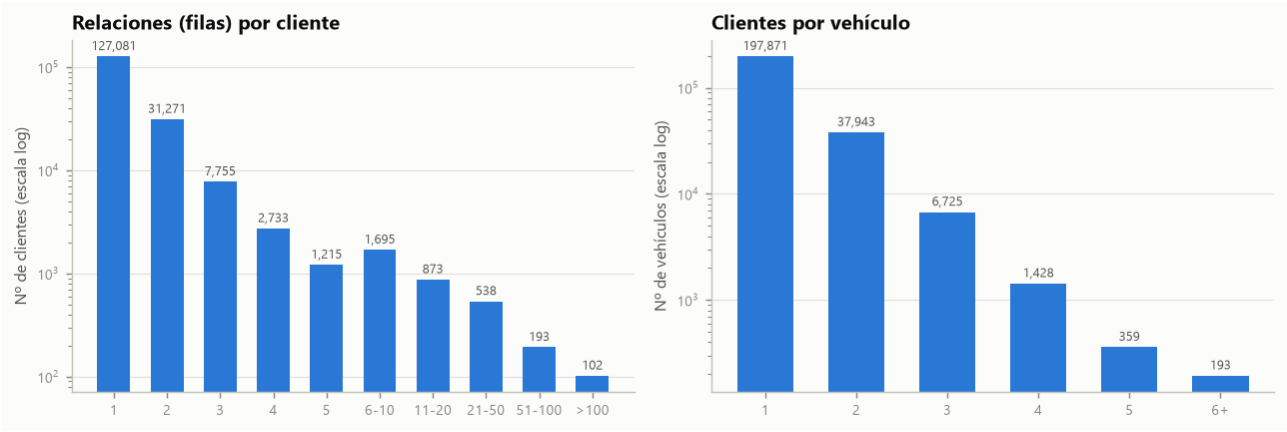


Figura 1.1. Granularidad: relaciones por cliente

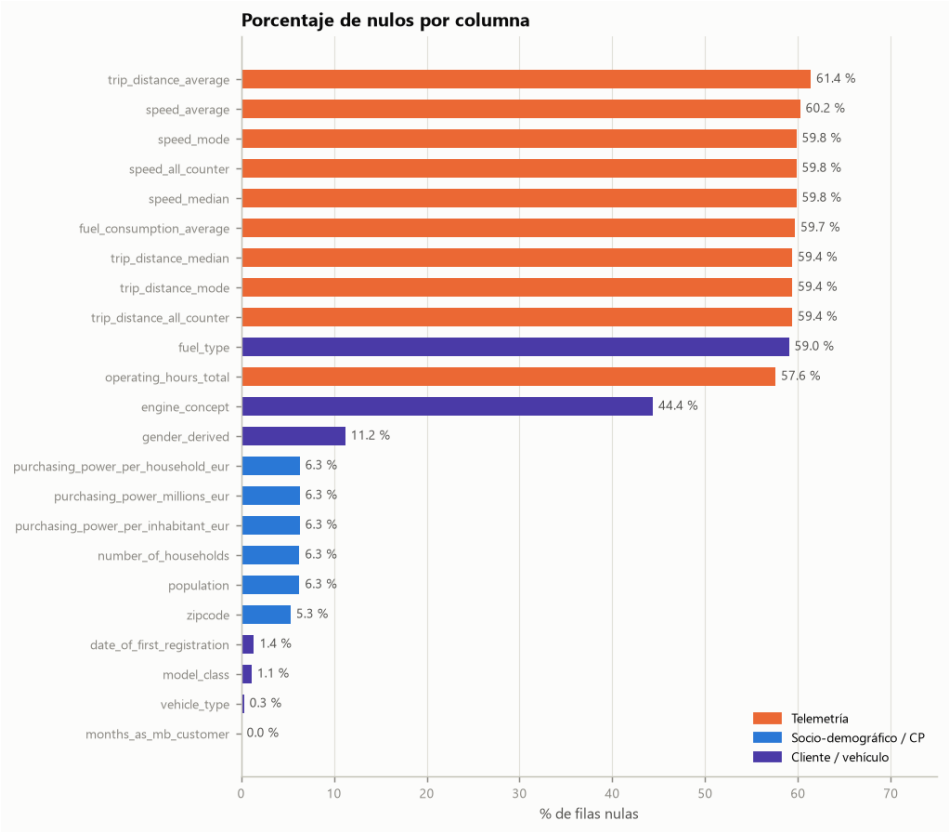


Figura 1.2. Nulos por columna

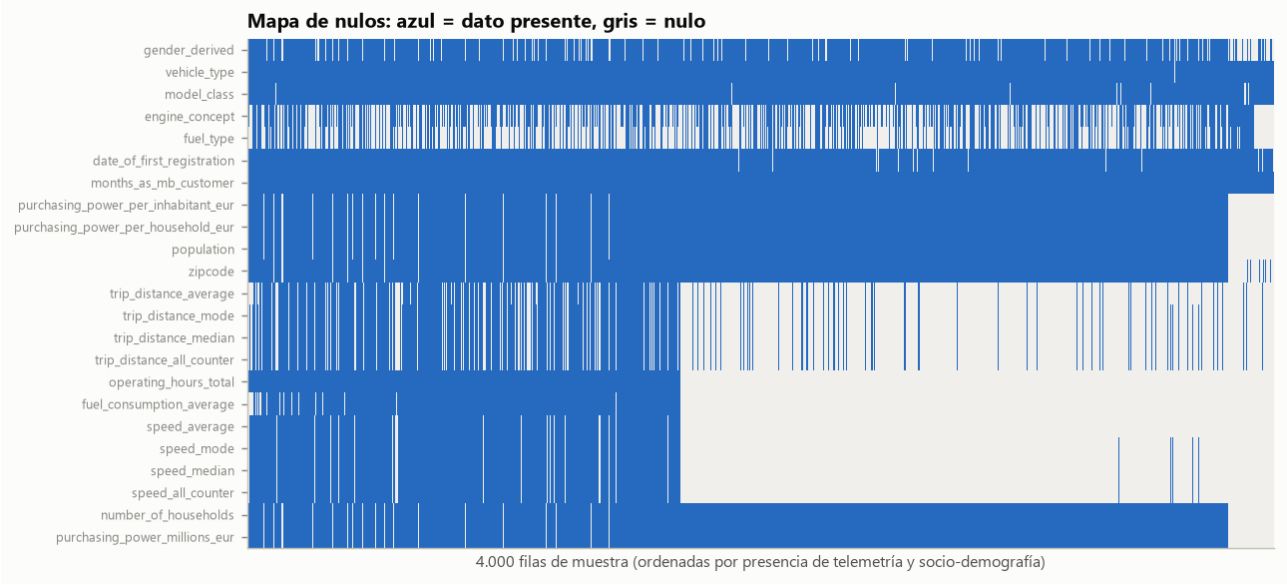


Figura 1.3. Mapa de nulos

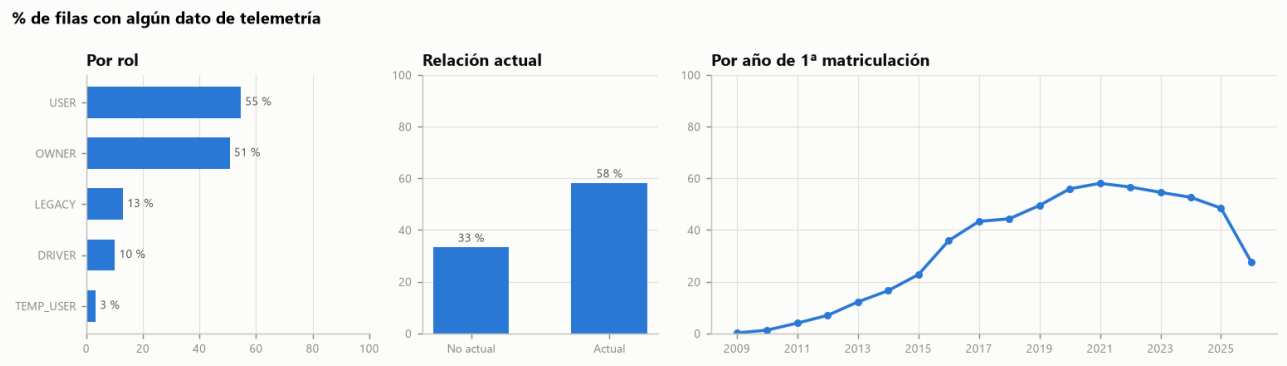


Figura 1.4. Disponibilidad de telemetría

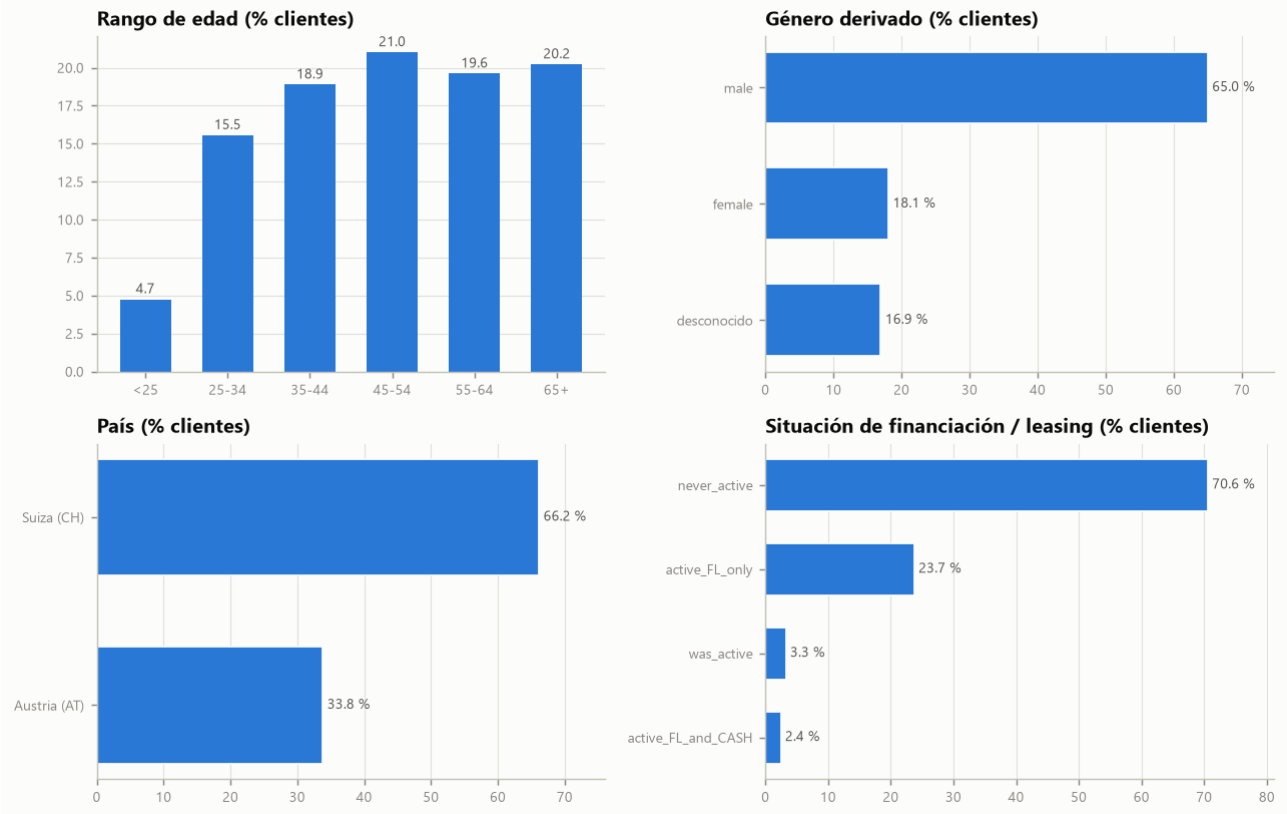


Figura 1.5. Perfil del cliente

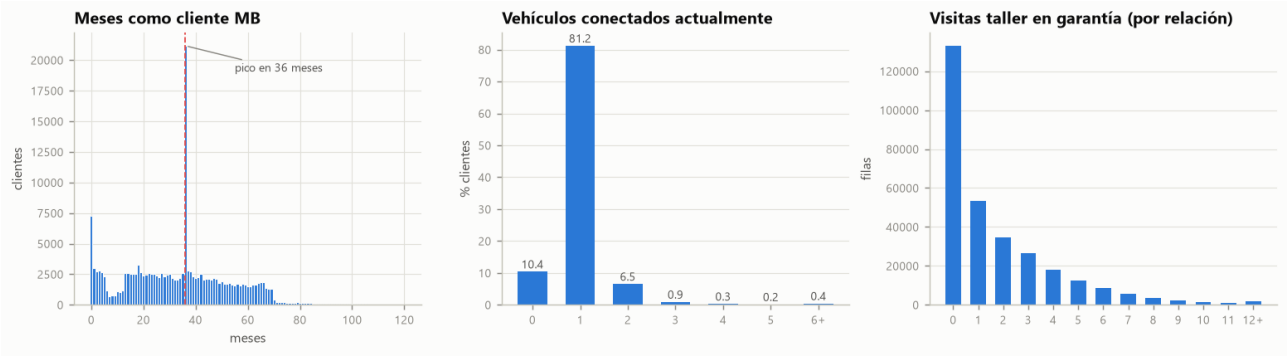


Figura 1.6. Relación con la marca

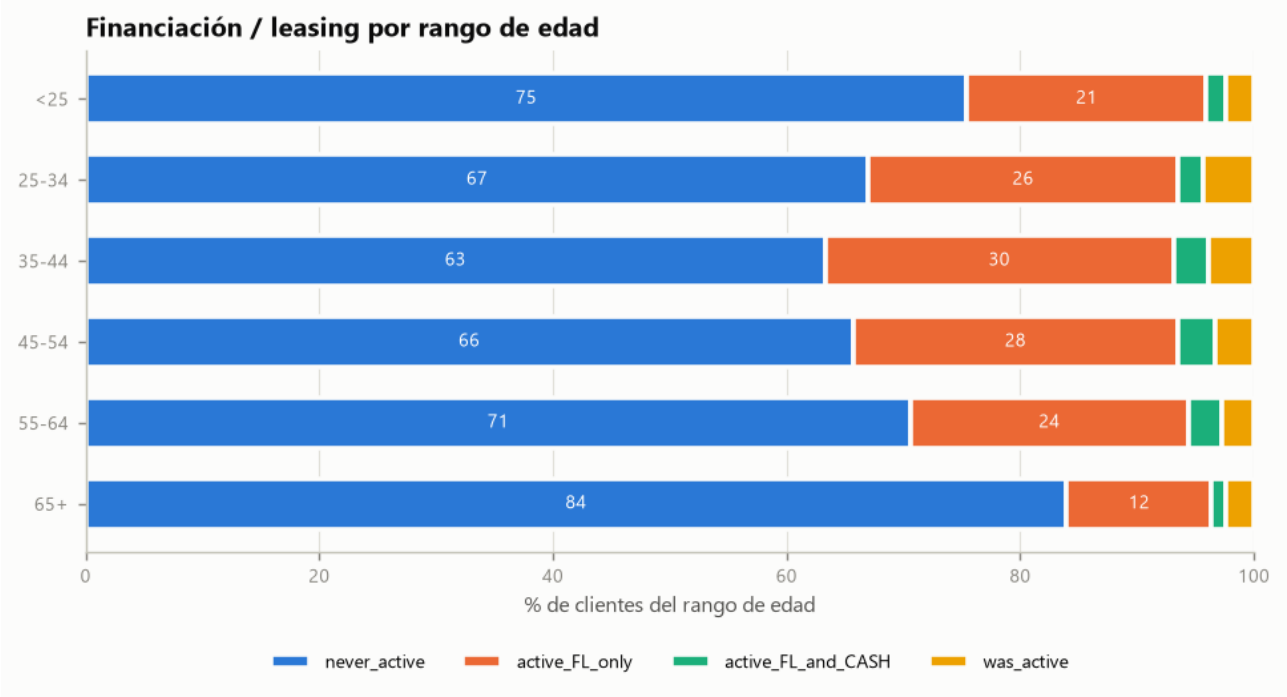


Figura 1.7. Financiación por edad

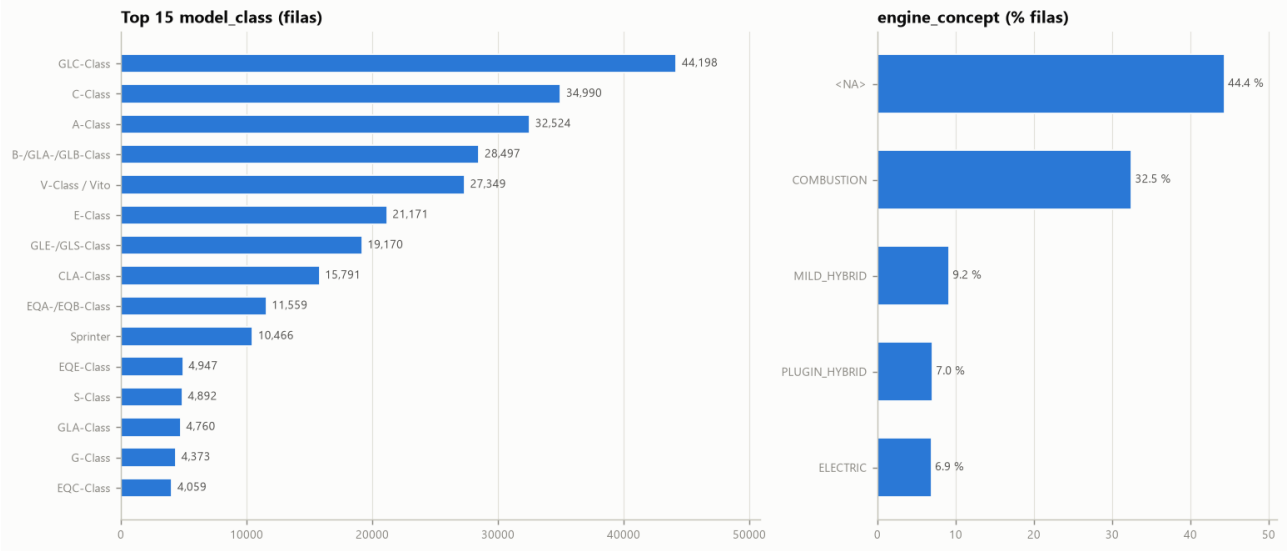


Figura 1.8. Clase de vehículo y motor

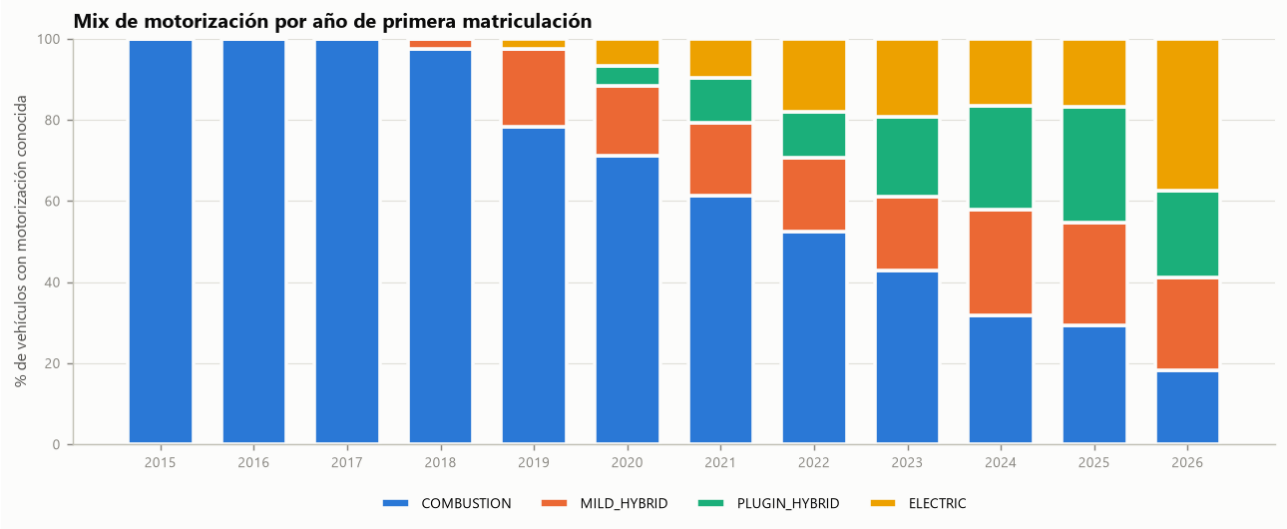


Figura 1.9. Electrificación por año de matriculación

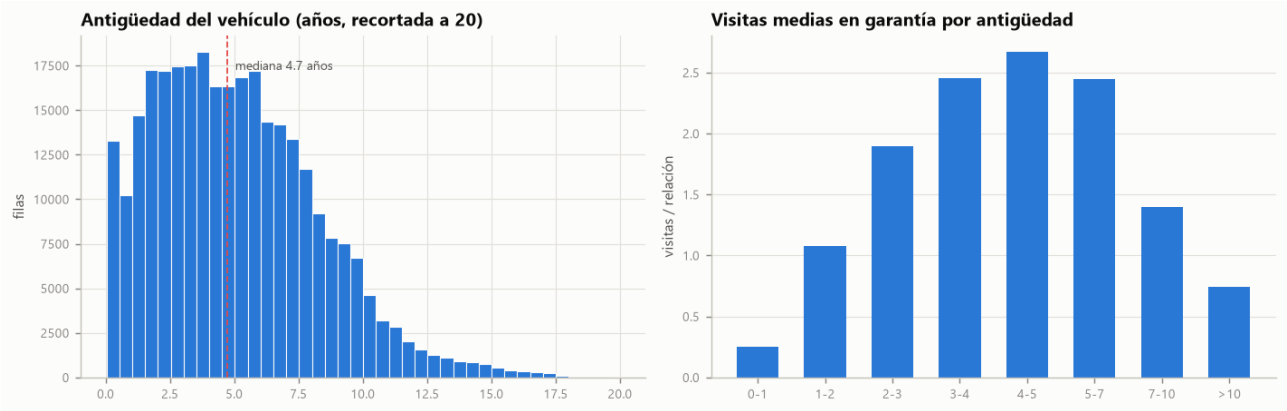


Figura 1.10. Antigüedad y visitas al taller

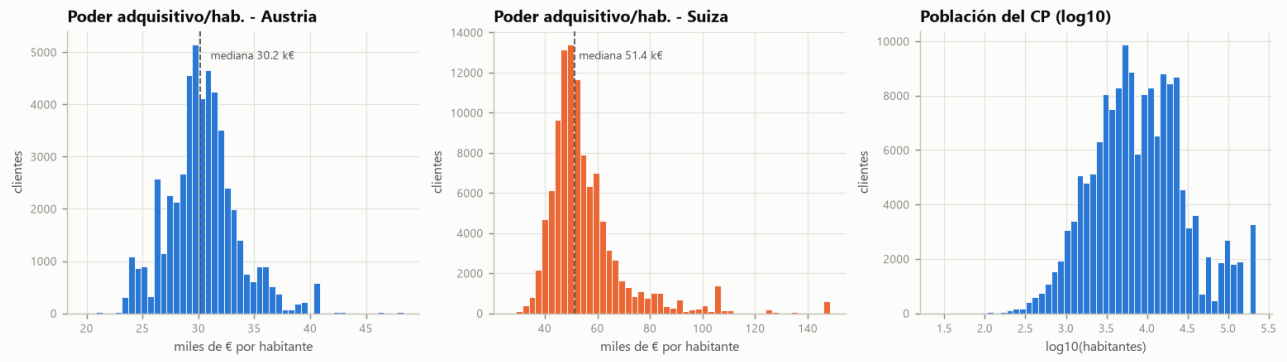


Figura 1.11. Socio-demografía de la zona

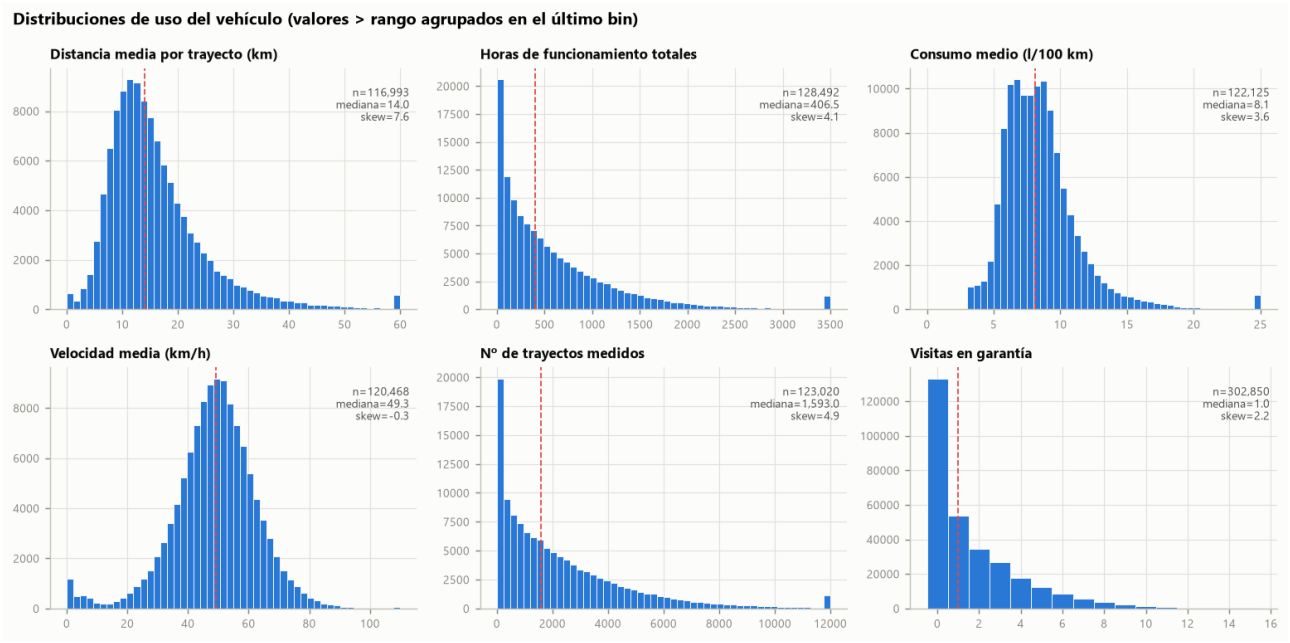


Figura 1.12. Distribuciones de telemetría

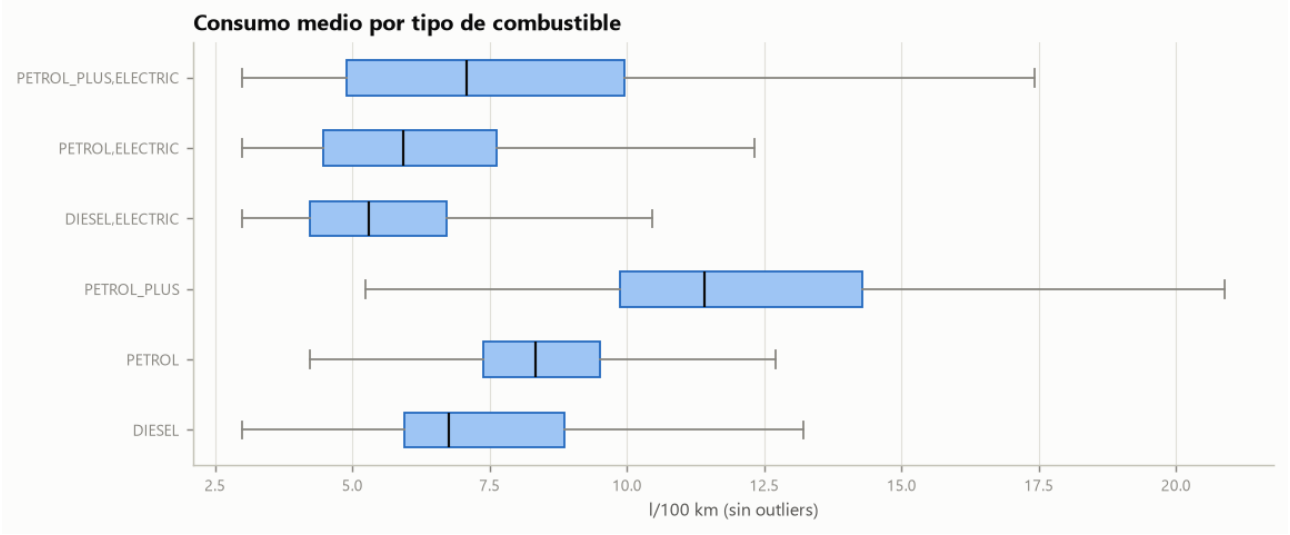


Figura 1.13. Consumo por combustible

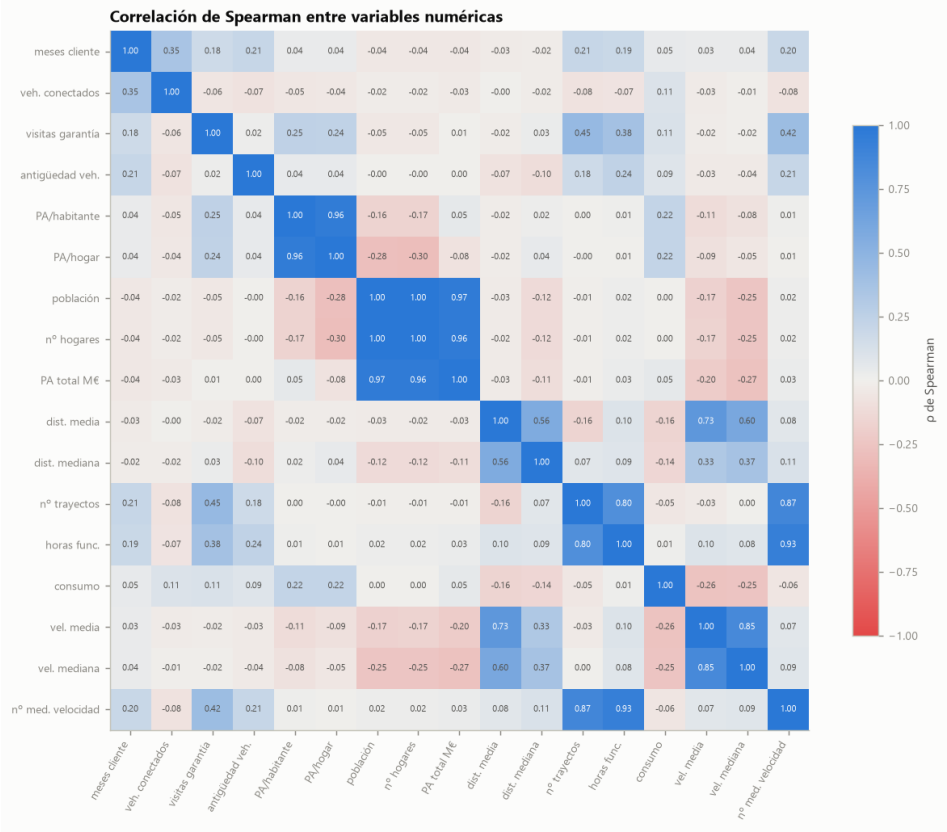


Figura 1.14. Correlación de Spearman

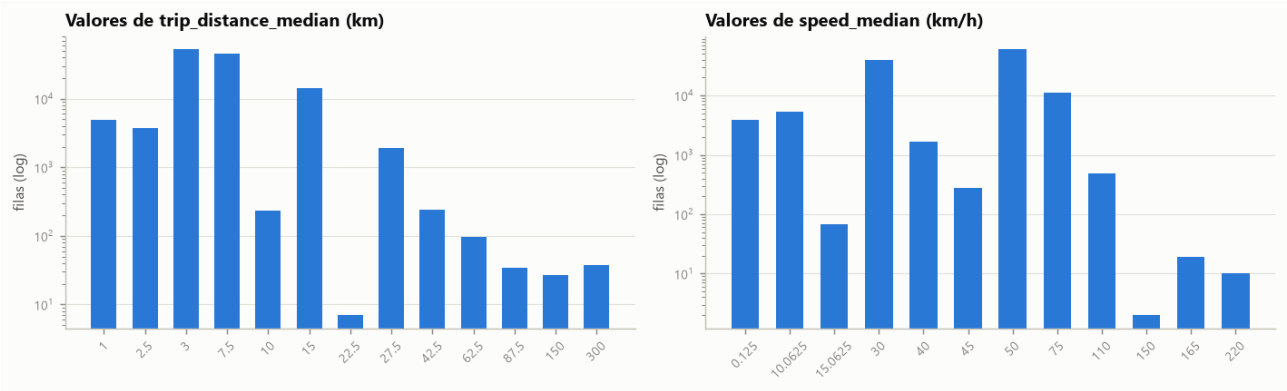


Figura 1.15. Medianas discretizadas

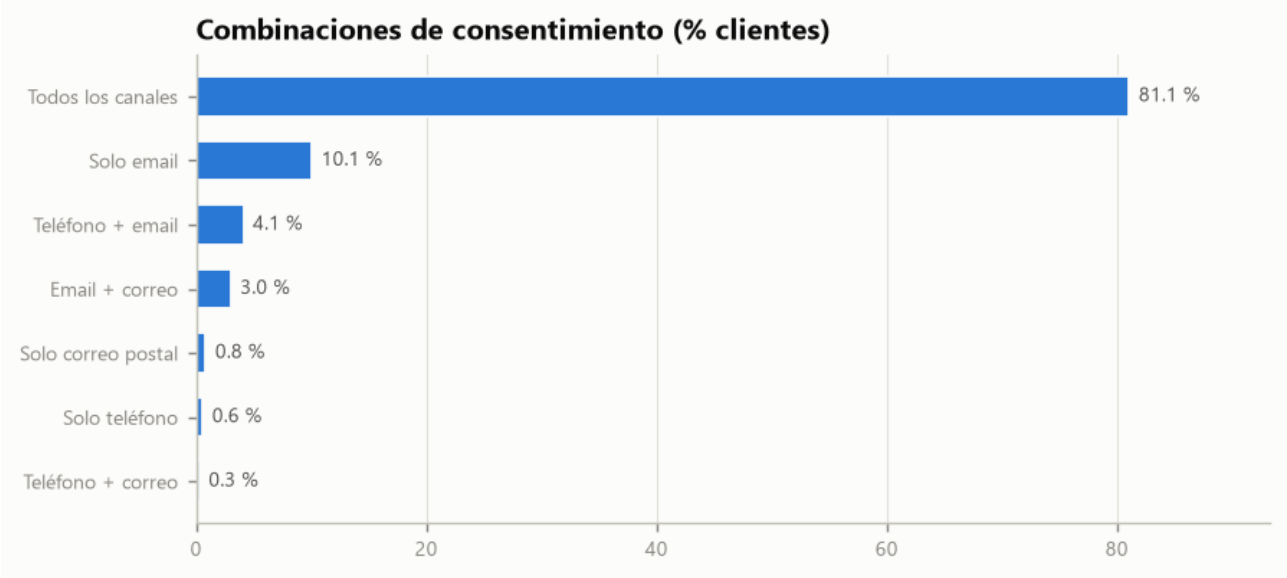


Figura 1.16. Consentimientos de comunicación

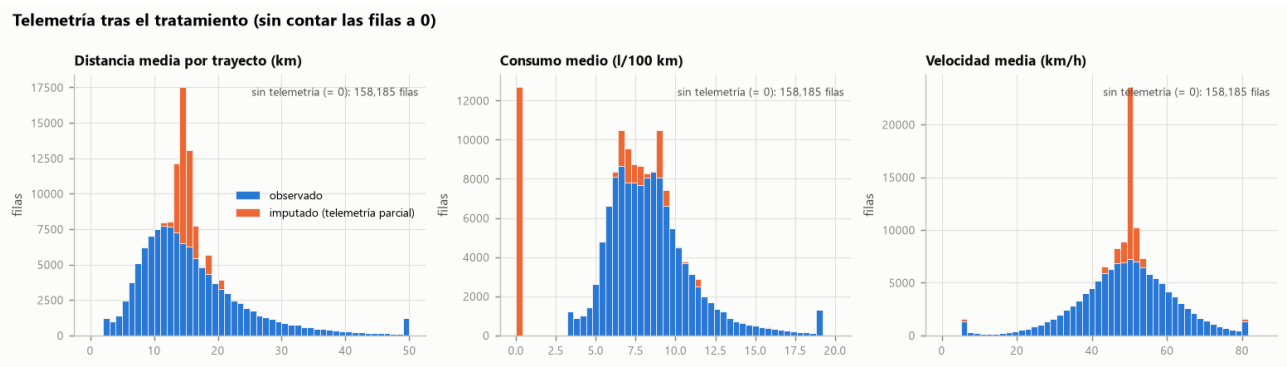


Figura 1.17. Impacto del relleno de telemetría

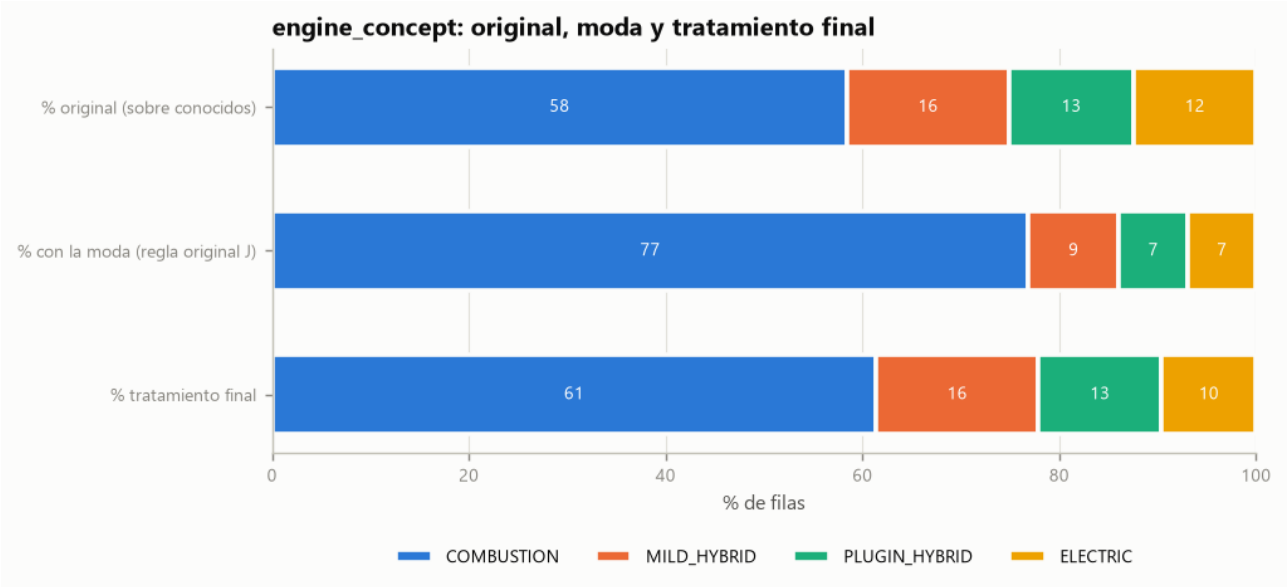


Figura 1.18. Motorización: moda frente a reglas

2. Feature engineering

Las 833 cuentas con más de 20 relaciones (concesionarios, rent-a-car o flotas) se apartan como segmento propio. El resto se segmenta con 10 features; telemetría, país, leasing pasado, meses como cliente, PA relativo y visitas al taller se usan solo para describir.

#	Feature	Por qué se incluye
1	edad_ord	Etapa vital
2	n_vehiculos_actuales	Valor del cliente; con 0 identifica a los ex-clientes
3	leasing_activo	Contrato vivo: renovación
4–7	share_compacto / suv / lujo_deportivo / furgoneta	Gama de la flota
8	share_amg	Altas prestaciones
9	share_electrificado	Transición energética
10	edad_vehiculo	Ciclo de renovación y garantía

Cambios respecto a la versión anterior: se eliminó *tiene_vehiculo_actual*, redundante con *n_vehiculos_actuales* (coinciden en el 99,998 % de los clientes), que duplicaba el peso de esa dimensión. Además, meses como cliente, PA relativo y visitas por vehículo pasan a ser solo descriptivas: son continuas y difusas y emborronaban las fronteras entre segmentos.

Sensibilidad: con esas 13 features el silhouette era 0,16 y el ARI Jackknife 0,69; con las 10 del modelo el silhouette sube a 0,24 y el ARI a 0,91.

Por qué estas variables

Se buscan variables que describan **quién es el cliente, qué relación tiene con la marca y qué conduce**, las palancas de las campañas del reto (ofertas de vehículo, mantenimiento, fidelización y comunicación), y que además formen segmentos **estables**.

Variables que se calculan pero solo describen los segmentos

Variable	Motivo para dejarla fuera del clustering
tiene_telemetria, km_por_trayecto, horas_uso	La telemetría falta de forma estructural en el 41 % de los clientes; con ella, K-Means separaba «con datos» de «sin datos» en vez de perfiles
es_suiza	Binaria de mucho peso que partía todos los segmentos por mercado; la riqueza ya entra de forma relativa y el país se usa para activar las campañas
leasing_pasado	Solo afecta al 3 % y añadía ruido
meses_cliente, pa_relativo_pais, visitas_por_vehiculo	Continuas y difusas: emborronaban las fronteras entre segmentos (ARI Jackknife 0,69 con ellas frente a 0,91 sin ellas)

Variables excluidas a propósito

Variable	Motivo
client_id, vehicle_id, zipcode	Identificadores sin significado métrico (los IDs solo como clave de agregación)
gender_derived	Dato inferido, no declarado: riesgo ético y legal (RGPD / nLPD). Solo descriptivo
Consentimientos (3)	Casi constantes (el 81 % acepta todo): no segmentan. Se usan para elegir el canal
PA por hogar, PA total, población, hogares	Redundantes con el PA por habitante ($\rho \geq 0{,}96$) o miden el tamaño de la zona
speed_average, fuel_consumption_average	$\rho = 0{,}73$ con km por trayecto; el consumo depende del motor
share_mhev, share_combustion, share_diesel, share_4matic	Redundantes con la electrificación y la gama, o poco relevantes
tiene_vehiculo_actual	Redundante con n_vehiculos_actuales (coinciden en el 99,998 %); duplicaba el peso de esa dimensión

Variable	Motivo
n_relaciones, n_relaciones_historicas, n_vehiculos_distintos	Muy correlacionadas con los vehículos actuales y dominadas por outliers
share_owner, rol_principal, is_b2b	El 99 % son propietarios B2C: casi constantes tras excluir las flotas
Flags de imputación	Son de control de calidad, no de negocio

Features derivadas, codificación y transformaciones

Paso	Técnica
edad_vehiculo (derivada)	Media de (fecha de corte − primera matriculación) sobre los vehículos actuales, en años
share_* de gama y energía (derivadas)	Proporción de la flota en cada segmento comercial, AMG y BEV + PHEV; la categoría «medio» es la referencia y se omite
leasing_activo (derivada)	finance_leasing_status □ {active_*} → 1
Categóricas	age_range ordinal 0–5 (conserva el orden); país y leasing como binarias (one-hot sin columna redundante); familias de modelo como proporciones, no como un código de 17 valores
Nulos en producción	SimpleImputer(median) dentro del pipeline, para datos nuevos
Asimetría	log1p en las variables con asimetría > 2
Escala	StandardScaler en todas: K-Means usa distancias euclídeas y ninguna variable debe pesar por sus unidades
Encapsulado	Todo en un Pipeline de scikit-learn: construcción de features → imputación → log1p → escalado
Control	Sin pares de features casi duplicados (|ρ| > 0,8) tras el pipeline

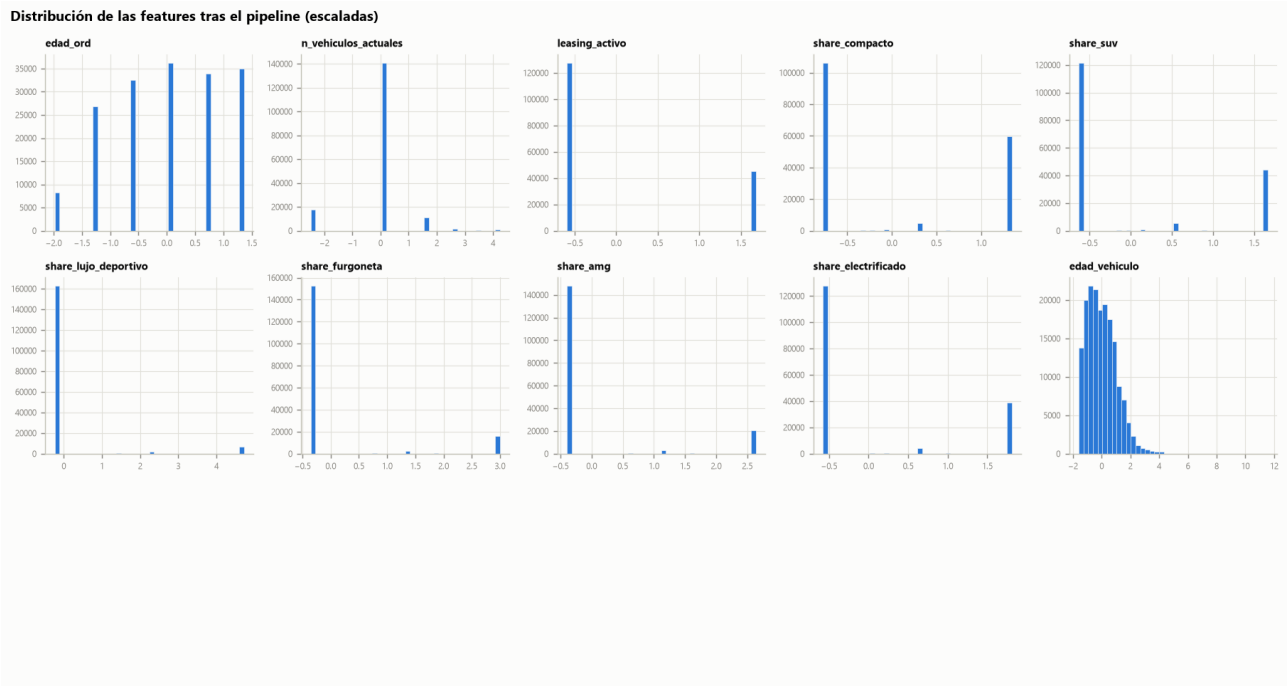


Figura 2.1. Distribución de las features

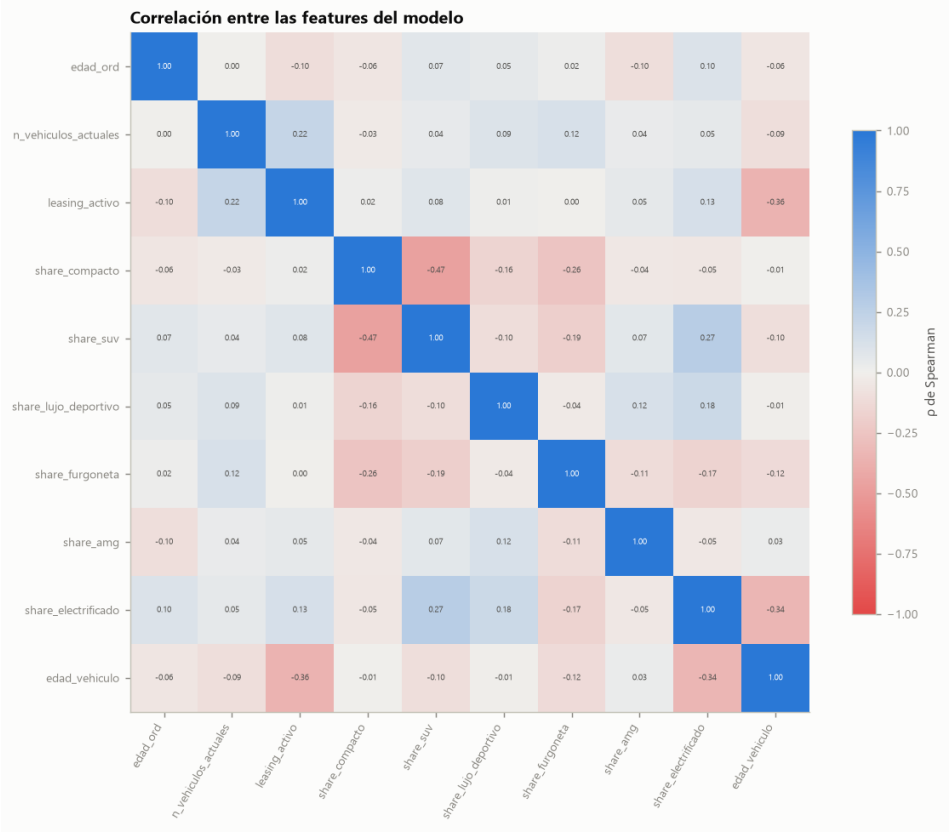


Figura 2.2. Correlación entre features (sin pares |ρ| > 0,8)

3. Modelo K-Means

K-Means para k = 2…10. Criterio: mejor silhouette dentro del rango de negocio (4–8 segmentos, todos ≥ 3 % de los clientes); a menos de 0,01 de silhouette se prefiere el mejor Davies-Bouldin; y estabilidad Jackknife. El candidato por silhouette es k = 8 (0,255), pero **se elige k = 7** (silhouette 0,240, Davies-Bouldin 1,42, clúster más pequeño 4,5 %) porque es mucho más estable.

k	silhouette	Davies-Bouldin	Calinski-Harabasz	clúster mín. %
2	0.179	2.300	3,182	34.1
3	0.223	1.858	3,304	11.0
4	0.219	1.639	3,381	5.1
5	0.224	1.586	3,521	4.9
6	0.238	1.473	3,635	4.8
7	0.240	1.417	3,609	4.5
8	0.255	1.399	3,533	4.4
9	0.259	1.321	3,441	4.1
10	0.249	1.263	3,411	4.2

Estabilidad k = 7 frente a k = 8: ARI Jackknife 0,909 frente a 0,818; con k = 8 dos segmentos son inestables (Jaccard 0,41 y 0,55), con k = 7 todos tienen Jaccard ≥ 0,87.

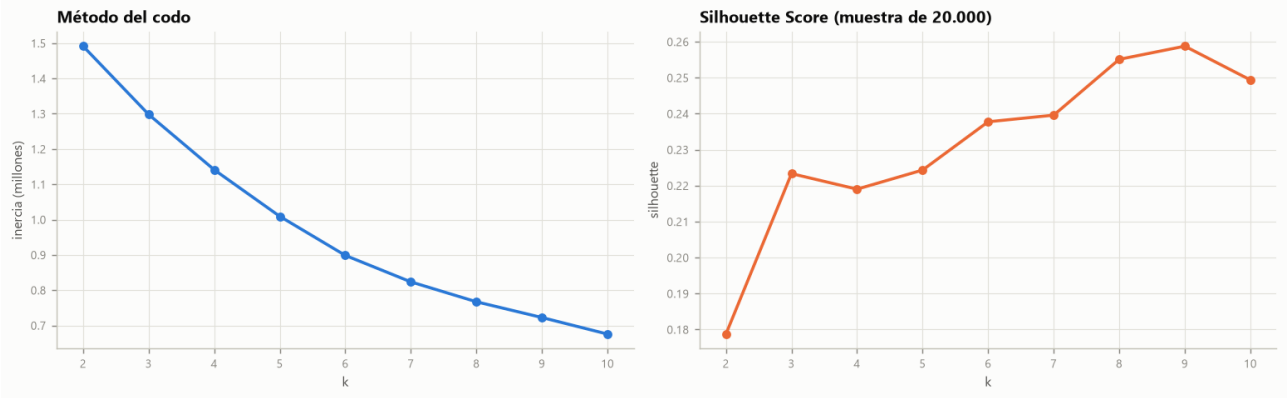


Figura 3.1. Método del codo y silhouette

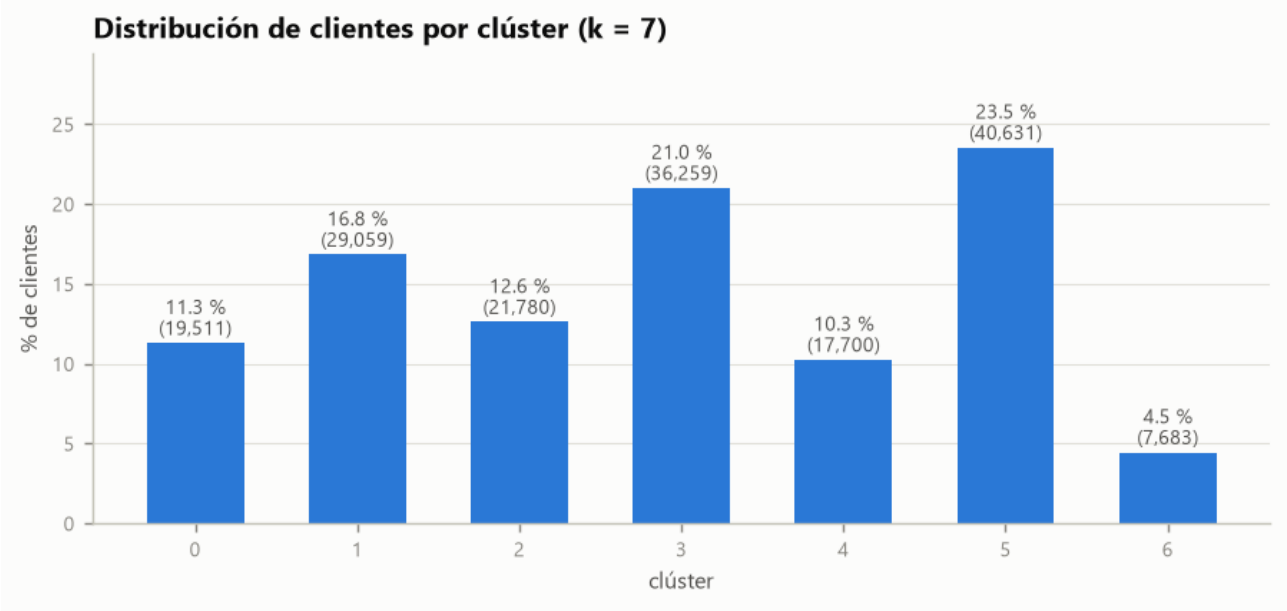


Figura 3.2. Distribución de clientes por clúster

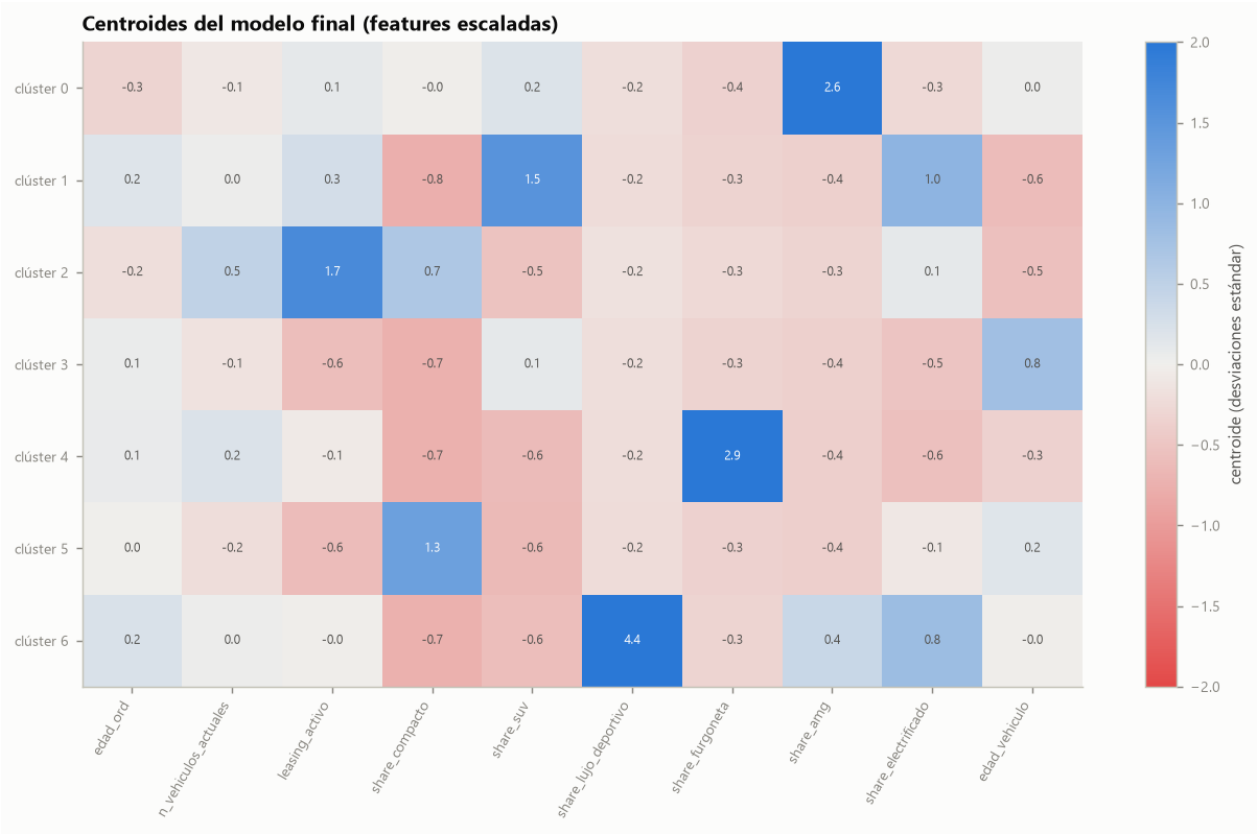


Figura 3.3. Centroides del modelo final (features escaladas)

4. Perfilado de los segmentos

Segmento	%	Quién es	Acción
Compacto al contado	23,4	A, B/GLA/GLB o CLA de ~5 años, sin financiación; 21 % electrificado; más mayores de 65	Renovación a compacto nuevo o EQA/EQB con financiación; mantenimiento al salir de garantía
Berlina clásica al contado	20,9	C/E y algo de GLC, ~7 años (los más antiguos), sin financiación, 3 % electrificado	Mantenimiento y extensión de garantía; renovación financiada con paso a híbrido
Familia SUV híbrida	16,8	GLC/GLE, 65 % electrificado (sobre todo PHEV), 45+ años, 39 % con leasing	Paso a SUV eléctrico, accesorios, mantenimiento de híbridos
Urbano financiado	12,6	100 % leasing, compactos de ~3 años, 19 % BEV, más joven, 77 % Suiza	Renovación anticipada al vencer el contrato, upgrade a EQ, canal digital
Entusiasta AMG	11,2	Flota casi solo AMG; el más joven y el más suizo (91 %); más visitas al taller	Eventos AMG, mantenimiento premium, personalización
Trabajador profesional que utiliza furgoneta	10,2	V-Class, Vito o Sprinter de ~4 años; 35–64 años	Taller prioritario, mantenimiento por km, eVito/eSprinter
Élite eléctrica y lujo	4,4	EQE/EQS, Clase S/Maybach, AMG GT; 49 % BEV; zona más rica; más edad	Gestor dedicado, acceso preferente, recogida y entrega
Flota / Profesional	0,5	833 cuentas con más de 20 relaciones (fuera del K-Means)	Gestión B2B; revisar el rol en el CRM

Campaña transversal de ex-clientes (~10 % de la base): los clientes sin vehículo actual (*n_vehiculos_actuales = 0*) no forman un segmento aparte, sino que se agrupan según la gama de su último coche (del 0 % en Urbano financiado al 15 % en Berlina clásica). Así la campaña de recuperación se personaliza con la oferta de su segmento: ocasión certificada o nuevo leasing del mismo tipo de vehículo.

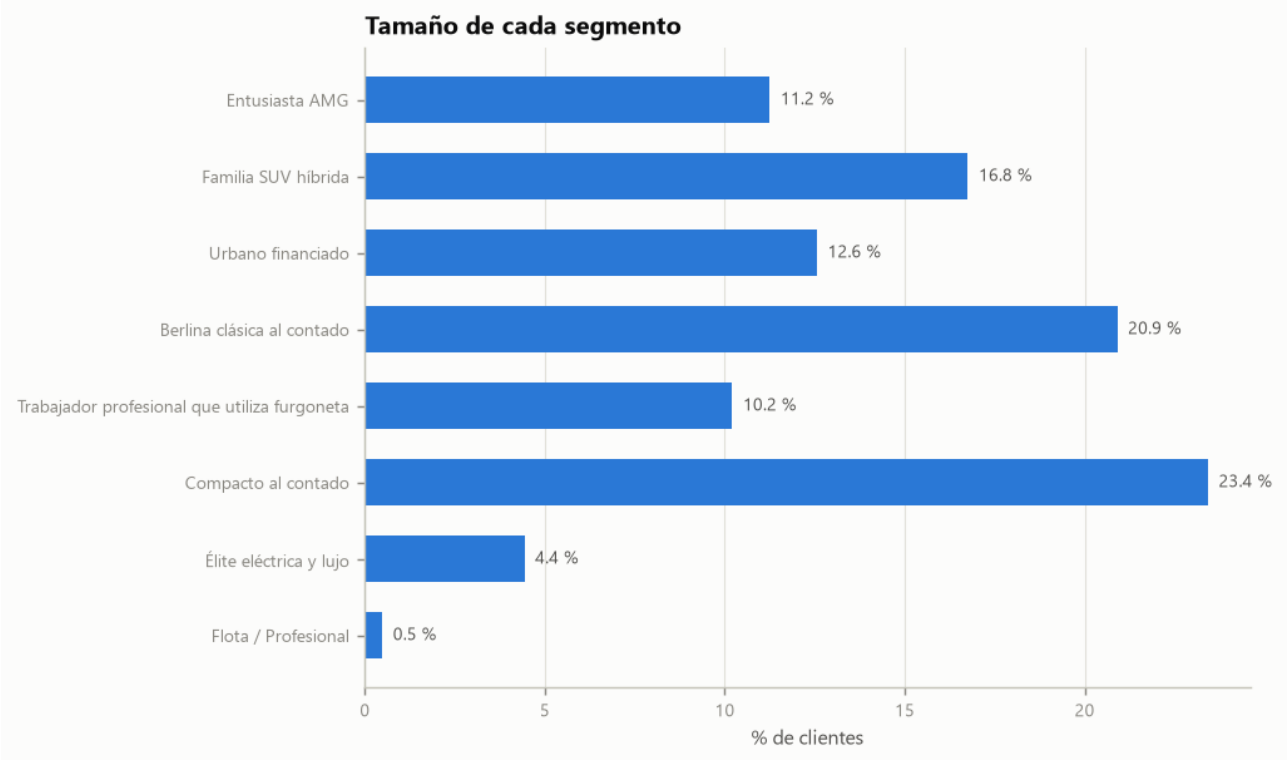


Figura 4.1. Tamaño de cada segmento

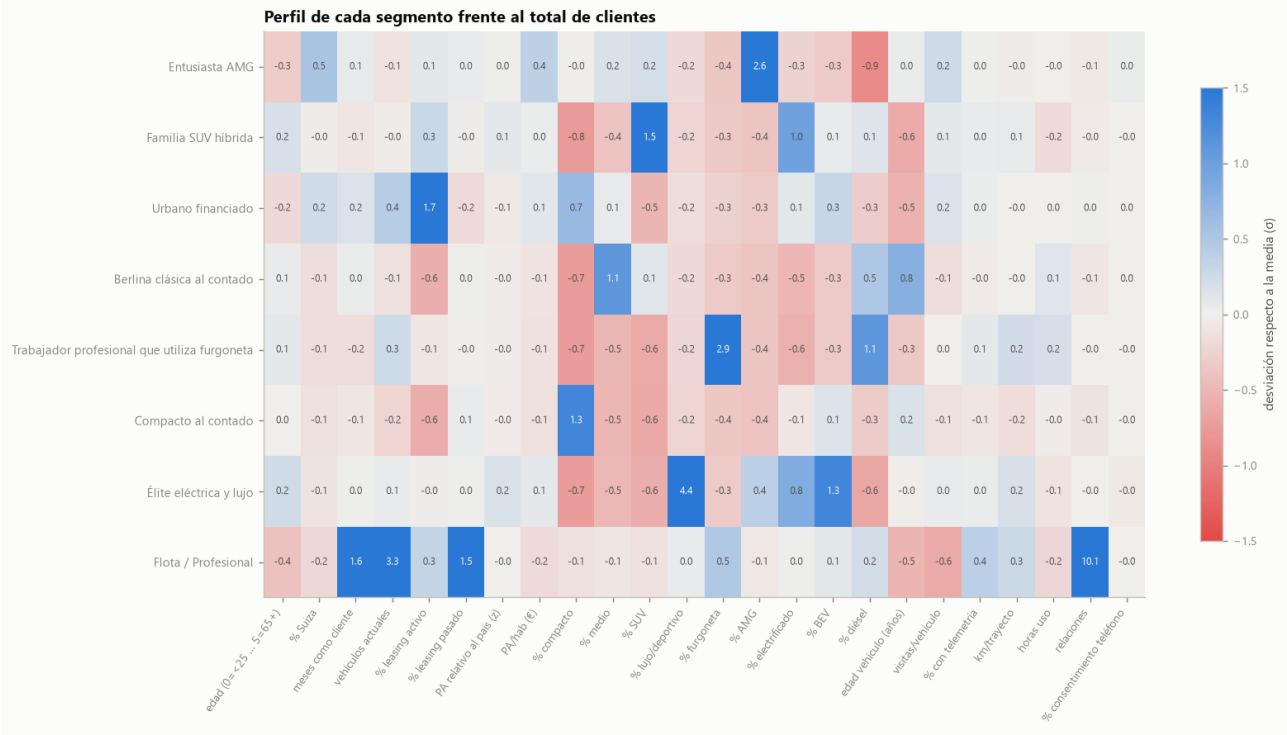


Figura 4.2. Perfil de cada segmento frente al total (σ)



Figura 4.3. Composición de cada segmento (%)

5. Avanzado 1: comparativa de algoritmos

Mismo k = 7 y mismos datos; métricas sobre una muestra común de 15.000 clientes.

Algoritmo	silhouette	Davies-Bouldin	ARI vs K-Means	NMI vs K-Means
K-Means	0.240	1.418	1.00	1.00
MiniBatch K-Means	0.239	1.402	0.73	0.79
Gaussian Mixture	0.221	1.650	0.42	0.57
Aglomerativo (Ward)	0.219	1.536	0.56	0.65
Birch	0.099	2.042	0.26	0.43

Furgonetas y élite eléctrica/lujo se reproducen en GMM y Ward con un 90–100 % de coincidencia, y Ward también reproduce AMG (94 %). Las diferencias se concentran entre Familia SUV, Berlina clásica y Compacto. MiniBatch K-Means es casi igual (silhouette 0,239, ARI 0,73). DBSCAN no encaja (decenas de microclústeres o un único clúster). **Recomendación: mantener K-Means.**

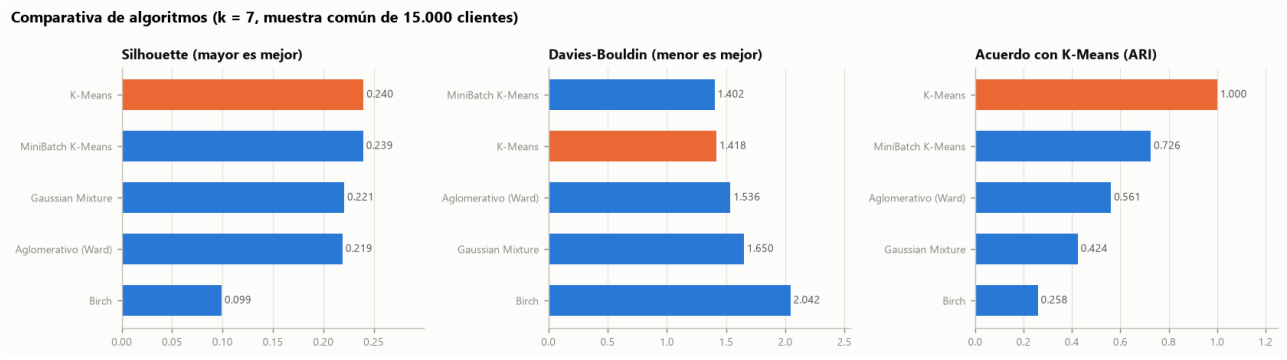


Figura 5.1. Comparativa de métricas

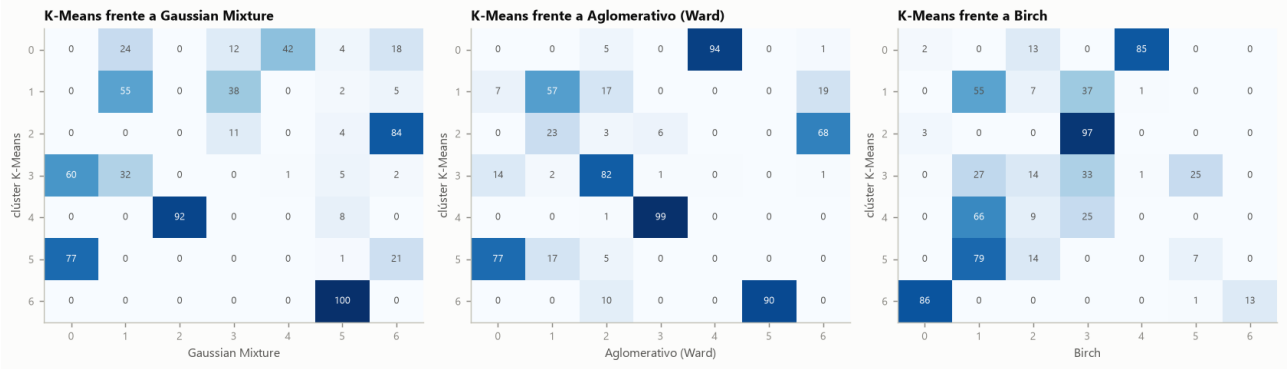


Figura 5.2. Contingencias frente a K-Means

6. Avanzado 2: PCA

Hacen falta 7 componentes para explicar el 80 % de la varianza (PC1 + PC2 = 32 %). En 2D los segmentos se distinguen en parte (silhouette 0,085), pero en 3D conservan casi toda su separación (0,236 frente a 0,239 en el espacio completo). PC1 = SUV electrificado y moderno frente a coche antiguo; PC2 = compacto financiado; PC3 = furgoneta; PC4 = AMG; PC5 = lujo.

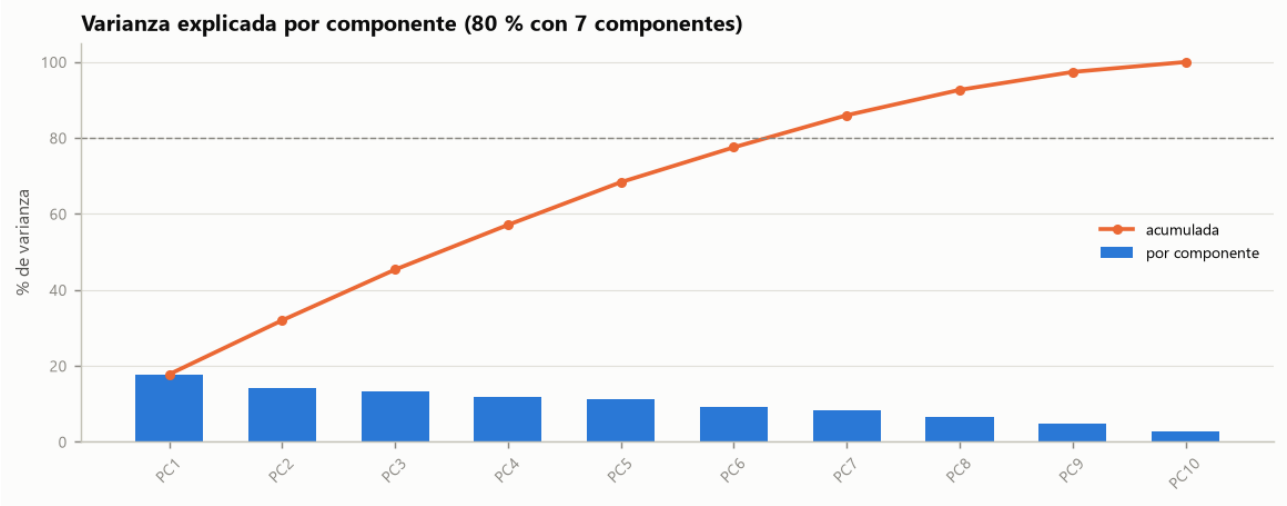


Figura 6.1. Varianza explicada

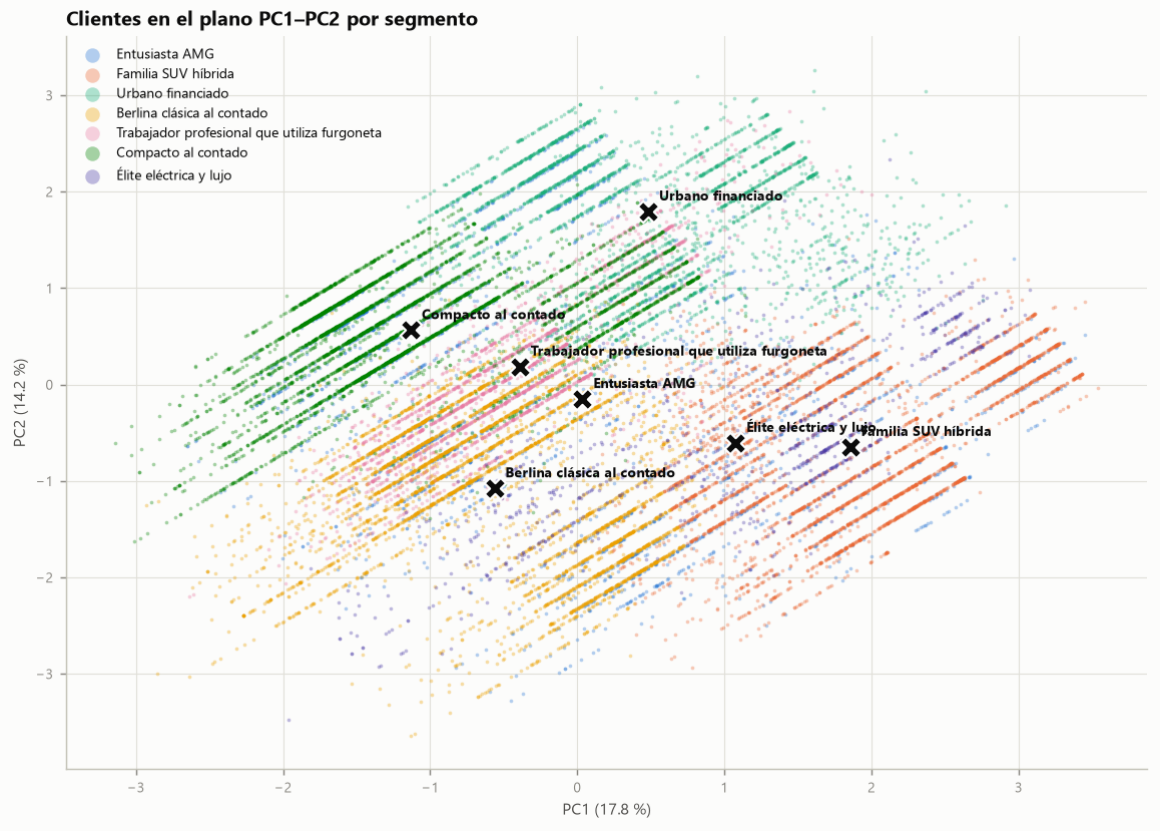


Figura 6.2. Clientes en el plano PC1–PC2

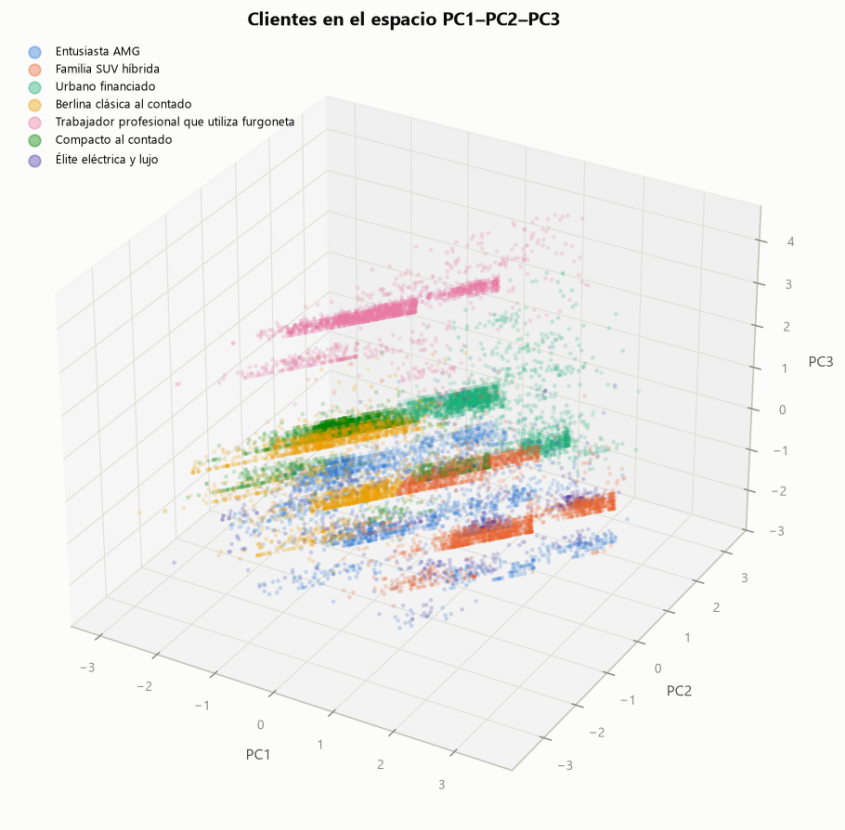


Figura 6.3. Proyección 3D

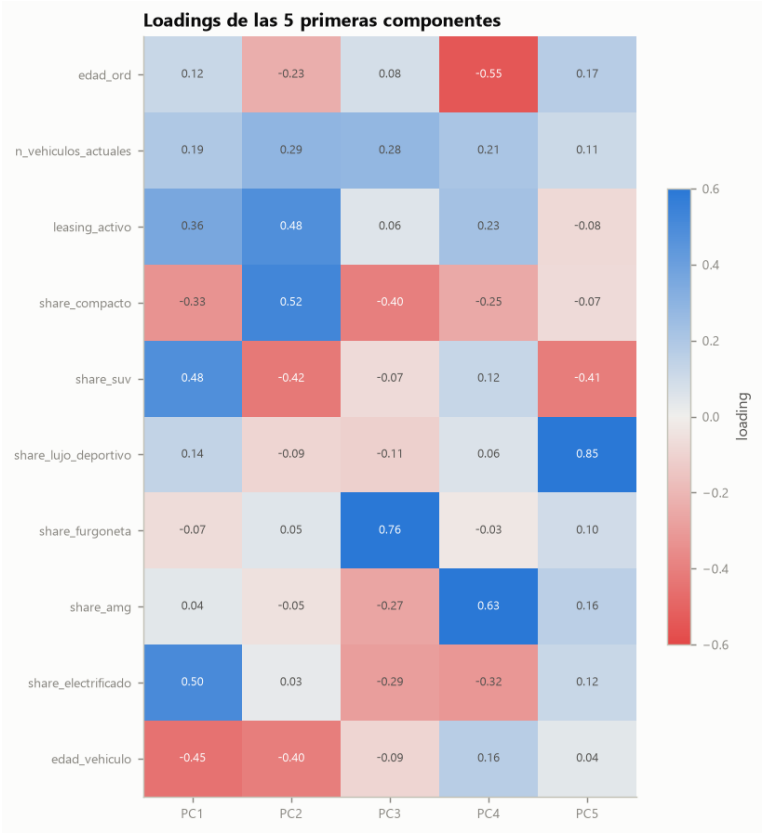


Figura 6.4. Loadings de las componentes

7. Avanzado 3: estabilidad (Jackknife)

20 submuestras excluyendo el 15 % de los clientes. **ARI medio 0,909** (mín. 0,613); coincidencia media por cliente 94,2 %; solo el 6,5 % de los clientes cambia de segmento en más del 20 % de las ejecuciones.

Segmento	Jaccard medio	Jaccard mín.	% coincidencia	Estabilidad
Familia SUV híbrida	0.867	0.609	89.8	muy estable
Urbano financiado	0.874	0.256	96.6	muy estable
Compacto al contado	0.887	0.120	89.4	muy estable
Berlina clásica al contado	0.904	0.413	95.6	muy estable
Entusiasta AMG	0.981	0.925	98.5	muy estable
Élite eléctrica y lujo	0.985	0.928	99.2	muy estable
Trabajador profesional que utiliza furgoneta	0.989	0.942	99.6	muy estable

Los 7 segmentos son muy estables (Jaccard ≥ 0,87) y pueden activarse ya. Los pocos saltos se dan sobre todo de Compacto al contado a Urbano financiado y entre Familia SUV y Berlina clásica: son clientes cerca de la frontera entre centroides. **Recomendación:** usar el margen a la frontera como medida de confianza, fijar semilla y n_init, y repetir el test cada trimestre.

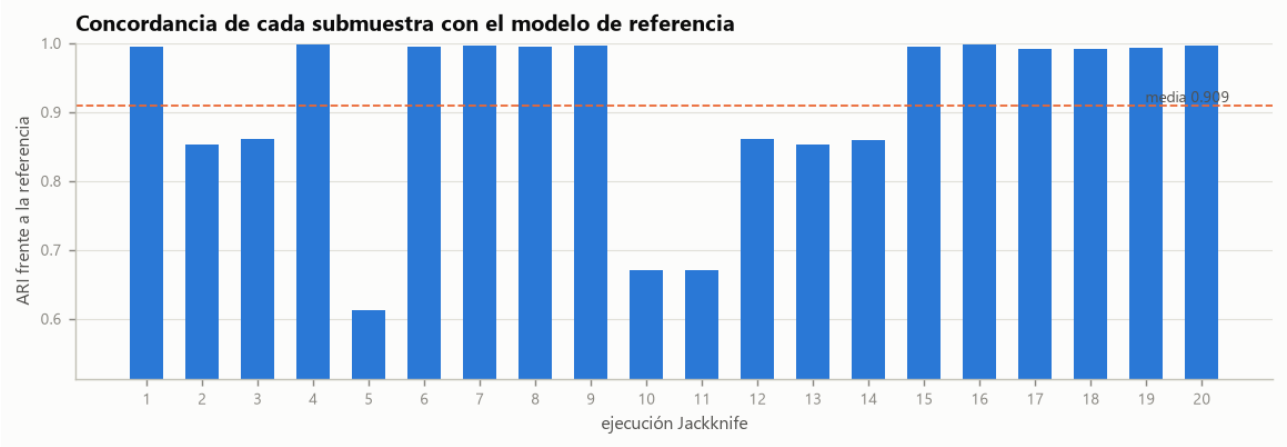


Figura 7.1. ARI de cada submuestra

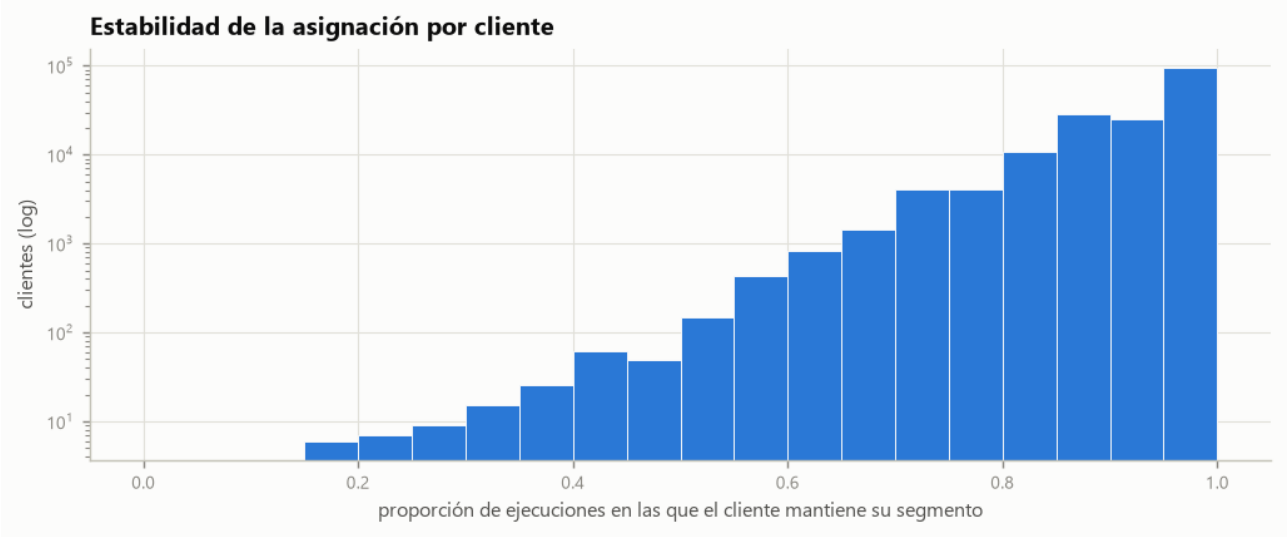


Figura 7.2. Estabilidad por cliente

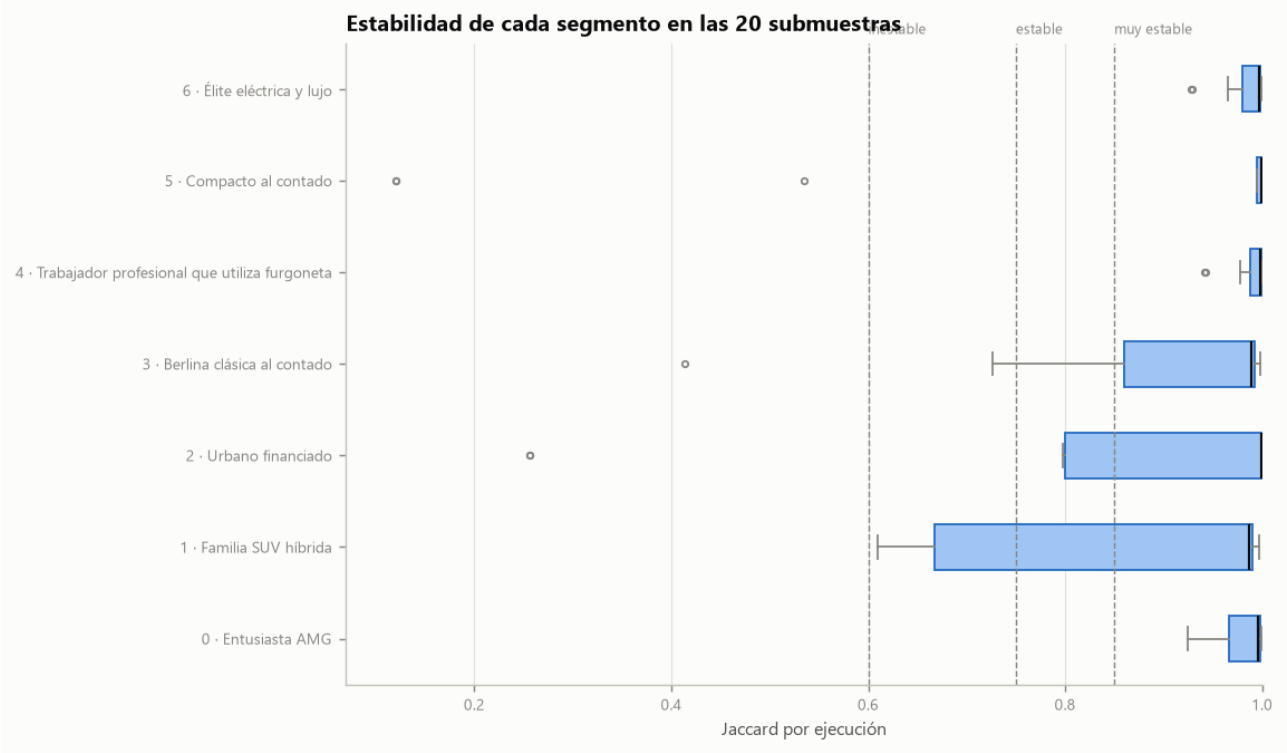


Figura 7.3. Jaccard por segmento

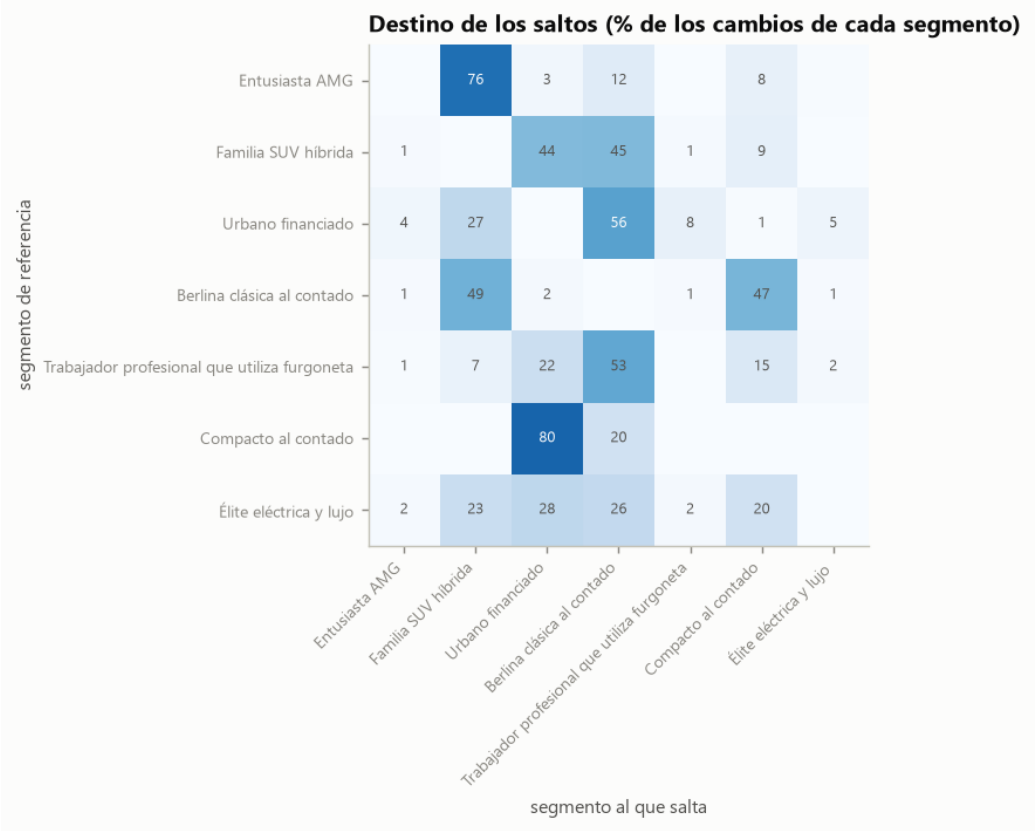


Figura 7.4. Destino de los saltos