Segmentación de clientes Mercedes-Benz

Informe de resultados del proyecto — Malackathon, reto Mercedes-Benz

Segmentación no supervisada (K-Means) de 173.456 clientes de Suiza y Austria para habilitar campañas de ofertas de vehículo, mantenimiento, fidelización y comunicación dirigida.

Resumen ejecutivo

• **Datos:** 302.850 relaciones cliente–vehículo, 173.456 clientes. Tras el tratamiento no queda ningún nulo y las 15 comprobaciones de coherencia dan 0 errores.

• **Features:** 10 variables de modelo (edad, vehículos actuales, leasing, gama de la flota, AMG, electrificación y antigüedad del vehículo), log1p + StandardScaler en un Pipeline. Se eliminó *tiene_vehiculo_actual* por redundante con *n_vehiculos_actuales*, y meses como cliente, PA relativo y visitas al taller pasan a ser solo descriptivas porque desestabilizaban el modelo.

• **Modelo:** K-Means con **k = 7** (silhouette 0,240; Davies-Bouldin 1,42).

• **Segmentos:** 7 segmentos K-Means + 1 segmento Flota/Profesional (833 cuentas excluidas del entrenamiento). Los ex-clientes (~10 %) se tratan con una campaña transversal.

• **Robustez:** K-Means es el mejor de los algoritmos comparados y la segmentación es muy estable: **ARI Jackknife 0,91** y los 7 segmentos con Jaccard ≥ 0,87.

1. EDA y calidad de datos

Cada fila es una relación cliente–vehículo, así que para segmentar se agrega por cliente.

Características principales de los clientes

• Particulares: el 99,4 % son B2C y el 61 % tiene 45 años o más.

• Mayoría en Suiza (66 %); poder adquisitivo de su zona ≈ 1,7 veces el de Austria (51 k€ frente a 30 k€ por habitante).

• Un solo coche conectado en el 81 % de los casos; el 10 % no tiene ningún vehículo actual (ex-clientes).

• Relación de unos 3 años con la marca; el 71 % no ha usado nunca leasing (más habitual en Suiza y entre 35 y 44 años).

• El 81 % acepta teléfono, email y correo postal.

• SUV y compactos premium (GLC, C, A, B/GLA/GLB), 13 % AMG, 14 % furgonetas; antigüedad mediana del coche 4,7 años.

• Electrificación en subida: los eléctricos pasan del 2,5 % de las matriculaciones de 2019 al 37,5 % de las de 2026.

• Uso urbano: trayectos de unos 14 km a unos 49 km/h.

Problemas de calidad y solución

Problema	Solución
Columnas sin valor analítico (índice, IDs, model_class)	Eliminadas; los IDs solo como clave de agregación
Telemetría ausente en el 52 % de las filas	Sin telemetría → 0 + indicador has_telemetry; parcial → mediana/moda de su serie
Motorización nula (44 %) y combustible nulo (59 %)	Reglas por nombre comercial, serie y año (99–100 % de acierto); el resto con la moda
Código postal nulo (5 %) y datos de zona nulos (6 %)	Código postal real del país por cliente; datos de zona del código postal o de la región
Valores imposibles (velocidad < 1 km/h, horas a 0…)	Tratados como nulos; extremos recortados a P1–P99
Género desconocido (17 %)	Categoría unknown
Pico artificial en 36 meses como cliente (12 %)	Se conserva y se marca con un indicador

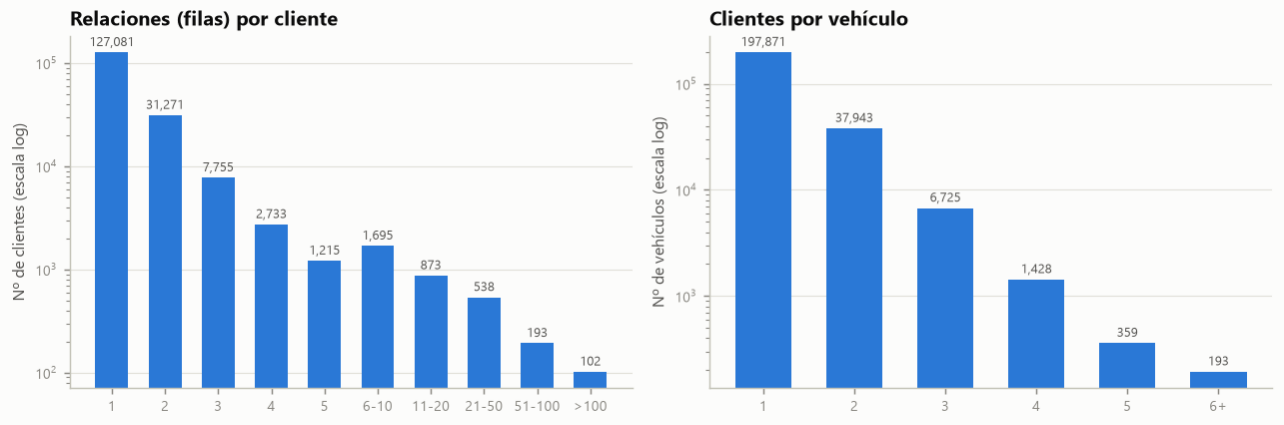


Figura 1.1. Granularidad: relaciones por cliente

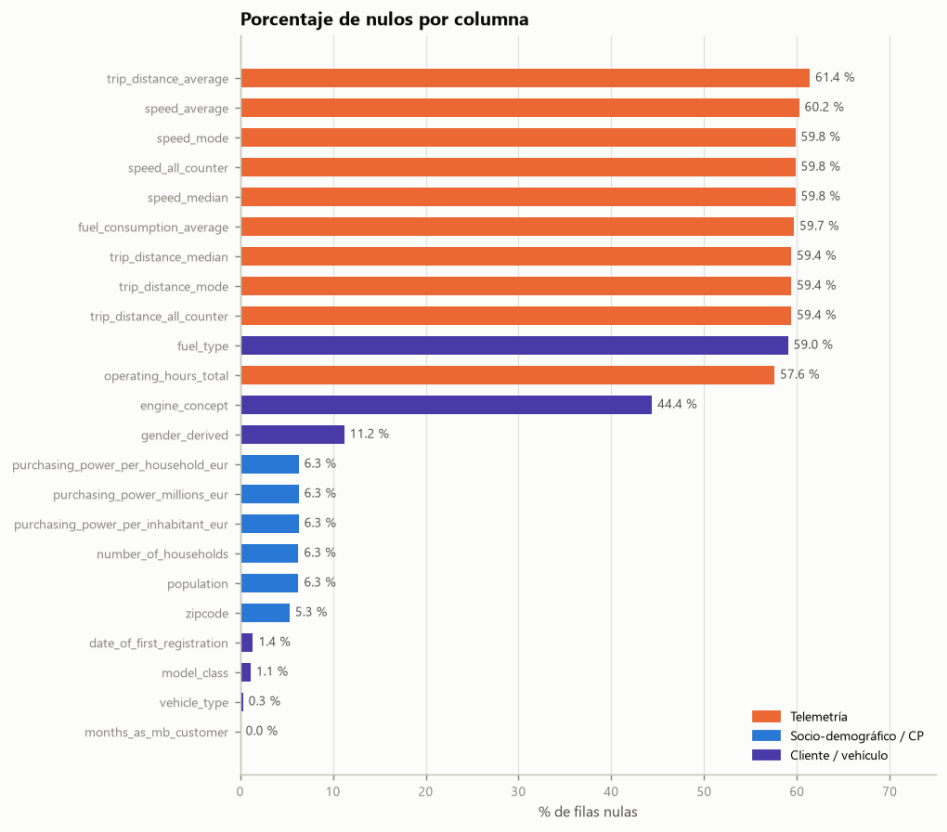


Figura 1.2. Nulos por columna

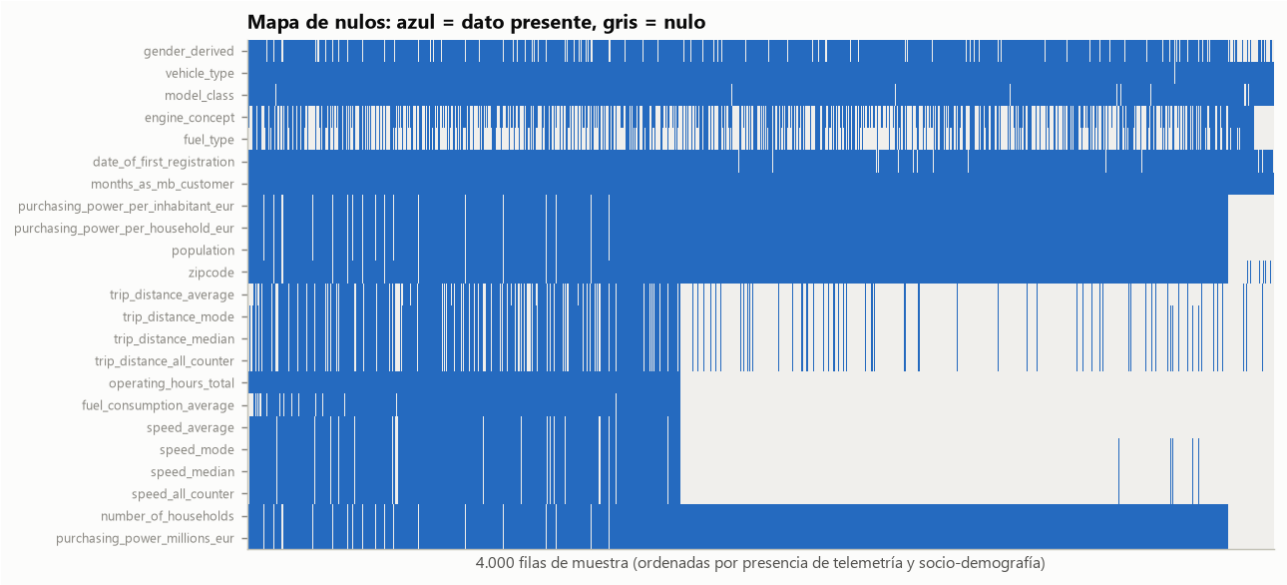


Figura 1.3. Mapa de nulos

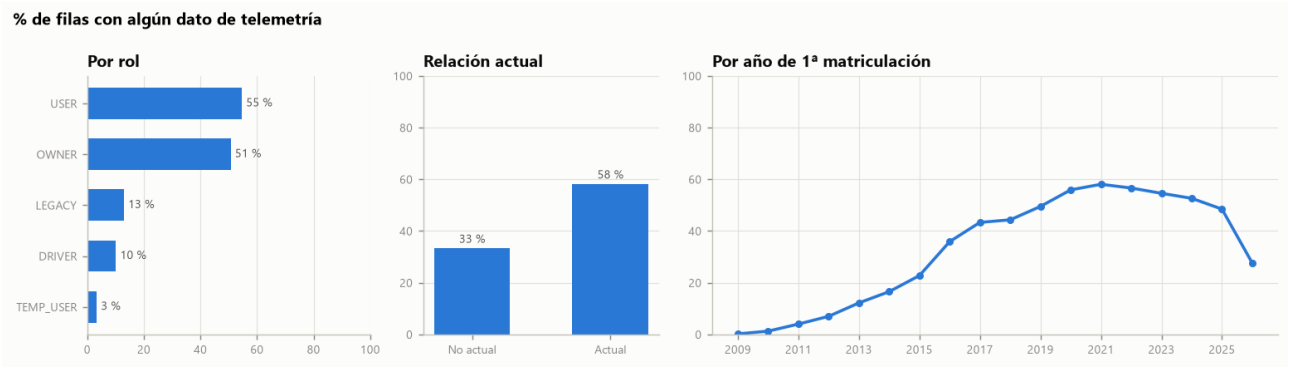


Figura 1.4. Disponibilidad de telemetría

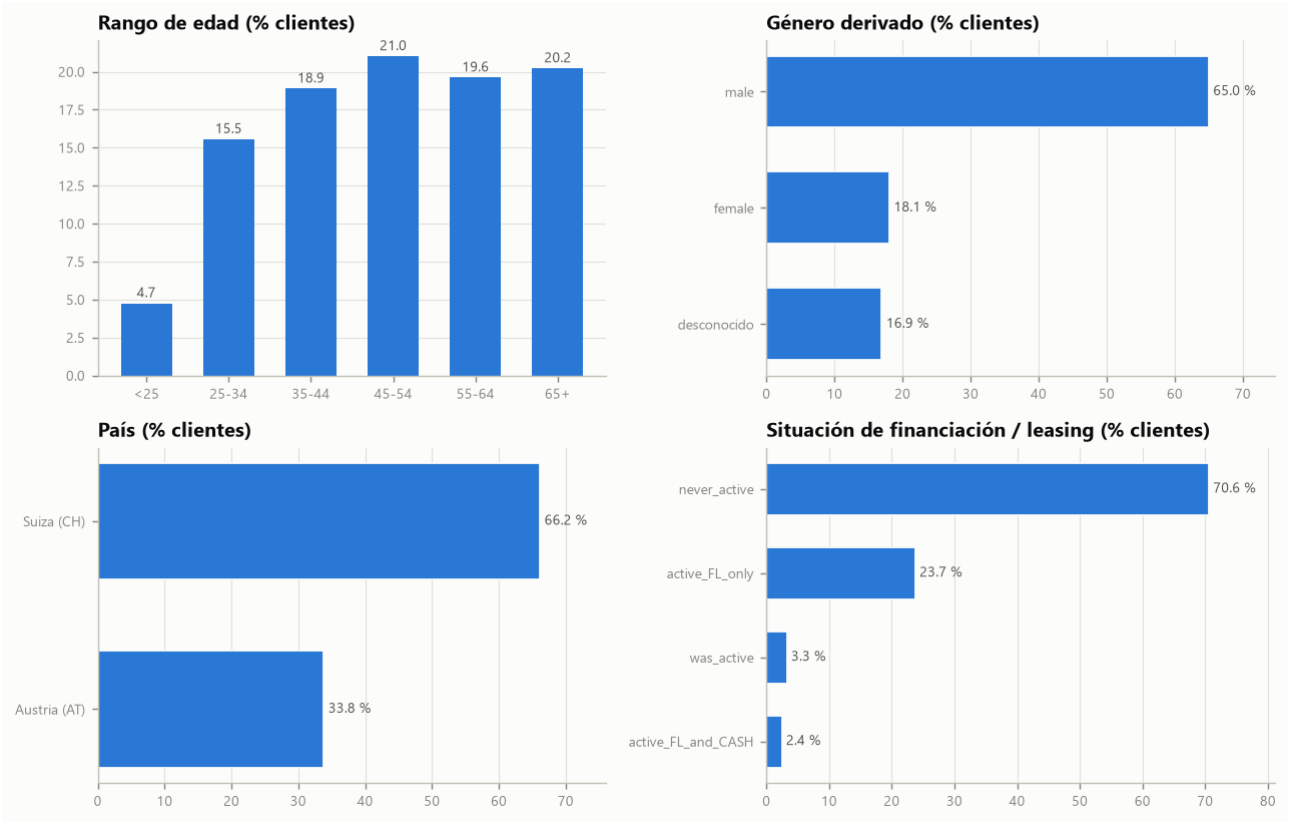


Figura 1.5. Perfil del cliente

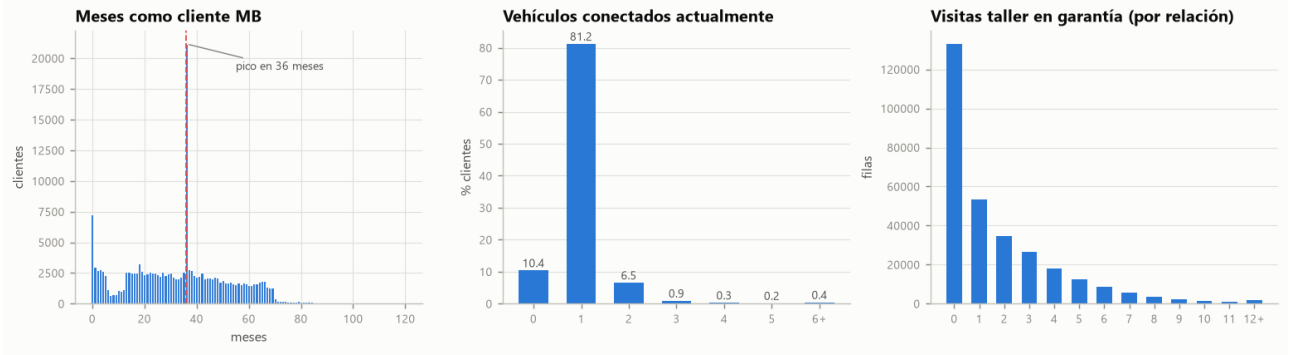


Figura 1.6. Relación con la marca

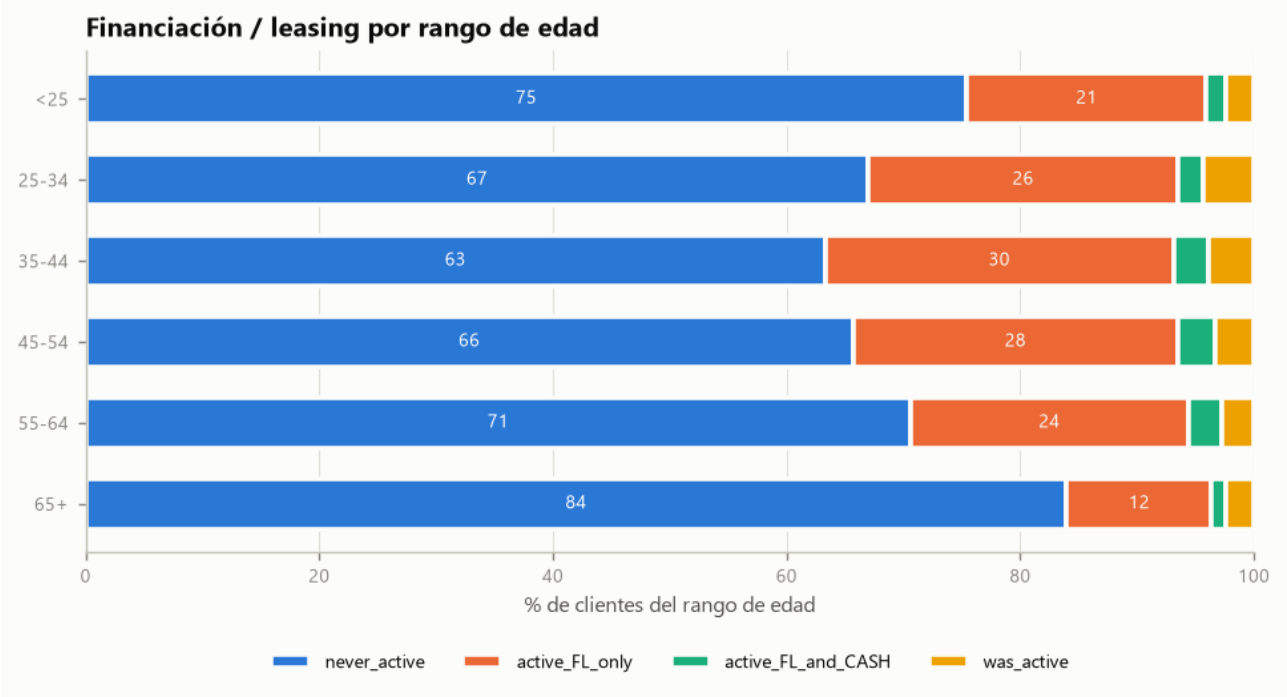


Figura 1.7. Financiación por edad

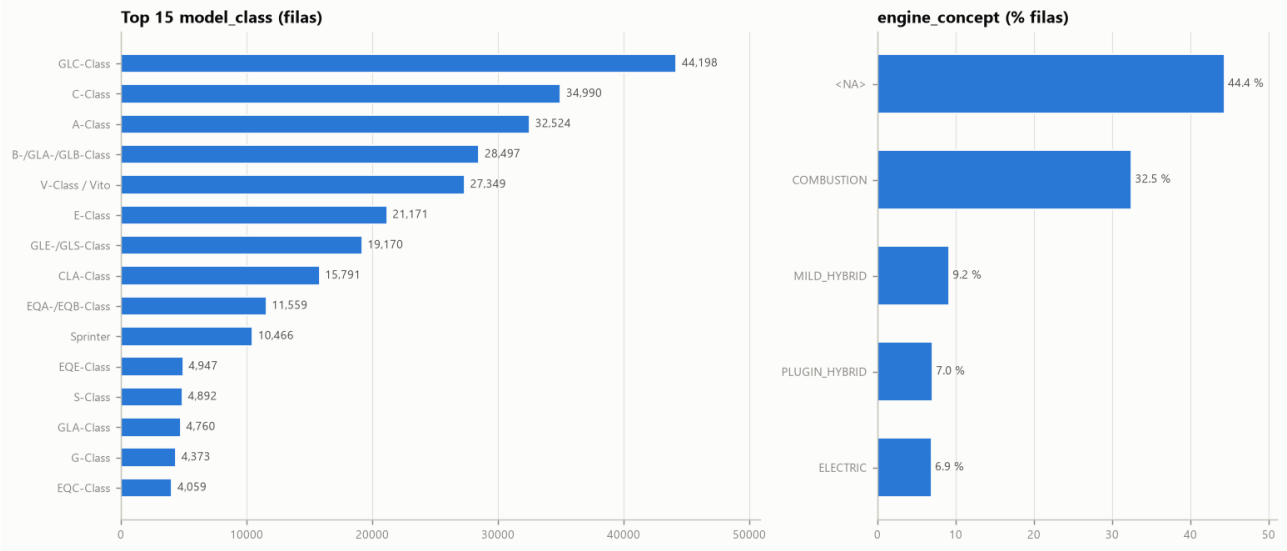


Figura 1.8. Clase de vehículo y motor

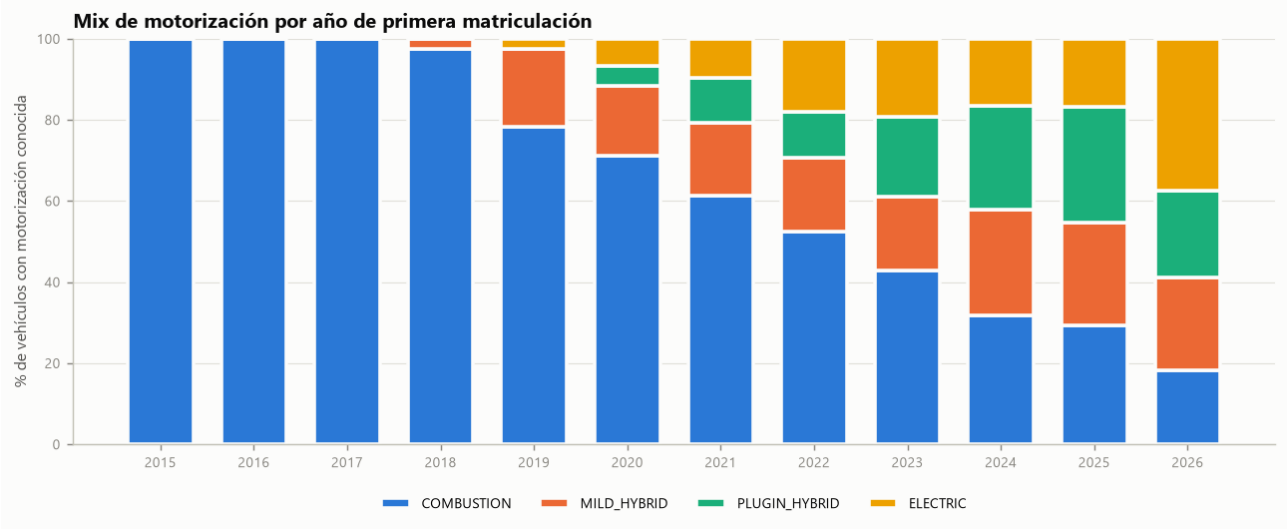


Figura 1.9. Electrificación por año de matriculación

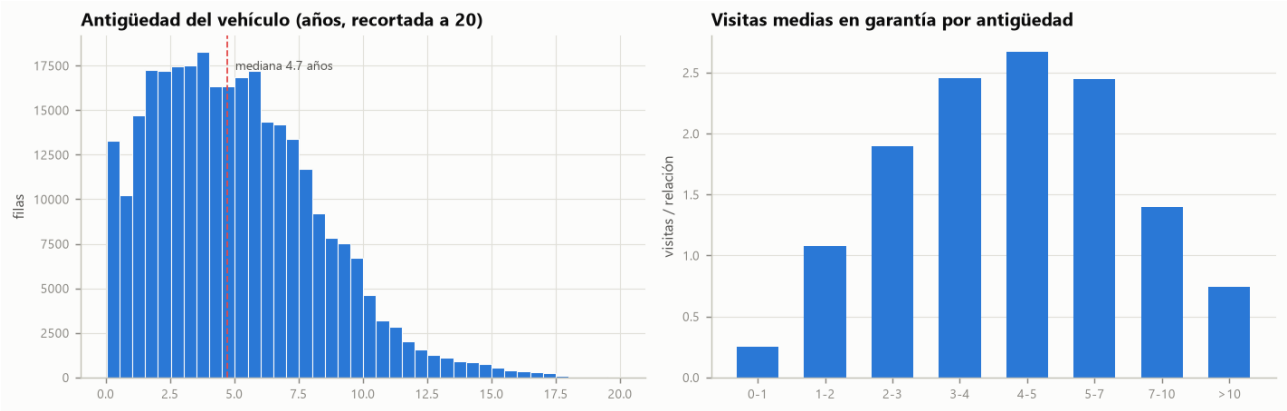


Figura 1.10. Antigüedad y visitas al taller

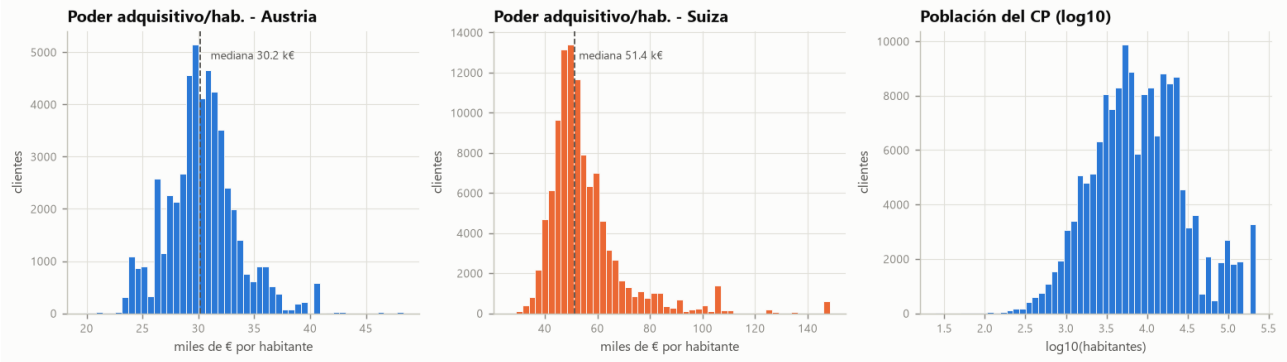


Figura 1.11. Socio-demografía de la zona

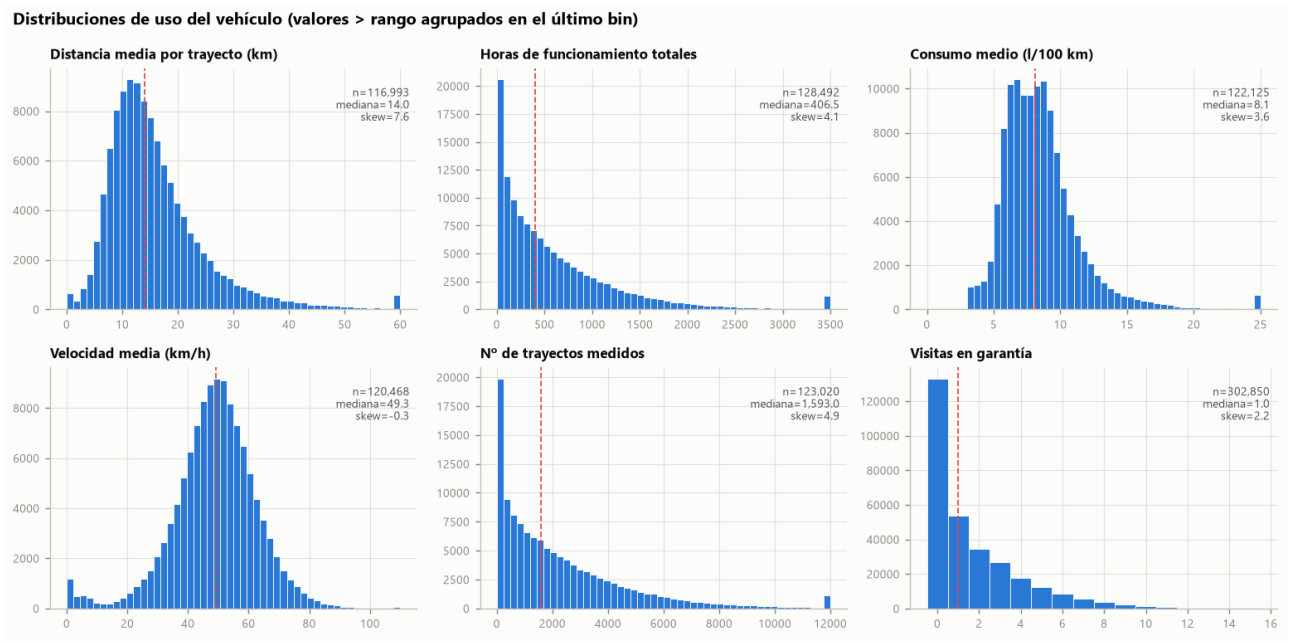


Figura 1.12. Distribuciones de telemetría

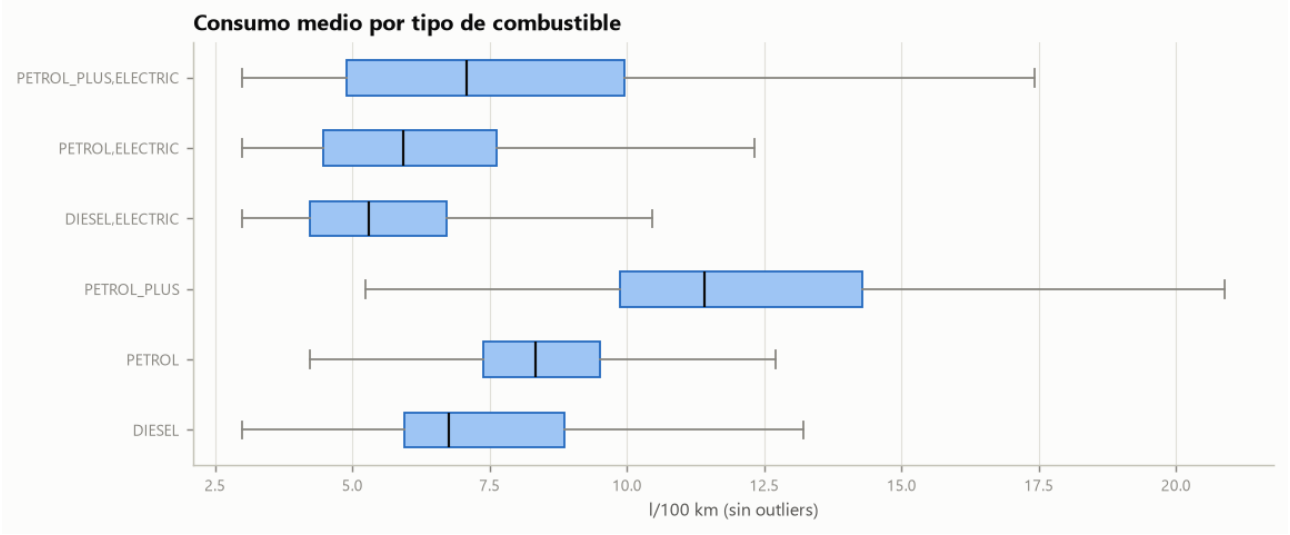


Figura 1.13. Consumo por combustible

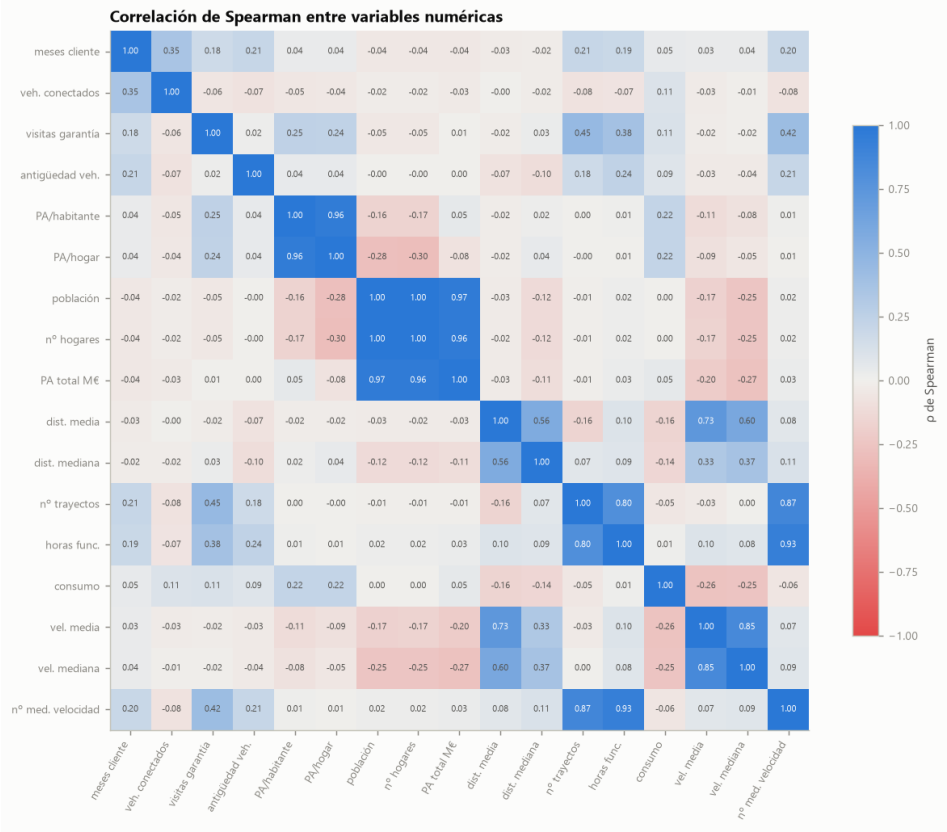


Figura 1.14. Correlación de Spearman

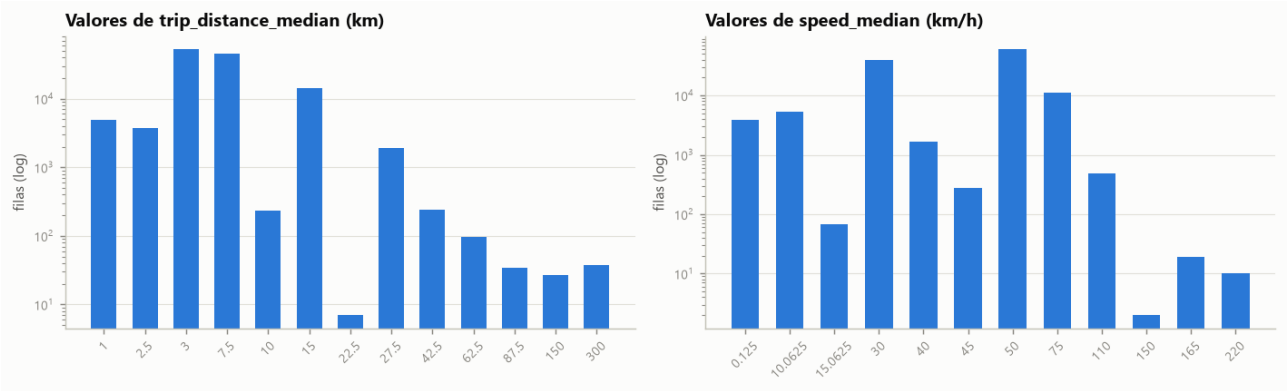


Figura 1.15. Medianas discretizadas

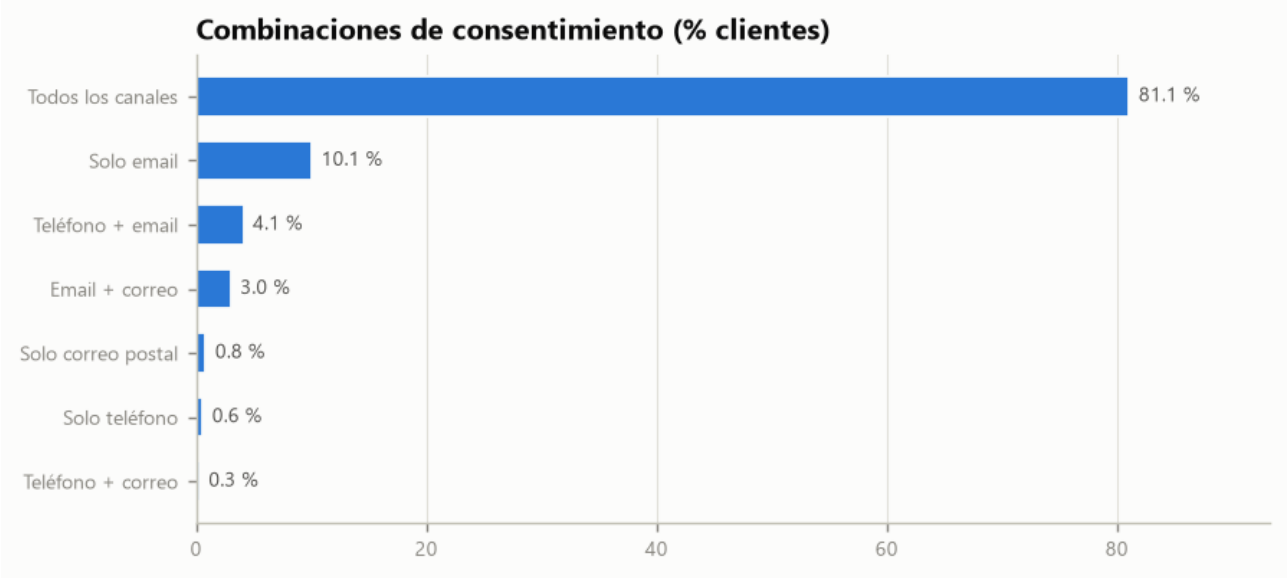


Figura 1.16. Consentimientos de comunicación

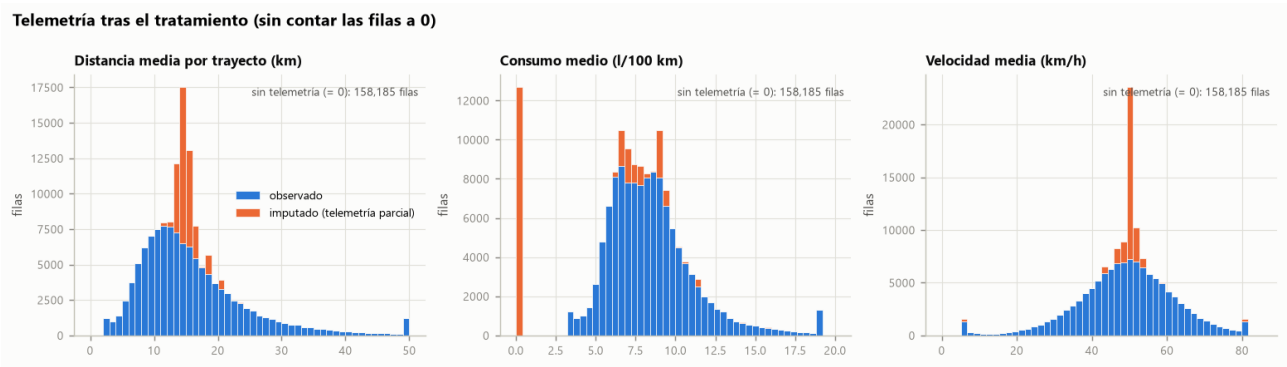


Figura 1.17. Impacto del relleno de telemetría

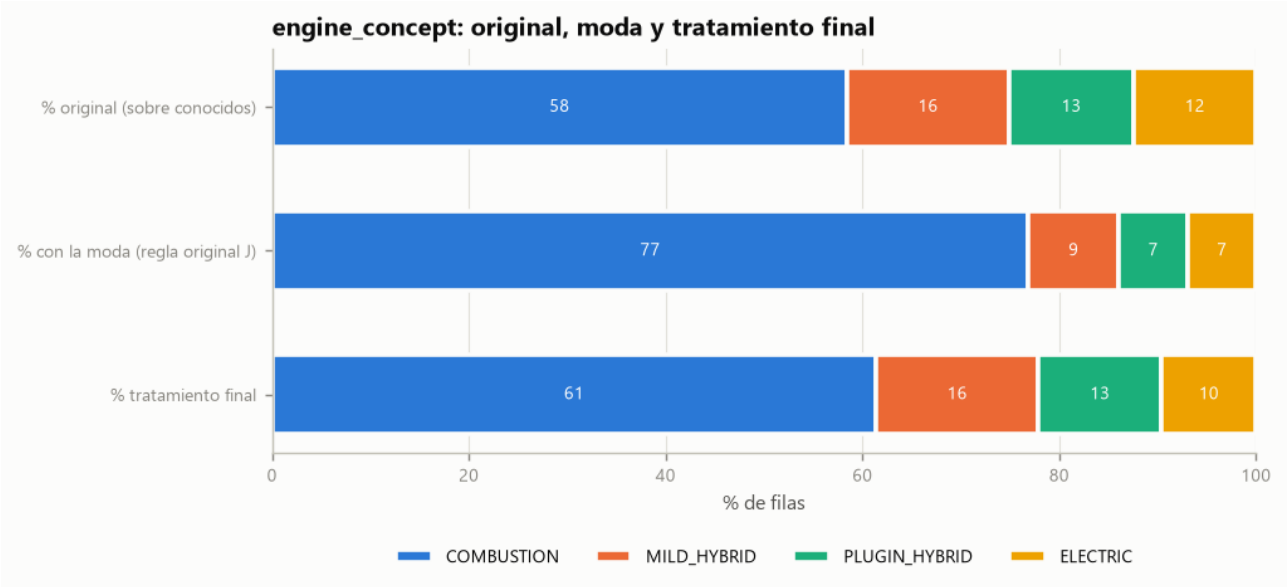


Figura 1.18. Motorización: moda frente a reglas

2. Feature engineering

Las 833 cuentas con más de 20 relaciones (concesionarios, rent-a-car o flotas) se apartan como segmento propio. El resto se segmenta con 10 features; telemetría, país, leasing pasado, meses como cliente, PA relativo y visitas al taller se usan solo para describir.

#	Feature	Por qué se incluye
1	edad_ord	Etapa vital
2	n_vehiculos_actuales	Valor del cliente; con 0 identifica a los ex-clientes
3	leasing_activo	Contrato vivo: renovación
4–7	share_compacto / suv / lujo_deportivo / furgoneta	Gama de la flota
8	share_amg	Altas prestaciones
9	share_electrificado	Transición energética
10	edad_vehiculo	Ciclo de renovación y garantía

Cambios respecto a la versión anterior: se eliminó *tiene_vehiculo_actual*, redundante con *n_vehiculos_actuales* (coinciden en el 99,998 % de los clientes), que duplicaba el peso de esa dimensión. Además, meses como cliente, PA relativo y visitas por vehículo pasan a ser solo descriptivas: son continuas y difusas y emborronaban las fronteras entre segmentos.

Sensibilidad: con esas 13 features el silhouette era 0,16 y el ARI Jackknife 0,69; con las 10 del modelo el silhouette sube a 0,24 y el ARI a 0,91.

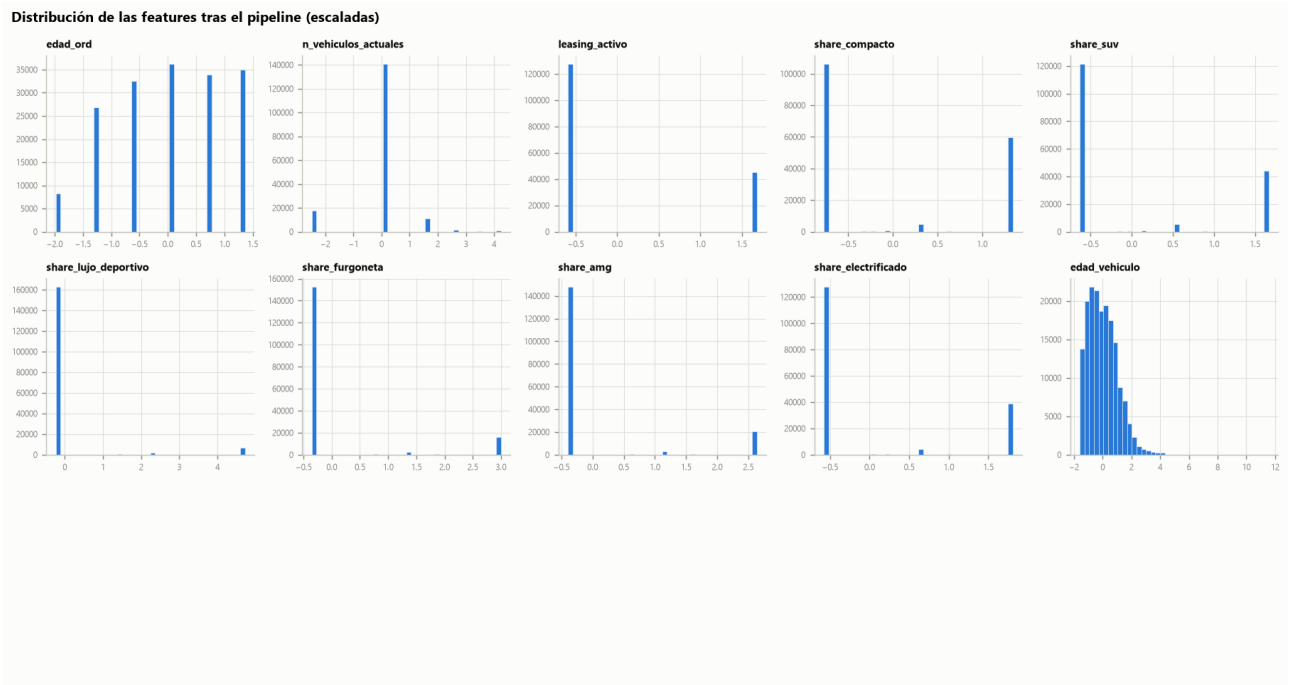


Figura 2.1. Distribución de las features

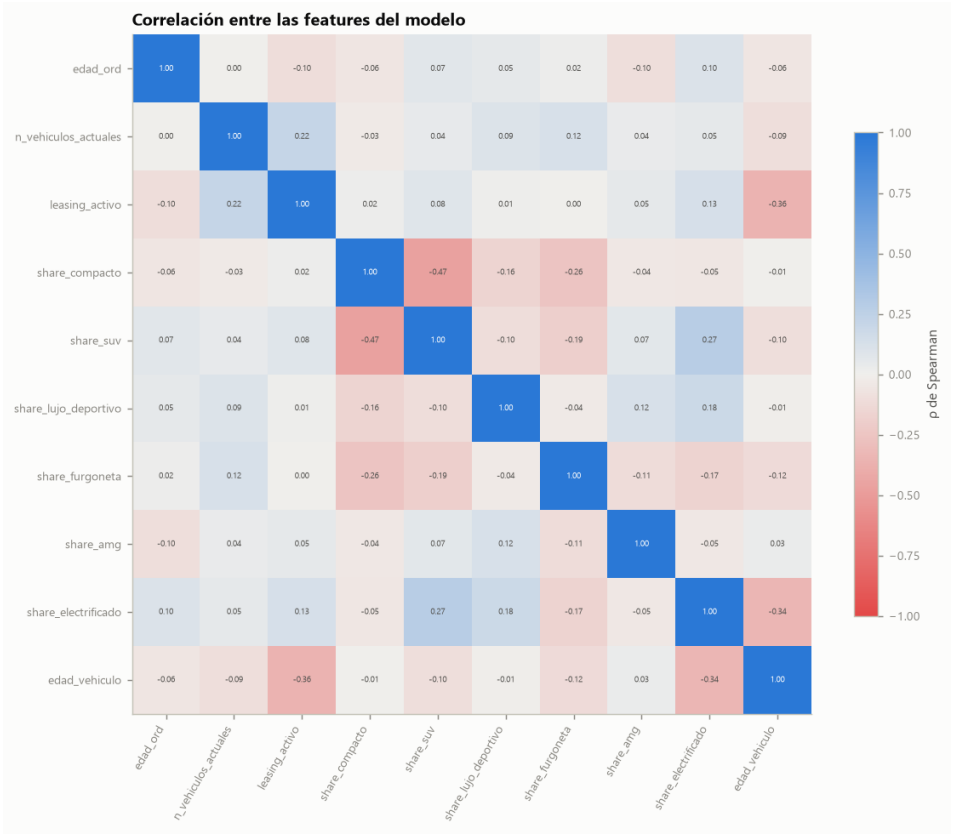


Figura 2.2. Correlación entre features (sin pares |ρ| > 0,8)

3. Modelo K-Means

K-Means para k = 2…10. Criterio: mejor silhouette dentro del rango de negocio (4–8 segmentos, todos ≥ 3 % de los clientes); a menos de 0,01 de silhouette se prefiere el mejor Davies-Bouldin; y estabilidad Jackknife. El candidato por silhouette es k = 8 (0,255), pero **se elige k = 7** (silhouette 0,240, Davies-Bouldin 1,42, clúster más pequeño 4,5 %) porque es mucho más estable.

k	silhouette	Davies-Bouldin	Calinski-Harabasz	clúster mín. %
2	0.179	2.300	3,182	34.1
3	0.223	1.858	3,304	11.0
4	0.219	1.639	3,381	5.1
5	0.224	1.586	3,521	4.9
6	0.238	1.473	3,635	4.8
7	0.240	1.417	3,609	4.5
8	0.255	1.399	3,533	4.4
9	0.259	1.321	3,441	4.1
10	0.249	1.263	3,411	4.2

Estabilidad k = 7 frente a k = 8: ARI Jackknife 0,909 frente a 0,818; con k = 8 dos segmentos son inestables (Jaccard 0,41 y 0,55), con k = 7 todos tienen Jaccard ≥ 0,87.

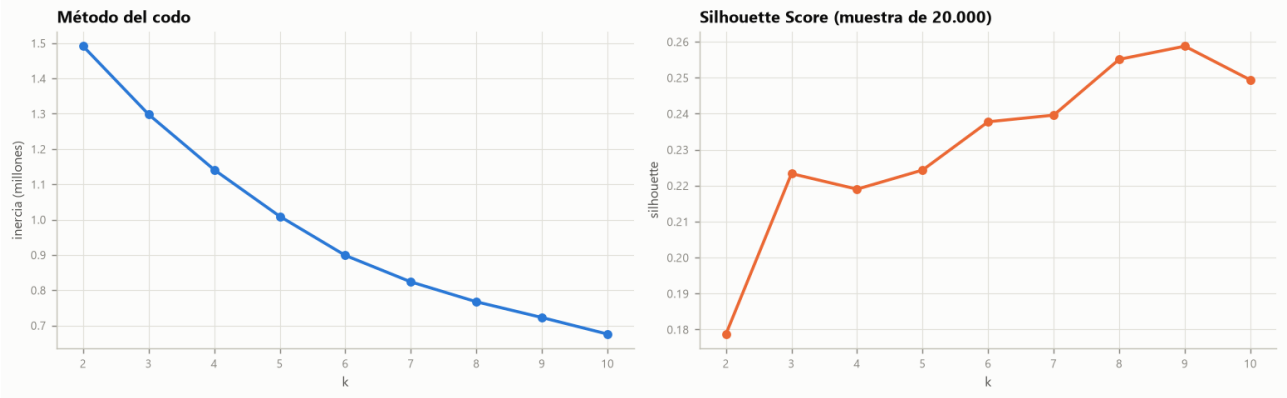


Figura 3.1. Método del codo y silhouette

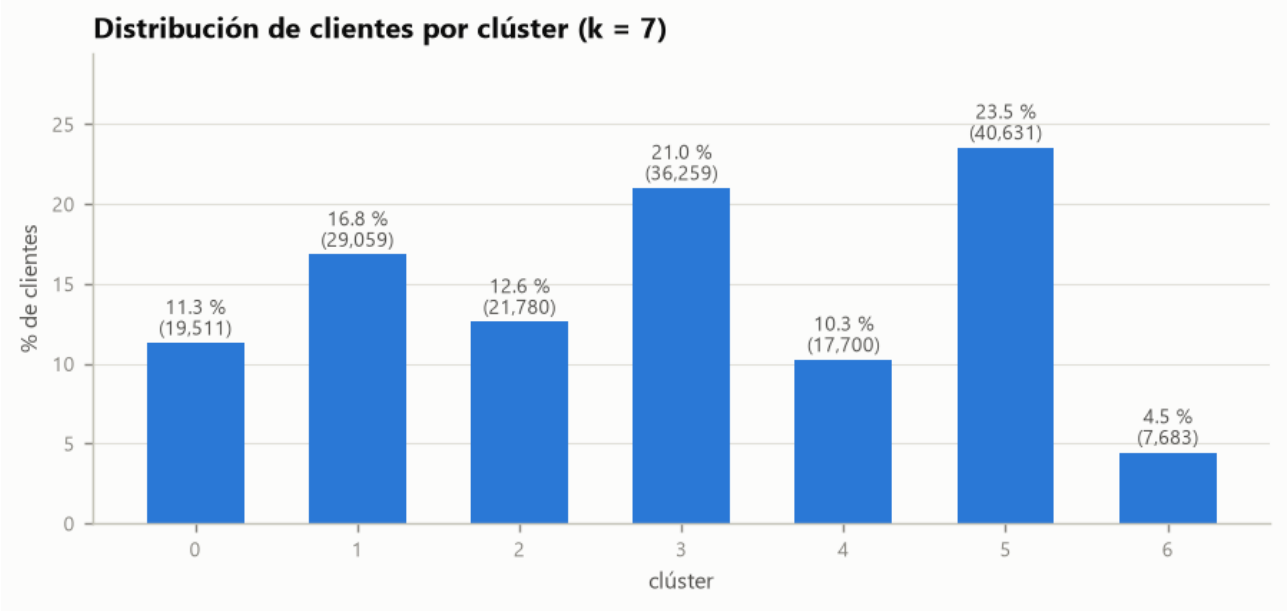


Figura 3.2. Distribución de clientes por clúster

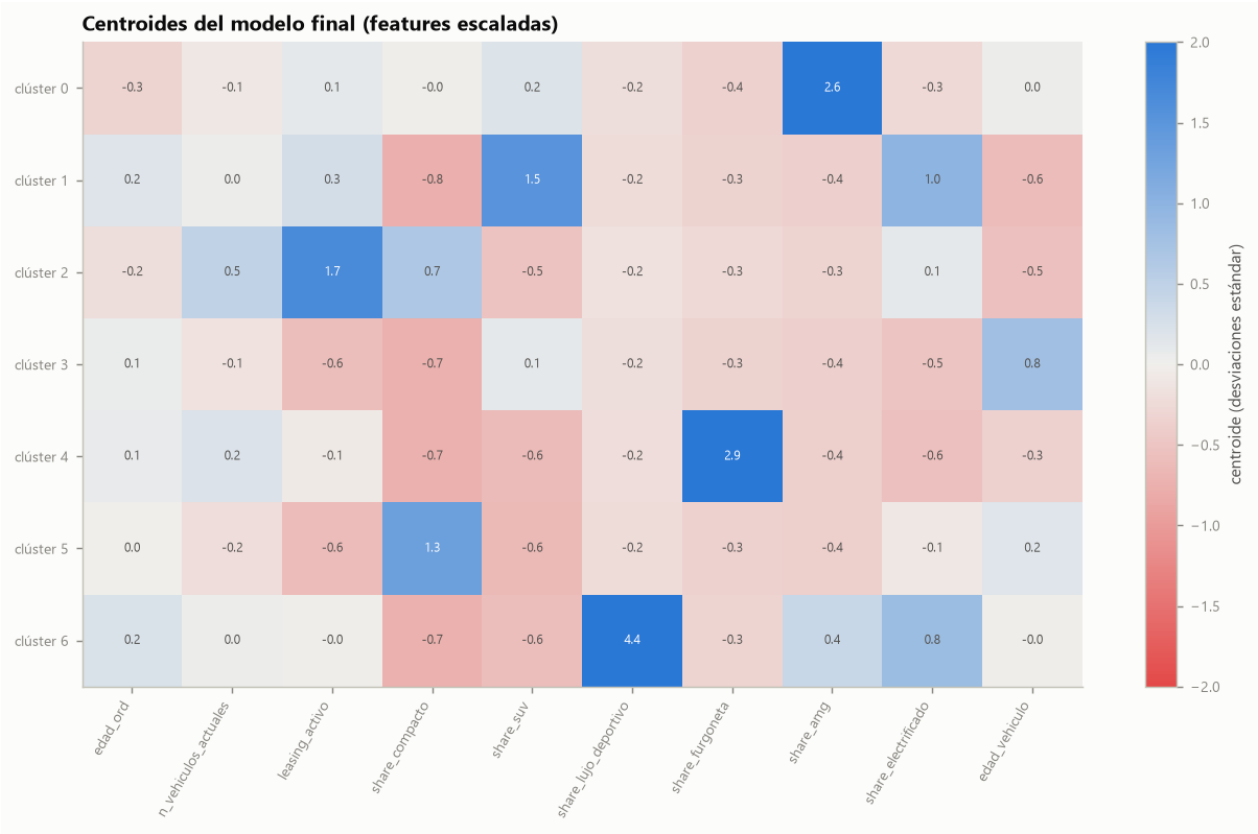


Figura 3.3. Centroides del modelo final (features escaladas)

4. Perfilado de los segmentos

Segmento	%	Quién es	Acción
Compacto al contado	23,4	A, B/GLA/GLB o CLA de ~5 años, sin financiación; 21 % electrificado; más mayores de 65	Renovación a compacto nuevo o EQA/EQB con financiación; mantenimiento al salir de garantía
Berlina clásica al contado	20,9	C/E y algo de GLC, ~7 años (los más antiguos), sin financiación, 3 % electrificado	Mantenimiento y extensión de garantía; renovación financiada con paso a híbrido
Familia SUV híbrida	16,8	GLC/GLE, 65 % electrificado (sobre todo PHEV), 45+ años, 39 % con leasing	Paso a SUV eléctrico, accesorios, mantenimiento de híbridos
Urbano financiado	12,6	100 % leasing, compactos de ~3 años, 19 % BEV, más joven, 77 % Suiza	Renovación anticipada al vencer el contrato, upgrade a EQ, canal digital
Entusiasta AMG	11,2	Flota casi solo AMG; el más joven y el más suizo (91 %); más visitas al taller	Eventos AMG, mantenimiento premium, personalización
Trabajador profesional que utiliza furgoneta	10,2	V-Class, Vito o Sprinter de ~4 años; 35–64 años	Taller prioritario, mantenimiento por km, eVito/eSprinter
Élite eléctrica y lujo	4,4	EQE/EQS, Clase S/Maybach, AMG GT; 49 % BEV; zona más rica; más edad	Gestor dedicado, acceso preferente, recogida y entrega
Flota / Profesional	0,5	833 cuentas con más de 20 relaciones (fuera del K-Means)	Gestión B2B; revisar el rol en el CRM

Campaña transversal de ex-clientes (~10 % de la base): los clientes sin vehículo actual (*n_vehiculos_actuales = 0*) no forman un segmento aparte, sino que se agrupan según la gama de su último coche (del 0 % en Urbano financiado al 15 % en Berlina clásica). Así la campaña de recuperación se personaliza con la oferta de su segmento: ocasión certificada o nuevo leasing del mismo tipo de vehículo.

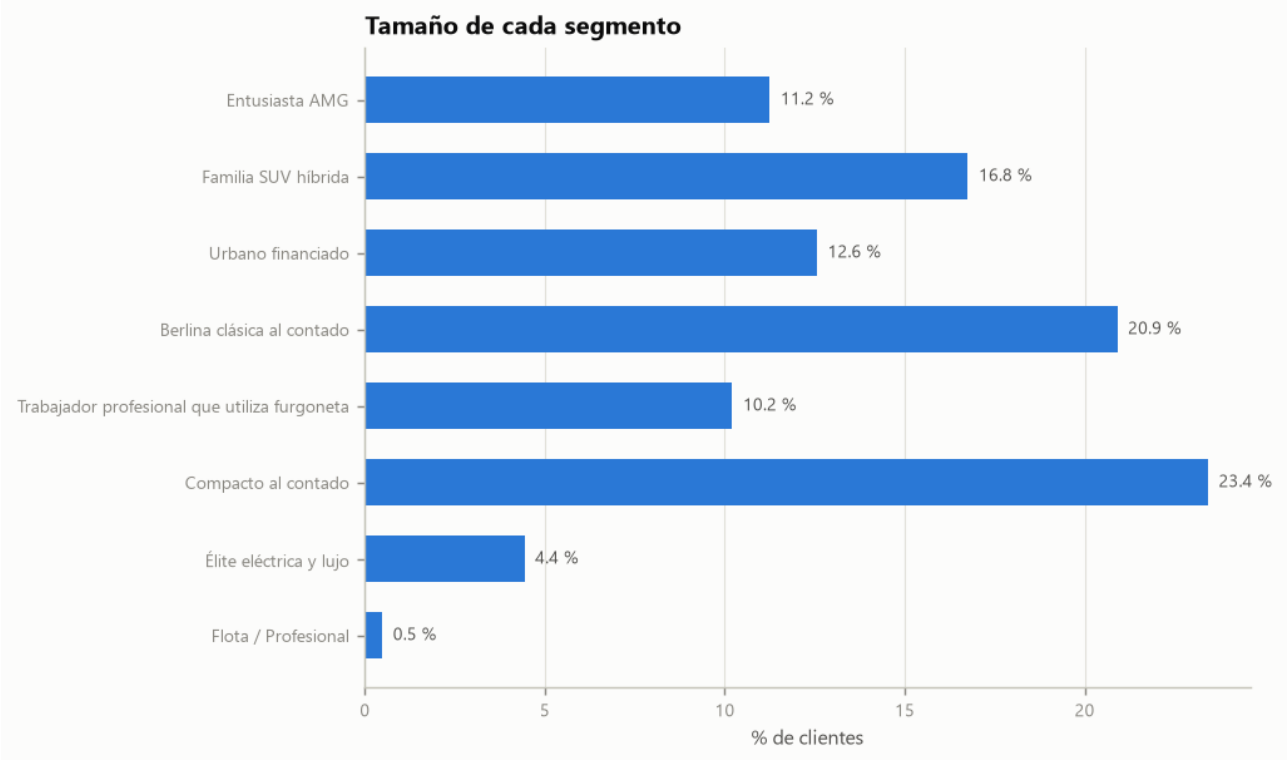


Figura 4.1. Tamaño de cada segmento

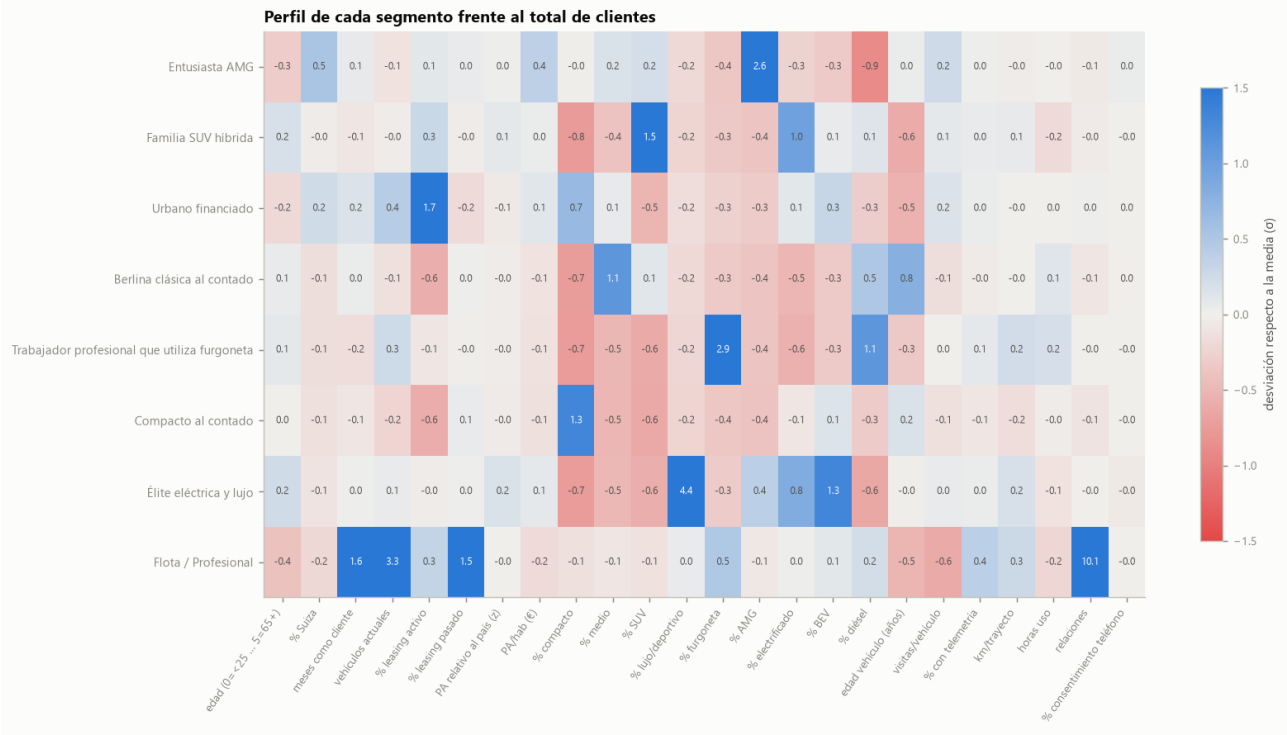


Figura 4.2. Perfil de cada segmento frente al total (σ)



Figura 4.3. Composición de cada segmento (%)

5. Avanzado 1: comparativa de algoritmos

Mismo k = 7 y mismos datos; métricas sobre una muestra común de 15.000 clientes.

Algoritmo	silhouette	Davies-Bouldin	ARI vs K-Means	NMI vs K-Means
K-Means	0.240	1.418	1.00	1.00
MiniBatch K-Means	0.239	1.402	0.73	0.79
Gaussian Mixture	0.221	1.650	0.42	0.57
Aglomerativo (Ward)	0.219	1.536	0.56	0.65
Birch	0.099	2.042	0.26	0.43

Furgonetas y élite eléctrica/lujo se reproducen en GMM y Ward con un 90–100 % de coincidencia, y Ward también reproduce AMG (94 %). Las diferencias se concentran entre Familia SUV, Berlina clásica y Compacto. MiniBatch K-Means es casi igual (silhouette 0,239, ARI 0,73). DBSCAN no encaja (decenas de microclústeres o un único clúster). **Recomendación: mantener K-Means.**

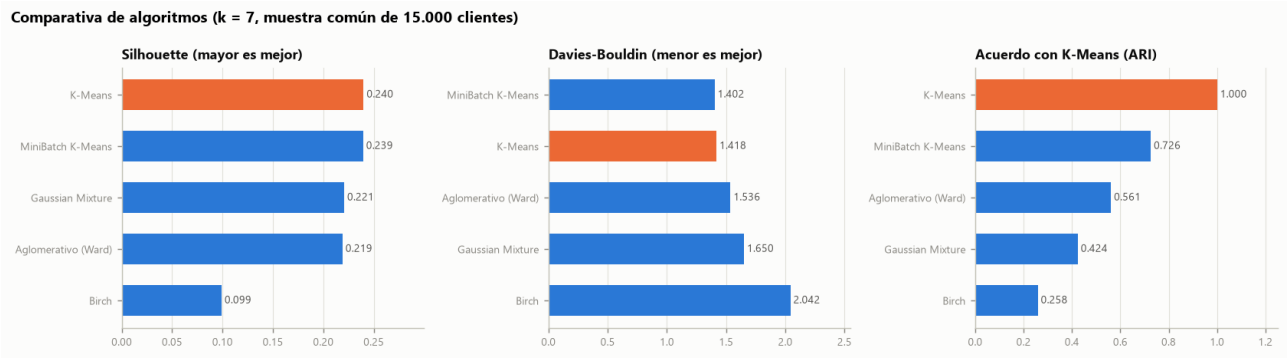


Figura 5.1. Comparativa de métricas

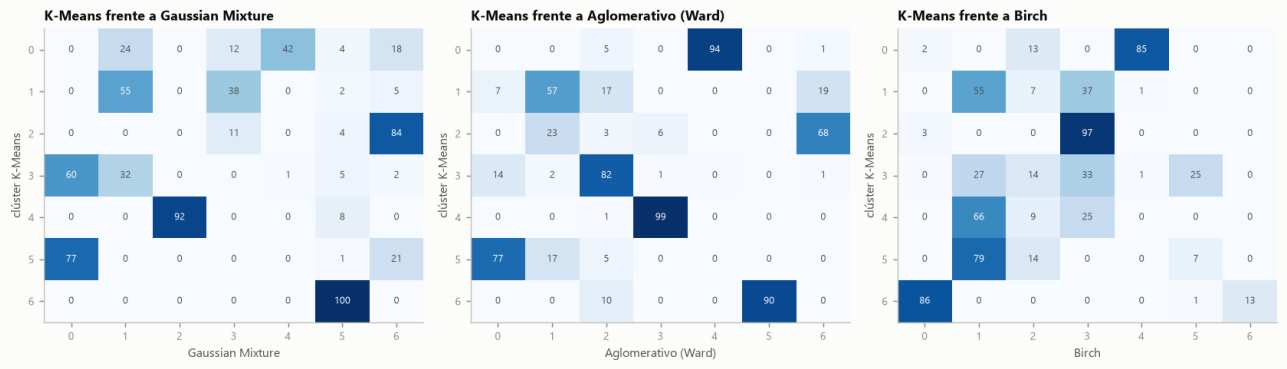


Figura 5.2. Contingencias frente a K-Means

6. Avanzado 2: PCA

Hacen falta 7 componentes para explicar el 80 % de la varianza (PC1 + PC2 = 32 %). En 2D los segmentos se distinguen en parte (silhouette 0,085), pero en 3D conservan casi toda su separación (0,236 frente a 0,239 en el espacio completo). PC1 = SUV electrificado y moderno frente a coche antiguo; PC2 = compacto financiado; PC3 = furgoneta; PC4 = AMG; PC5 = lujo.

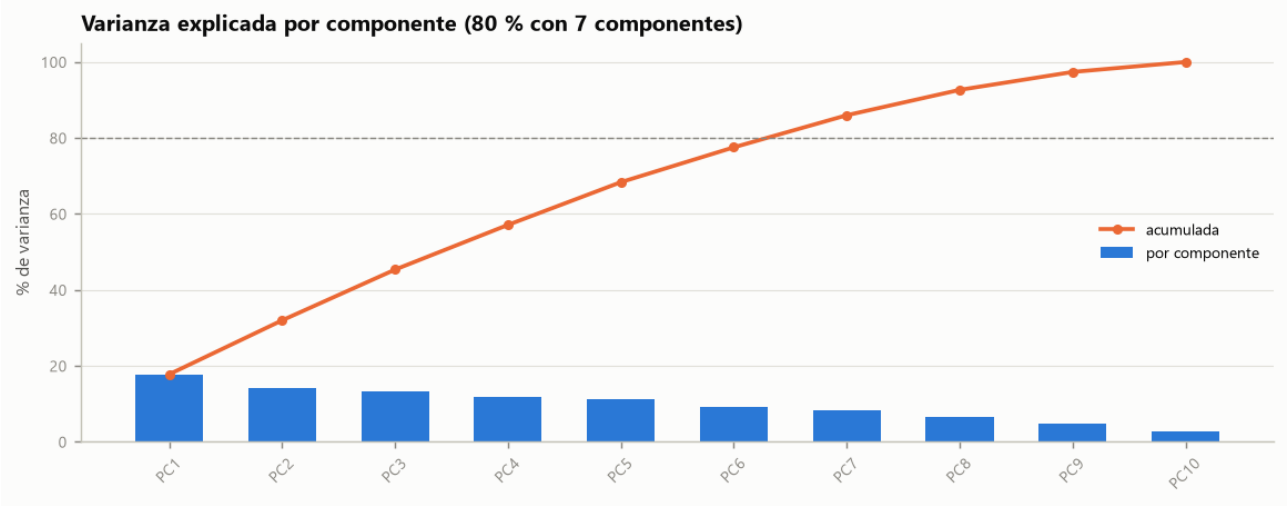


Figura 6.1. Varianza explicada

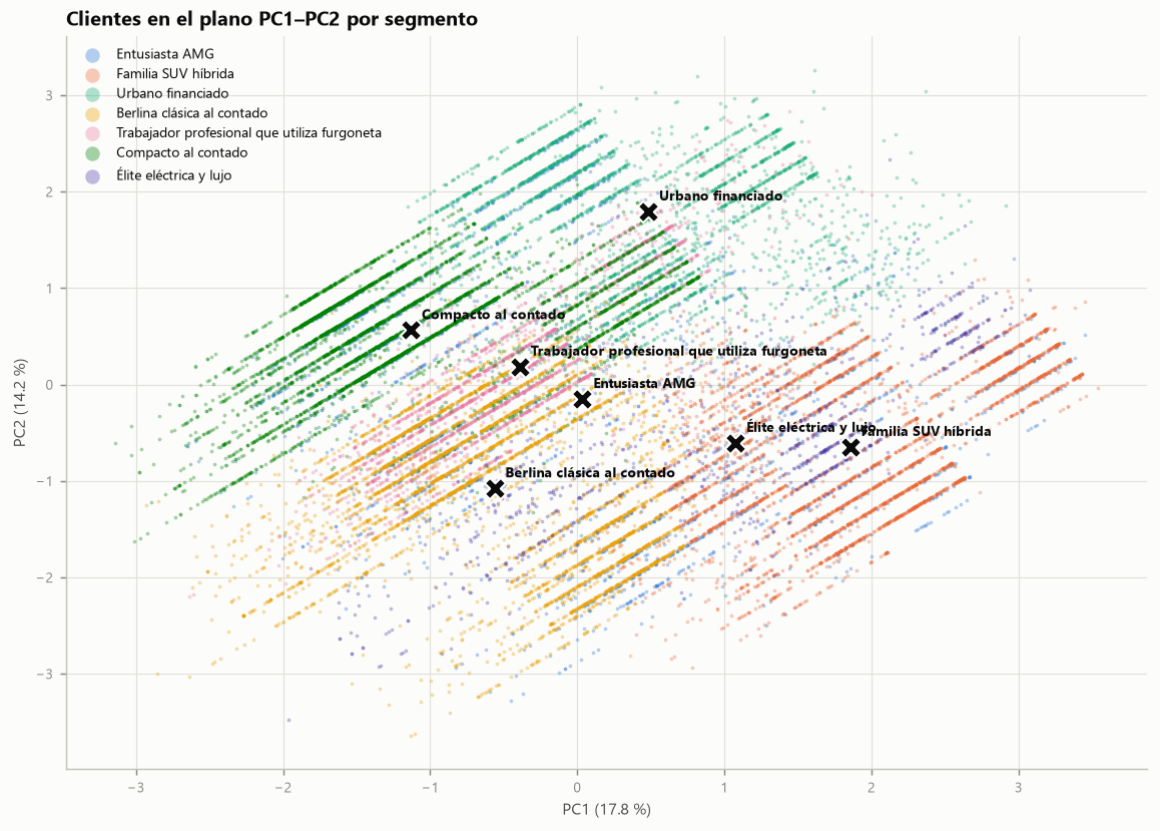


Figura 6.2. Clientes en el plano PC1–PC2

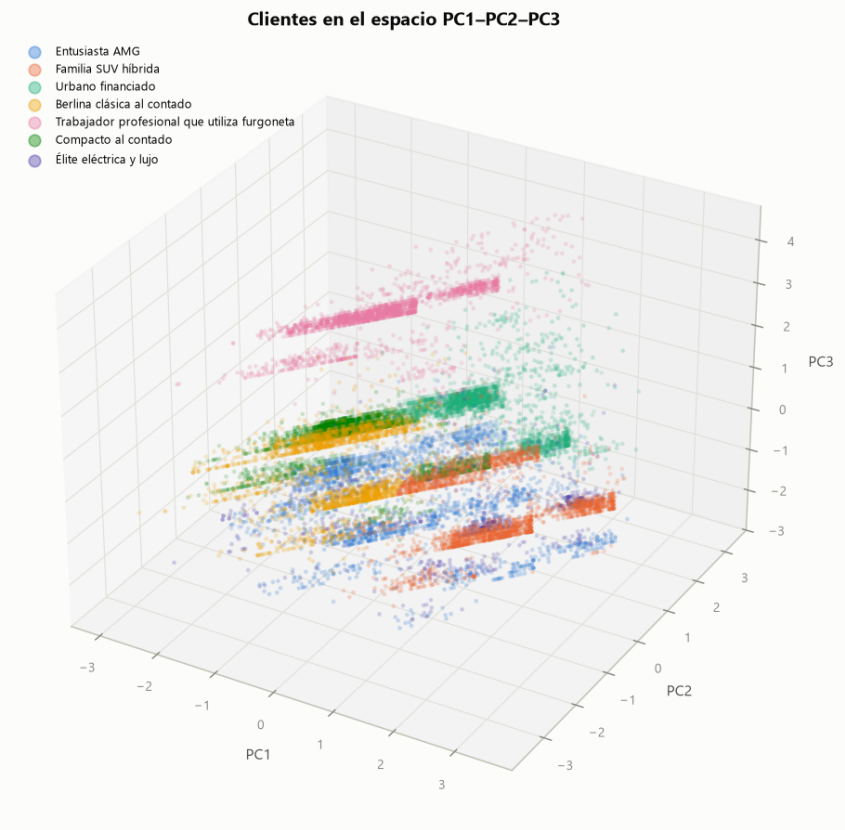


Figura 6.3. Proyección 3D

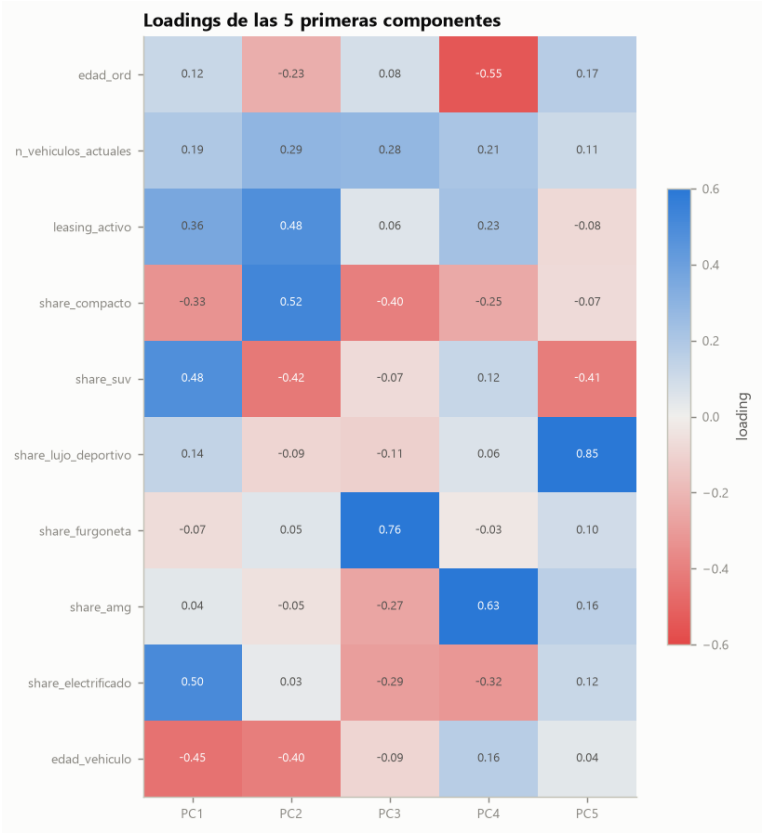


Figura 6.4. Loadings de las componentes

7. Avanzado 3: estabilidad (Jackknife)

20 submuestras excluyendo el 15 % de los clientes. **ARI medio 0,909** (mín. 0,613); coincidencia media por cliente 94,2 %; solo el 6,5 % de los clientes cambia de segmento en más del 20 % de las ejecuciones.

Segmento	Jaccard medio	Jaccard mín.	% coincidencia	Estabilidad
Familia SUV híbrida	0.867	0.609	89.8	muy estable
Urbano financiado	0.874	0.256	96.6	muy estable
Compacto al contado	0.887	0.120	89.4	muy estable
Berlina clásica al contado	0.904	0.413	95.6	muy estable
Entusiasta AMG	0.981	0.925	98.5	muy estable
Élite eléctrica y lujo	0.985	0.928	99.2	muy estable
Trabajador profesional que utiliza furgoneta	0.989	0.942	99.6	muy estable

Los 7 segmentos son muy estables (Jaccard ≥ 0,87) y pueden activarse ya. Los pocos saltos se dan sobre todo de Compacto al contado a Urbano financiado y entre Familia SUV y Berlina clásica: son clientes cerca de la frontera entre centroides. **Recomendación:** usar el margen a la frontera como medida de confianza, fijar semilla y n_init, y repetir el test cada trimestre.

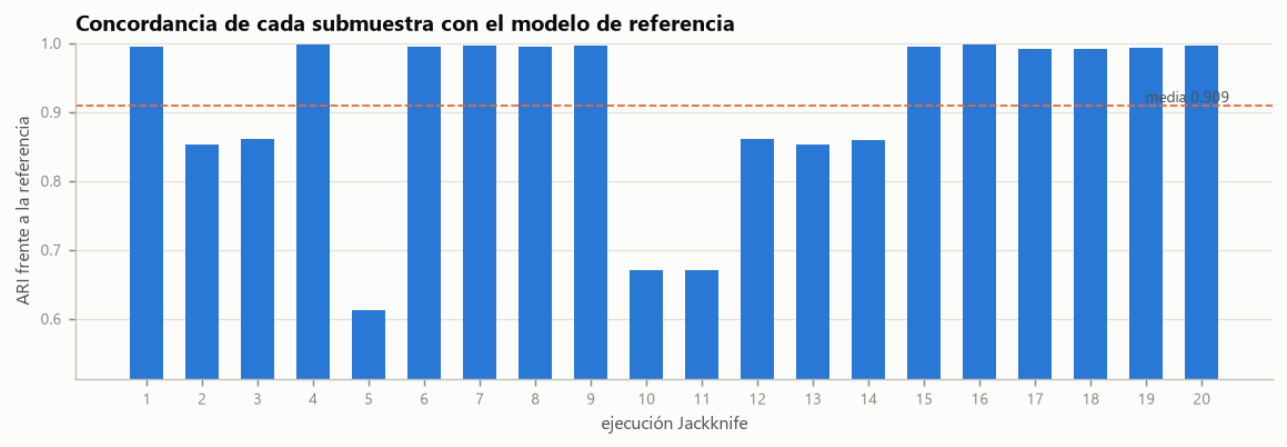


Figura 7.1. ARI de cada submuestra

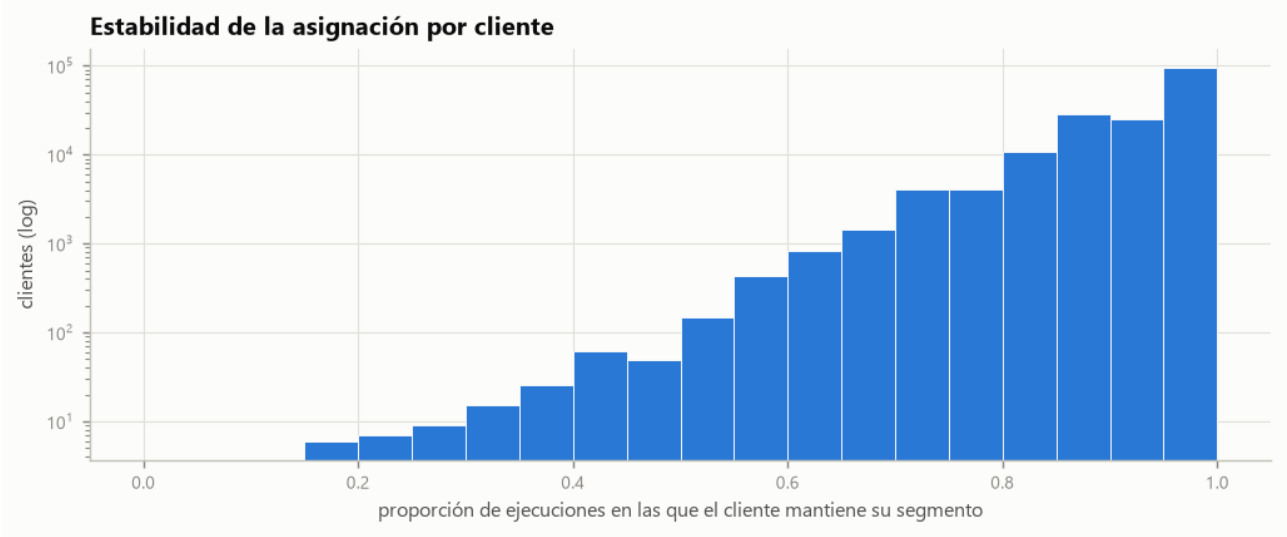


Figura 7.2. Estabilidad por cliente

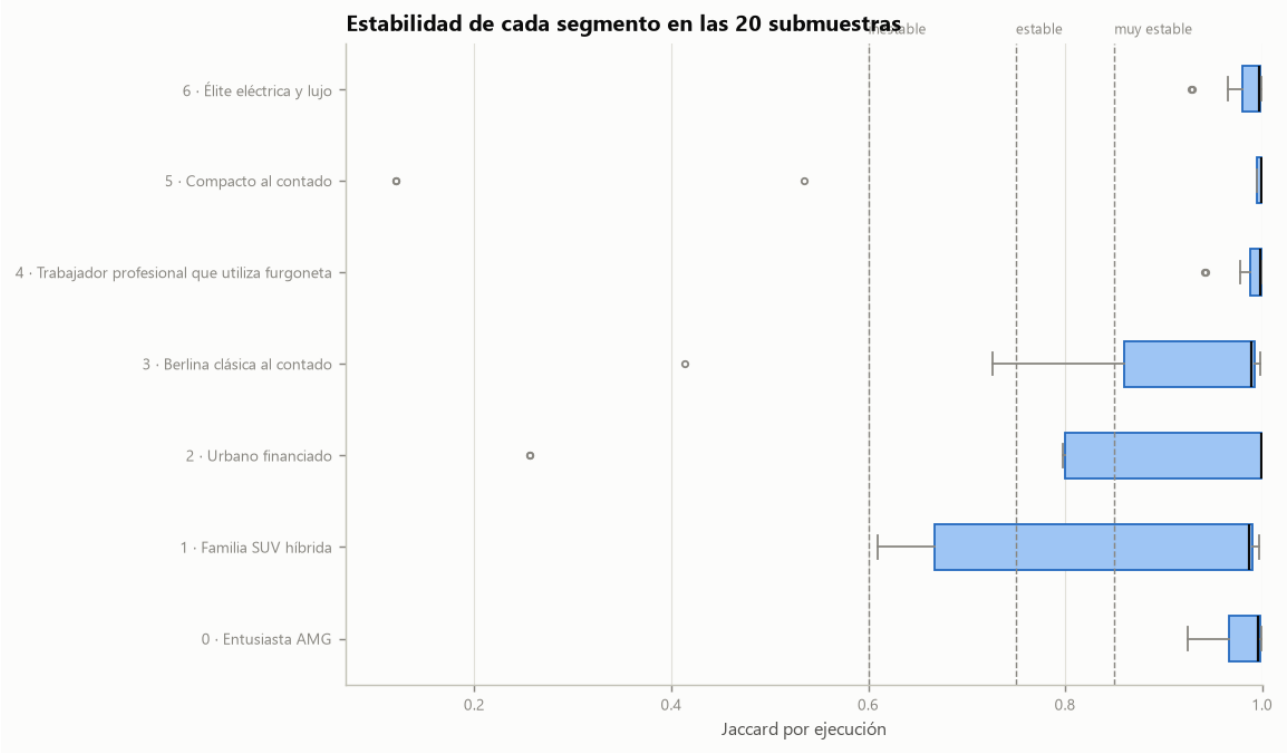


Figura 7.3. Jaccard por segmento

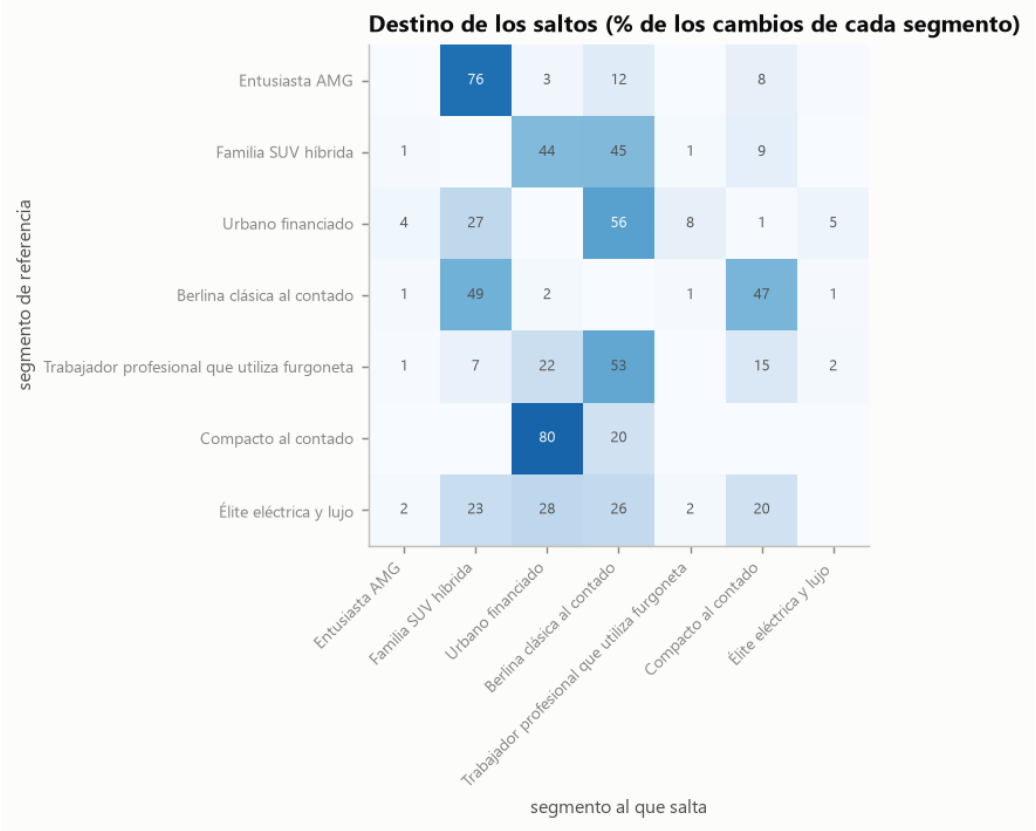


Figura 7.4. Destino de los saltos